

Adaptive Lernverfahren: Systematisierung und didaktische Aufbereitung

Johannes Dankert

2026-06-23

Adaptive Lernverfahren: Systematisierung und didaktische Aufbereitung

Bachelorarbeit
im Studiengang Informatik

Johannes Dankert
Matrikelnummer: 4279727

FernUniversität in Hagen
Fakultät für Mathematik und Informatik

Betreuer: Dr. Niels Seidel

2026

Inhaltsverzeichnis

Preface	8
1 Einleitung	9
2 Analyse adaptiver Lernverfahren	11
2.1 Forschungsstand und verwandte Arbeiten	11
2.2 Methodisches Vorgehen des Scoping Reviews	12
2.3 Bestehende Klassifikationen und Perspektiven	13
2.3.1 Adaptivitätsorientierte Klassifikationen	14
2.3.2 System- und lernendenmodellorientierte Perspektiven	14
2.3.3 Algorithmisch orientierte Perspektiven	16
2.3.4 KI- und Machine-Learning-orientierte Perspektiven	17
2.3.5 Zwischenbetrachtung und Grenzen bestehender Ansätze	18
2.4 Zentrale algorithmische Verfahren im Überblick	19
2.4.1 Learner Modeling und Knowledge Tracing	19
2.4.2 Recommender-Systeme und Lernpfadverfahren	22
2.4.3 Computerized Adaptive Testing	25
2.4.4 Reinforcement Learning	26
2.4.5 Heterogene Verfahren und Datenquellen	27
2.5 Zwischenfazit und Anforderungen an eine eigene Klassifikation	29
2.6 Offene Punkte und Grenzen	30
3 Eigene Klassifikation adaptiver Lernverfahren	32
3.1 Wahl der Klassifikationsstruktur	32
3.1.1 Herleitung der Hauptdimensionen	33
3.2 Die vorgeschlagene Klassifikation	33
3.2.1 Zustandsmodellierung	33
3.2.2 Adaptionentscheidung	38
3.3 Ergänzende Klassifikationsdimensionen	43
3.3.1 Datenbasis	43
3.3.2 Modellierungsfamilie	44
3.3.3 Interpretierbarkeit	44
3.4 Diskussion und Grenzen der Klassifikation	45
4 Konzeption der Lernressource	47
4.1 Zielsetzung	47

4.2	Didaktisches Konzept	48
4.3	Lern- und Interaktionselemente	49
4.4	Modularität und Erweiterbarkeit	50
5	Umsetzung einer Lernressource	51
5.1	Motivation und Problemstellung	51
5.2	Die Grundidee des Elo-Verfahrens	51
5.3	Algorithmische Funktionsweise des Elo-Verfahrens	52
5.4	Mathematische Grundlagen des Elo-Verfahrens	53
5.4.1	Erwartete Erfolgswahrscheinlichkeit	54
5.4.2	Aktualisierung der Bewertungen	55
5.4.3	Beispiel einer Aktualisierung	56
5.5	Implementierung des Elo-Verfahrens	58
5.5.1	Repräsentation von Lernenden und Aufgaben	58
5.5.2	Berechnung der erwarteten Erfolgswahrscheinlichkeit	58
5.5.3	Aktualisierung der Bewertungen	59
5.5.4	Durchführung einer Aktualisierung	59
5.5.5	Zusammenspiel der einzelnen Schritte	60
5.6	Interaktive Simulation des Elo-Verfahrens	61
5.6.1	Nutzung der Simulation	61
5.7	Anwendungen des Elo-Verfahrens in adaptiven Lernsystemen	65
5.7.1	Lernendenmodellierung	65
5.7.2	Schätzung von Aufgabenschwierigkeiten	65
5.7.3	Grundlage adaptiver Entscheidungen	66
5.7.4	Open Learner Models	66
5.8	Grenzen und Erweiterungen des Elo-Verfahrens	66
5.8.1	Grenzen des Standard-Elo-Verfahrens	66
5.8.2	Unsicherheitsfunktionen	67
5.8.3	Multiple-Choice-Aufgaben und Teilpunkte	69
5.8.4	Berücksichtigung von Bearbeitungszeiten	70
5.8.5	Multivariate Elo-Modelle	72
5.8.6	Erweiterung durch Lernmodellierung (PFAE)	73
	References	77

Abbildungsverzeichnis

5.1	Vergleich eines konstanten Aktualisierungsparameters K mit verschiedenen Unsicherheitsfunktionen. Die gestrichelte Linie kennzeichnet den tatsächlichen Schwierigkeitswert. Quelle: (Pelánek 2016).	68
-----	---	----

Tabellenverzeichnis

Preface

This is a Quarto book.

To learn more about Quarto books visit <https://quarto.org/docs/books>.

1 Einleitung

Lernprozesse sind durch erhebliche Unterschiede zwischen Lernenden geprägt, etwa hinsichtlich ihres Vorwissens, ihrer Lernstrategien und ihres individuellen Lerntempos (Wang u. a. 2025). Traditionelle Lernumgebungen berücksichtigen diese Heterogenität häufig nur unzureichend und folgen vielfach einem standardisierten, sogenannten „one-size-fits-all“-Ansatz, bei dem allen Lernenden identische Inhalte in gleicher Reihenfolge angeboten werden (Sibley u. a. 2024). Adaptive Lernsysteme setzen an dieser Problematik an, indem sie Lerninhalte, Aufgaben und Lernpfade gezielt an individuelle Voraussetzungen und Lernverläufe anpassen (Wang u. a. 2025). Hierbei kommen unterschiedliche methodische Ansätze zum Einsatz, um Lernprozesse dynamisch zu personalisieren und besser auf die Bedürfnisse einzelner Lernender einzugehen.

In der Forschung werden solche Systeme unter Begriffen wie adaptive learning, adaptive learning technologies oder personalized adaptive learning gefasst. Anhand aktueller Überblicksarbeiten zeigt sich, dass sich das Feld in den letzten Jahren merklich ausdifferenziert hat und heute sehr unterschiedliche technische, didaktische und methodische Ansätze existieren (Gligorea u. a. 2023; Plooy u. a. 2024).

Die damit verbundene Heterogenität macht das Themenfeld aus wissenschaftlicher Sicht besonders interessant. Adaptive Lernsysteme lassen sich nicht auf ein einzelnes Verfahren reduzieren, sondern bilden ein breites Spektrum unterschiedlicher Formen algorithmisch gestützter Personalisierung. Die Literatur verweist dabei nicht nur auf technische Entwicklungen, sondern auch auf Fragen der didaktischen Einbettung, der Transparenz, der Nutzbarkeit und der praktischen Umsetzung in Bildungskontexten (Alajlani u. a. 2024; Simon und Zeng 2024).

Bestehende Überblicksarbeiten beschreiben adaptive Lernsysteme häufig aus didaktischer, pädagogischer oder anwendungsorientierter Perspektive. Weniger im Fokus steht bislang eine informatisch orientierte Betrachtung der algorithmischen Verfahren und Mechanismen, auf denen adaptive Lernsysteme basieren. Vor diesem Hintergrund besteht weiterhin Bedarf an systematisierenden Überblicken, die unterschiedliche methodische Richtungen adaptiver Lernsysteme bündeln und strukturiert aufbereiten. Eine solche Strukturierung ist insbesondere aus informatischer Perspektive relevant, da adaptive Lernsysteme auf unterschiedlichen algorithmischen Verfahren beruhen, die jeweils spezifische Funktionen innerhalb adaptiver Lernprozesse übernehmen.

Genau daran setzt die vorliegende Arbeit an. Ziel ist es, Methoden des adaptiven Lernens auf Grundlage der Forschungsliteratur zu klassifizieren und auf dieser Basis eine interaktive Lernressource zu entwickeln und umzusetzen. Diese richtet sich an Studierende der Informatik

oder verwandter Fachrichtungen mit grundlegenden Kenntnissen in Programmierung und algorithmischem Denken und soll es ermöglichen, zentrale Verfahren verständlich nachzuvollziehen sowie deren Funktionsweise anhand interaktiver Beispiele praktisch zu erproben.

Viele Verfahren des adaptiven Lernens beruhen auf dynamischen und datengetriebenen Entscheidungsmechanismen, deren Verhalten sich häufig erst durch konkrete Interaktion nachvollziehen lässt. Insbesondere probabilistische Modelle und adaptive Auswahlverfahren sind in rein theoretischer Darstellung oft schwer zugänglich. Eine interaktive Lernressource kann dazu beitragen, solche Verfahren experimentell erfahrbar zu machen und deren Funktionsweise anhand von Parametervariationen und Visualisierungen verständlicher aufzubereiten.

Die Arbeit orientiert sich dabei an den folgenden Forschungsfragen:

1. Welche methodischen und algorithmischen Ansätze werden in der Forschung zum adaptiven Lernen beschrieben?
2. Nach welchen Kriterien lassen sich diese Ansätze sinnvoll klassifizieren?
3. Wie kann auf Grundlage dieser Klassifikation ein didaktisch sinnvolles Konzept für eine interaktive Lernressource entwickelt werden, das sich an eine informatisch geprägte Zielgruppe richtet?
4. Wie lässt sich dieses Konzept in Form einer interaktiven Lernressource konkret umsetzen?

Die Arbeit gliedert sich in mehrere Kapitel. Kapitel 2 analysiert den Forschungsstand sowie bestehende methodische Ansätze des adaptiven Lernens. Kapitel 3 entwickelt eine Klassifikation zentraler Verfahren sowie das didaktische Konzept der Lernressource. Kapitel 4 beschreibt die technische Umsetzung der Lernumgebung. Kapitel 5 widmet sich der Evaluation der entwickelten Lernressource. Abschließend fasst Kapitel 6 die Ergebnisse der Arbeit zusammen und gibt einen Ausblick auf mögliche Weiterentwicklungen.

2 Analyse adaptiver Lernverfahren

2.1 Forschungsstand und verwandte Arbeiten

Die neuere Literatur beschreibt adaptive Lernsysteme nicht als einzelne, klar umrissene Technologie, sondern als breites Feld personalisierter digitaler Lernumgebungen, die Inhalte, Rückmeldungen, Aufgaben oder Lernpfade auf Grundlage von Lernerdaten dynamisch anpassen (Plooy u. a. 2024; Wang u. a. 2025; Martin u. a. 2020). Überblicksarbeiten verdeutlichen dabei, dass adaptive Lernsysteme in sehr unterschiedlichen Bildungskontexten - etwa in Hochschulumgebungen, intelligenten Tutorensystemen oder digitalen Lernplattformen - eingesetzt werden und zugleich methodisch stark ausdifferenziert sind. Das Spektrum reicht von klassischen psychometrischen und probabilistischen Modellen über regelbasierte und wissensbasierte Verfahren bis hin zu Recommender-Systemen sowie neueren KI- und Machine-Learning-Ansätzen (Wang u. a. 2025; Hariyanto u. a. 2025; Silva u. a. 2023; Liu u. a. 2024).

Adaptive Lerntechnologien lassen sich daher nicht auf einzelne technische Ansätze reduzieren, sondern umfassen unterschiedliche Verfahren, Modelle und Formen der Personalisierung.

Allgemeine Überblicksarbeiten betonen häufig die pädagogischen, organisatorischen und implementierungsbezogenen Potenziale adaptiver Lernsysteme. Für den Hochschulbereich zeigt ein aktueller Scoping Review, dass adaptive Lernangebote häufig mit Verbesserungen von Lernleistung und Engagement verbunden sind, zugleich jedoch durch technische, zeitliche und organisatorische Ressourcen begrenzt werden. Eine weitere Review zu KI-gestützten Adaptive-Learning-Plattformen hebt hervor, dass insbesondere Plattformdesign, pädagogische Fundierung, praktische Implementierung sowie geeignete Evaluationsmetriken zentrale Themen des Forschungsfeldes darstellen. Solche Arbeiten machen die Breite und Vielfalt adaptiver Lernsysteme deutlich, betrachten Verfahren jedoch häufig primär auf Ebene konkreter Plattformen oder Anwendungsszenarien. Die zugrunde liegenden algorithmischen Verfahren werden dabei meist nicht systematisch als eigenständige Verfahrensfamilien analysiert (Plooy u. a. 2024; Tan u. a. 2025).

Daneben existieren zahlreiche spezialisierte Reviews, die jeweils nur einzelne Teilbereiche adaptiver Lernsysteme untersuchen. Wang et al. analysieren adaptive E-Learning-Systeme mit Fokus auf die Modellierung von Lernendenmerkmalen und die Verfahren zu deren Identifikation. Die Autoren zeigen dabei insbesondere die große methodische Vielfalt bestehender Learner-Modeling-Ansätze sowie eine zunehmende Erweiterung des eingesetzten Methodenspektrums von klassischen regelbasierten und probabilistischen Verfahren hin zu breiteren

Machine-Learning-Ansätzen (Wang u. a. 2025). Desmarais und Baker heben insbesondere probabilistische Modelle und Modelle latenter Wissenszustände als zentrale Ansätze des Learner- und Skill-Modelings in intelligenten Lernumgebungen hervor und zeigen, dass Verfahren zur Wissensdiagnose eine Schlüsselrolle innerhalb adaptiver Systeme einnehmen (Desmarais und Baker 2012). Neuere Surveys zu Knowledge Tracing beschreiben zudem einen Übergang von klassischen probabilistischen Verfahren wie Bayesian Knowledge Tracing hin zu tiefen neuronalen Sequenzmodellen (Abdelrahman u. a. 2023). Im Bereich des Computerized Adaptive Testing liegt der Fokus insbesondere auf Verfahren zur adaptiven Auswahl informativer Testaufgaben sowie auf der kontinuierlichen Fähigkeitsdiagnostik unter Verwendung psychometrischer Modelle (Han 2018; Liu u. a. 2024). Aktuelle Reviews zu Reinforcement Learning im Bildungsbereich zeigen, dass RL-Verfahren insbesondere zur sequentiellen Optimierung adaptiver Lernentscheidungen eingesetzt werden, zugleich jedoch weiterhin Herausforderungen hinsichtlich realistischer Trainingsdaten und praktischer Implementierung bestehen (Riedmann u. a. 2025).

Der Forschungsstand ist damit reich an spezialisierten Teilanalysen, enthält jedoch bislang nur wenige übergreifende Einordnungen, die unterschiedliche Verfahrensfamilien systematisch und aus informatischer Perspektive über Anwendungskontexte hinweg zusammenführen.

Darüber hinaus untersucht ein Teil der Literatur adaptive Lernsysteme aus Perspektive von Implementierung, Akzeptanz und Stakeholderbeteiligung. Alajlani, Crabb und Murray zeigen in ihrem systematischen Review, dass Lehrende bislang nur in begrenztem Umfang in Design, Implementierung und Evaluation adaptiver Lernsysteme eingebunden sind (Alajlani u. a. 2024). Diese Perspektive ist insbesondere für die praktische Einführung adaptiver Lernsysteme relevant, trägt jedoch nur eingeschränkt dazu bei, die zugrunde liegenden Verfahren und Adaptionsmechanismen systematisch einzuordnen.

Insgesamt zeigt der Forschungsstand damit eine deutliche Perspektivenpluralität: Pädagogische, didaktische, organisationale, anwendungsbezogene und algorithmische Zugänge existieren weitgehend nebeneinander, werden jedoch bislang nur selten in übergreifenden Systematisierungen zusammengeführt.

2.2 Methodisches Vorgehen des Scoping Reviews

Zur Analyse bestehender Klassifikationsansätze und algorithmischer Verfahren adaptiver Lernsysteme wurde ein explorativ angelegtes Scoping Review durchgeführt. Ziel war dabei nicht die vollständige Erfassung sämtlicher Veröffentlichungen des Forschungsfeldes, sondern die strukturierende Analyse zentraler Forschungsrichtungen, algorithmischer Verfahren und bestehender Systematisierungsansätze.

Das Vorgehen orientierte sich an methodischen Empfehlungen für Scoping Reviews nach Arksey und O'Malley sowie den weiterentwickelten Leitlinien von Peters et al. und PRISMA-ScR (Arksey und O'Malley 2005; Peters u. a. 2020; Tricco u. a. 2018). Übernommen wurden insbesondere die explorative Ausrichtung des Vorgehens, die systematische Identifikation relevanter Literatur sowie die thematische Zusammenführung unterschiedlicher Forschungsstränge.

Auf eine vollständige PRISMA-konforme Durchführung mit formalisiertem Screening-Prozess, detaillierter Dokumentation aller Suchanfragen und vollständigem PRISMA-Flow-Diagramm wurde hingegen verzichtet. Hintergrund hierfür ist, dass die Arbeit nicht auf eine vollständige quantitative Erfassung sämtlicher Veröffentlichungen abzielt, sondern auf die strukturierende Analyse zentraler algorithmischer Verfahren und Klassifikationsperspektiven adaptiver Lernsysteme.

Die Literaturrecherche erfolgte explorativ unter Nutzung wissenschaftlicher Suchmaschinen und Datenbanken. Ergänzend wurden KI-gestützte Recherche- und Analysewerkzeuge verwendet, um relevante Überblicksarbeiten, Surveys und thematische Zusammenhänge innerhalb des Forschungsfeldes zu identifizieren. Berücksichtigt wurden insbesondere Überblicksarbeiten, Surveys und systematische Reviews zu adaptiven Lernsystemen, algorithmischen Verfahren adaptiver Lernprozesse, Learner Modeling, Adaptivitätskonzepten, Empfehlungssystemen sowie bestehenden Klassifikations- und Strukturierungsansätzen des Forschungsfeldes.

Die Auswahl der Literatur erfolgte anhand ihrer thematischen Relevanz für die Forschungsfragen der Arbeit. Besonderes Augenmerk lag auf Arbeiten, die bestehende Klassifikationen adaptiver Systeme beschreiben oder algorithmische Verfahren und deren funktionale Rollen innerhalb adaptiver Lernprozesse analysieren.

Für die weitere Analyse wurden insbesondere Überblicksarbeiten, Surveys und systematische Reviews berücksichtigt, da diese eine vergleichende Einordnung bestehender Verfahren und Forschungsperspektiven ermöglichen. Die identifizierten Arbeiten wurden anschließend hinsichtlich ihrer Klassifikationslogiken, ihrer funktionalen Perspektiven auf Adaptivität sowie der beschriebenen algorithmischen Verfahren ausgewertet und thematisch zusammengeführt.

2.3 Bestehende Klassifikationen und Perspektiven

Die Klassifikation adaptiver Lernsysteme gestaltet sich schwierig, da die Literatur unterschiedliche Perspektiven auf Adaptivität und Personalisierung verwendet. Während einige Arbeiten adaptive Systeme primär über ihre Systemarchitektur beschreiben, orientieren sich andere an pädagogischen Zielgrößen, psychologischen Merkmalen oder spezifischen algorithmischen Teilproblemen. Eine einheitliche und allgemein akzeptierte Taxonomie adaptiver Lernverfahren existiert bislang nicht.

Für die vorliegende Arbeit ist diese Heterogenität besonders relevant, da unterschiedliche Klassifikationsansätze jeweils verschiedene funktionale Aspekte adaptiver Systeme hervorheben. Im Folgenden werden daher zentrale Perspektiven bestehender Systematisierungen analysiert und hinsichtlich ihrer Eignung für eine informatisch orientierte Klassifikation algorithmischer Verfahren eingeordnet.

Die Heterogenität der Literatur macht zugleich deutlich, dass eine informatisch orientierte Klassifikation adaptiver Lernverfahren nicht unmittelbar aus einer einzelnen bestehenden Taxonomie übernommen werden kann. Vielmehr ergibt sich die Notwendigkeit, unterschiedliche

etablierte Perspektiven vergleichend zu betrachten und zu einer begründeten Synthese zusammenzuführen.

2.3.1 Adaptivitätsorientierte Klassifikationen

Eine adaptivitätsorientierte Perspektive beschreibt adaptive Lernsysteme danach, auf welche Arten von Lernendenmerkmalen Anpassungen erfolgen. Plass und Pawar strukturieren Adaptivität dabei anhand affektiver, kognitiver, motivationaler sowie soziokultureller Variablen (Plass und Pawar 2020).

Zusätzlich unterscheiden Plass und Pawar zwischen Mikro- und Makroadaptivität. Makroadaptivität beschreibt längerfristige oder stärker vorausgeplante Anpassungen innerhalb des allgemeinen Lernkontexts. Hierzu zählen beispielsweise die Gestaltung von Lernpfaden, die Sequenzierung von Kursinhalten, vorbereitende Lernaktivitäten, Unterstützungsangebote oder curriculare Entscheidungen innerhalb eines Studienverlaufs. Anpassungen erfolgen dabei typischerweise auf Grundlage allgemeinerer Informationen über Lernende und können daher auch qualitative Merkmale und längerfristige Lernziele berücksichtigen.

Mikroadaptivität bezieht sich dagegen auf kurzfristige und dynamische Anpassungen innerhalb der unmittelbaren Lerninteraktion. Dazu gehören beispielsweise adaptive Rückmeldungen, Hilfestellungen, Aufgabenanpassungen oder die Auswahl nächster Lernschritte während der Bearbeitung konkreter Lernaufgaben. Solche Anpassungen erfordern häufig eine kontinuierliche oder echtzeitnahe Erfassung von Interaktionsdaten und beruhen daher oft auf quantitativen Messungen des Lernverhaltens (Plass und Pawar 2020).

Die Stärke dieser Taxonomie liegt insbesondere darin, dass Adaptivität nicht primär technisch, sondern funktional über die zugrunde liegenden Anpassungsziele beschrieben wird. Dadurch eignet sich der Ansatz gut, um unterschiedliche Formen personalisierten Lernens pädagogisch und psychologisch vergleichbar zu machen.

Für eine informatisch orientierte Analyse algorithmischer Verfahren bleibt diese Perspektive jedoch nur begrenzt ausreichend. Die Taxonomie fokussiert damit primär die funktionale Perspektive der Adaptivität, weniger jedoch die algorithmischen Mechanismen, durch die adaptive Entscheidungen tatsächlich realisiert werden.

2.3.2 System- und lernendenmodellorientierte Perspektiven

Im Unterschied zu adaptivitätsorientierten Ansätzen beschreiben andere Arbeiten adaptive Lernsysteme stärker über ihre Systemarchitektur und die Repräsentation lernendenbezogener Informationen. Typischerweise werden dabei Komponenten wie Domänenmodell, Learner Model, Adaptionmodell sowie Benutzerschnittstelle unterschieden. Das Domänenmodell repräsentiert dabei die fachlichen Inhalte und Wissensstrukturen eines Lernsystems, während das Learner Model Informationen über Wissen, Fähigkeiten, Präferenzen oder Interaktionen von Lernenden

enthält. Das Adaptionmodell nutzt diese Informationen, um Entscheidungen über Lerninhalte, Unterstützungsmaßnahmen oder Lernpfade zu treffen. Die Benutzerschnittstelle bildet schließlich die Interaktion zwischen Lernenden und System ab. Innerhalb dieser Architektur nimmt insbesondere das Learner Model eine zentrale Rolle ein, da dort diejenigen Informationen über Lernende repräsentiert werden, auf deren Grundlage spätere adaptive Entscheidungen erfolgen (Wang u. a. 2025).

Im Mittelpunkt dieser Perspektive stehen daher insbesondere Learner Models sowie die Frage, wie Informationen über Lernende innerhalb adaptiver Systeme strukturiert, verarbeitet und für Adaptionentscheidungen genutzt werden.

Martin et al. verfolgen eine stärker forschungs- und implementierungsorientierte Perspektive auf adaptive Lernsysteme. Statt adaptive Verfahren primär algorithmisch zu klassifizieren, systematisieren die Autoren die Forschungslandschaft anhand von Publikationstrends, Anwendungskontexten, eingesetzten Strategien und technologischen Umsetzungen adaptiver Systeme. Die Analyse zeigt dabei unter anderem, dass Lernstile über längere Zeit zu den am häufigsten betrachteten Lernendenmerkmalen gehörten. Gleichzeitig wurden insbesondere adaptive Feedback-Mechanismen und adaptive Navigation häufig untersucht. Darüber hinaus verdeutlicht die Arbeit, dass adaptive Lernsysteme in sehr unterschiedlichen Bildungskontexten eingesetzt werden und sich sowohl hinsichtlich ihrer pädagogischen Zielsetzungen als auch ihrer technischen Umsetzung stark unterscheiden (Martin u. a. 2020).

Auch Wang et al. verfolgen keine primär algorithmische Klassifikation adaptiver Systeme, sondern betrachten adaptive Lernumgebungen aus Perspektive des Learner Modelings. Im Mittelpunkt steht dabei die Frage, welche Lernendenmerkmale innerhalb adaptiver Systeme erfasst und modelliert werden und mit welchen Verfahren diese Merkmale identifiziert oder aktualisiert werden. Die Autoren beschreiben adaptive Systeme dabei als mehrstufigen Prozess: Zunächst werden relevante Merkmale von Lernenden – beispielsweise Wissen, Präferenzen oder Lernverhalten – innerhalb eines Learner Models repräsentiert. Anschließend kommen unterschiedliche Verfahren zum Einsatz, um Lernende anhand dieser Merkmale zu klassifizieren oder Veränderungen des Lernzustands zu erkennen. Auf Grundlage dieser Informationen erfolgen schließlich adaptive Entscheidungen, etwa bei der Auswahl von Lerninhalten, Aufgaben oder Unterstützungsmaßnahmen (Wang u. a. 2025).

Eine noch stärkere Fokussierung auf das Learner Model selbst findet sich bei Böck. Dort wird das Learner Model als explizite maschineninterne Repräsentation individueller Merkmale, Zustände und Interaktionsdaten eines Lernenden beschrieben. Im Mittelpunkt steht dabei insbesondere die Frage, wie lernendenbezogene Informationen innerhalb adaptiver Systeme formal strukturiert, repräsentiert und weiterverarbeitet werden.

Zugleich zeigt die Arbeit, dass viele Publikationen zwar mögliche Attribute von Learner Models benennen, deren konkrete formale Modellierung sowie die zugrunde liegenden Datenquellen jedoch häufig unklar bleiben. Darüber hinaus verweist Böck darauf, dass bislang kein allgemeiner und flexibel erweiterbarer Standard für Learner Models identifiziert werden konnte. Die fehlende Standardisierung von Learner Models hängt zugleich mit der großen Vielfalt unterschiedlicher Modellierungsansätze zusammen. Böck verweist in diesem Zusammenhang auf Verfahren, die

von regel- und constraintsbasierten Ansätzen über probabilistische Verfahren und Ontologien bis hin zu Clustering-, Klassifikations- und Deep-Learning-Methoden reichen. Dies verdeutlicht, dass adaptive Lernsysteme nicht nur unterschiedliche Lernendenmerkmale modellieren, sondern hierfür auch sehr unterschiedliche technische Modellierungsstrategien verwenden (Böck 2025).

Die betrachteten Arbeiten verdeutlichen insgesamt unterschiedliche Perspektiven auf adaptive Lernsysteme. Während Martin et al. adaptive Lernforschung primär über Kontexte, Strategien und Technologien strukturieren, stellen Wang et al. insbesondere den Prozess des Learner Modelings in den Mittelpunkt. Böck fokussiert dagegen stärker die technische Struktur und Modellierung lernendenbezogener Informationen. Gemeinsam ist diesen Ansätzen, dass sie wichtige Einblicke in Aufbau, Informationsverarbeitung und Adaptionslogik adaptiver Systeme liefern, jedoch keine durchgängige Einordnung algorithmischer Verfahrensfamilien vornehmen. Adaptive Lernsysteme werden damit häufig über Lernendenmerkmale, Systemarchitekturen oder Forschungs- und Anwendungskontexte beschrieben, weniger jedoch über die zugrunde liegenden algorithmischen Mechanismen selbst.

2.3.3 Algorithmisch orientierte Perspektiven

Im Gegensatz zu stärker pädagogisch, system- oder lernendenmodellorientierten Ansätzen existieren auch Arbeiten, die adaptive Lernsysteme primär über algorithmische Verfahren und Methoden der Wissensmodellierung strukturieren. Im Mittelpunkt steht dabei weniger die Frage, welche Lernendenmerkmale modelliert werden, sondern vielmehr, mit welchen technischen Verfahren adaptive Entscheidungen getroffen, Wissenszustände geschätzt oder Lernprozesse analysiert werden.

Zwar existieren zahlreiche spezialisierte Arbeiten zu einzelnen algorithmischen Verfahrensfamilien adaptiver Lernsysteme, darunter probabilistische Verfahren des Learner Modelings, psychometrische Modelle im Computerized Adaptive Testing, Verfahren des Knowledge Tracing, Recommender-Systeme oder Reinforcement-Learning-basierte Ansätze. Diese Arbeiten untersuchen adaptive Verfahren jedoch meist innerhalb spezifischer Anwendungskontexte oder Forschungsfelder und verwenden unterschiedliche Begrifflichkeiten, Modellannahmen und Klassifikationslogiken. Eine übergreifende und konsistente algorithmische Taxonomie adaptiver Lernverfahren findet sich bislang nur eingeschränkt.

Im Bereich des Learner Modelings spielen insbesondere probabilistische Verfahren zur Wissens- und Fähigkeitsdiagnostik eine zentrale Rolle. Desmarais und Baker beschreiben verschiedene Ansätze zur Modellierung von Wissenszuständen in intelligenten Lernumgebungen und heben hervor, dass probabilistische Modelle besonders geeignet sind, Unsicherheit innerhalb adaptiver Systeme abzubilden (Desmarais und Baker 2012). Adaptive Systeme besitzen dabei keinen direkten Zugriff auf den tatsächlichen Wissensstand von Lernenden, sondern müssen diesen aus beobachtbaren Interaktionen wie Antworten, Fehlermustern oder Bearbeitungszeiten inferieren.

Pelánek beschreibt in seiner Überblicksarbeit zum Learner Modeling insbesondere Bayesian Knowledge Tracing sowie logistische Modelle als zentrale Ansätze zur Modellierung von Wissenszuständen über mehrere Lerninteraktionen hinweg (Pelánek 2017). Gleichzeitig betont die Arbeit, dass unterschiedliche Modellierungsverfahren jeweils von den verfügbaren Daten, dem Anwendungskontext und dem Ziel der Adaptation abhängen. Lernendenmodellierung stellt damit keinen einzelnen Algorithmus dar, sondern einen breiten Bereich unterschiedlicher Zustands-, Fähigkeits- und Wahrscheinlichkeitsmodelle.

Neuere Arbeiten zum Knowledge Tracing differenzieren adaptive Wissensmodellierung zusätzlich stärker nach technischen Modellfamilien. Abdelrahman et al. unterscheiden dabei insbesondere Bayesian Models, Logistic Models sowie Deep-Learning-basierte Ansätze (Abdelrahman u. a. 2023). Neben klassischen Verfahren wie Bayesian Knowledge Tracing treten damit zunehmend neuronale Sequenzmodelle zur Modellierung latenter Wissenszustände in den Vordergrund. Die Literatur verdeutlicht zugleich, dass ähnliche funktionale Ziele – etwa die Schätzung von Wissensständen – mit sehr unterschiedlichen Modellierungsansätzen realisiert werden können.

Neben probabilistischen Verfahren existieren weitere spezialisierte algorithmische Forschungsfelder adaptiver Lernsysteme. Im Bereich des Computerized Adaptive Testing stehen insbesondere psychometrische Verfahren zur adaptiven Auswahl informativer Testaufgaben und zur kontinuierlichen Fähigkeitsdiagnostik im Mittelpunkt (Han 2018; Liu u. a. 2024). Educational Recommender Systems konzentrieren sich dagegen auf die personalisierte Auswahl von Lernressourcen, Aufgaben oder Lernpfaden auf Grundlage von Präferenzen, Interaktionsdaten oder Ähnlichkeiten zwischen Lernenden (Silva u. a. 2023; Nabizadeh u. a. 2020). Reinforcement-Learning-basierte Ansätze fokussieren schließlich die sequenzielle Optimierung adaptiver Entscheidungen und die dynamische Steuerung von Lernprozessen (Riedmann u. a. 2025).

Die algorithmisch orientierte Perspektive macht deutlich, dass adaptive Lernsysteme eine große Vielfalt unterschiedlicher Modellierungs- und Entscheidungsverfahren verwenden. Gleichzeitig zeigt sich jedoch, dass die Literatur algorithmische Verfahren häufig innerhalb spezialisierter Teilbereiche diskutiert und nur selten übergreifend zusammenführt. Die bestehende Forschungslandschaft ist damit reich an spezialisierten Verfahrensanalysen, weist jedoch weiterhin eine starke Fragmentierung hinsichtlich Begrifflichkeiten, Modellierungslogiken und Klassifikationsansätzen auf.

2.3.4 KI- und Machine-Learning-orientierte Perspektiven

Neben probabilistischen, psychometrischen oder regelbasierten Verfahren existieren auch Arbeiten, die adaptive Lernsysteme primär über Methoden des maschinellen Lernens strukturieren. Im Mittelpunkt steht dabei insbesondere die automatische Analyse von Lernerdaten sowie die datengetriebene Modellierung adaptiver Entscheidungen.

Hariyanto et al. klassifizieren adaptive Bildungssysteme beispielsweise anhand zentraler Kategorien des maschinellen Lernens und unterscheiden zwischen überwachten, unüberwachten und Reinforcement-Learning-Verfahren.

Überwachte Lernverfahren werden dabei vor allem zur Klassifikation von Lernendenprofilen und zur Vorhersage lernbezogener Eigenschaften eingesetzt. Die Autoren nennen unter anderem Entscheidungsbäume, Support Vector Machines sowie k-Nearest-Neighbor-Verfahren als typische Ansätze zur Analyse von Leistungsdaten und Lernverhalten. Ziel solcher Verfahren ist es häufig, Lernende bestimmten Kategorien oder Unterstützungsmaßnahmen zuzuordnen.

Unüberwachte Lernverfahren dienen dagegen insbesondere der Identifikation von Mustern und Gruppenstrukturen innerhalb von Lernerdaten. Hierzu werden beispielsweise Clustering-Verfahren genutzt, um Ähnlichkeiten in Interaktions-, Zeit- oder Leistungsdaten zu erkennen und Lernende anhand gemeinsamer Merkmale zu gruppieren.

Reinforcement-Learning-Verfahren werden vor allem zur dynamischen Steuerung adaptiver Lernprozesse eingesetzt. Reinforcement Learning ermöglicht dabei insbesondere die sequenzielle Optimierung von Lernpfaden, Inhaltsauswahl oder Unterstützungsmaßnahmen auf Grundlage fortlaufender Rückmeldungen aus der Interaktion mit dem Lernsystem (Hariyanto u. a. 2025).

Die KI- und ML-orientierte Perspektive verdeutlicht insbesondere die zunehmende Bedeutung datengetriebener Verfahren innerhalb adaptiver Lernsysteme. Gleichzeitig konzentrieren sich solche Arbeiten häufig auf bestimmte Paradigmen des maschinellen Lernens, während probabilistische, psychometrische oder symbolische Verfahren teilweise weniger berücksichtigt werden.

2.3.5 Zwischenbetrachtung und Grenzen bestehender Ansätze

Die analysierten Arbeiten verdeutlichen insgesamt, dass adaptive Lernsysteme in der Forschung aus sehr unterschiedlichen Perspektiven beschrieben und strukturiert werden. Während einige Ansätze Adaptivität primär über Lernendenmerkmale und pädagogische Zielgrößen definieren, fokussieren andere stärker Systemarchitekturen, Learner Models, Forschungs- und Anwendungskontexte oder konkrete algorithmische Verfahren.

Darüber hinaus zeigt sich, dass adaptive Lernsysteme häufig innerhalb spezialisierter Forschungsfelder wie Intelligent Tutoring Systems, Knowledge Tracing, Educational Recommender Systems, Computerized Adaptive Testing oder Reinforcement-Learning-basierten Lernumgebungen untersucht werden (Desmarais und Baker 2012; Abdelrahman u. a. 2023; Silva u. a. 2023; Liu u. a. 2024; Riedmann u. a. 2025). Dadurch entstehen eigenständige Teilbereiche mit jeweils eigenen Begrifflichkeiten, Modellierungsansätzen und Bewertungskriterien.

Gleichzeitig wird jedoch deutlich, dass ähnliche algorithmische Grundprinzipien in unterschiedlichen Anwendungskontexten wiederkehren. Probabilistische Zustandsmodellierung, Klassifikation, Mustererkennung oder sequenzielle Entscheidungsoptimierung treten beispielsweise in

mehreren Teilbereichen adaptiver Lernsysteme auf, werden jedoch häufig getrennt voneinander betrachtet und nur selten gemeinsam eingeordnet.

Die bestehende Literatur liefert damit zahlreiche spezialisierte Teilsystematiken und wichtige Perspektiven auf adaptive Lernsysteme, bietet bislang jedoch nur begrenzte Ansätze für eine integrierte informatisch orientierte Klassifikation algorithmischer Verfahren. Insbesondere fehlt häufig eine gemeinsame Strukturierung, die funktionale Rolle, Datenbasis, Adaptionsmechanismus und technische Modellierungsansätze systematisch zusammenführt.

2.4 Zentrale algorithmische Verfahren im Überblick

Für eine informatisch orientierte Betrachtung adaptiver Lernsysteme ist zunächst weniger entscheidend, welcher konkrete Plattfortyp vorliegt, sondern vielmehr, welche algorithmischen Verfahrensfamilien innerhalb adaptiver Systeme wiederkehren und welche funktionalen Rollen diese übernehmen.

2.4.1 Learner Modeling und Knowledge Tracing

Eine zentrale Rolle spielt dabei der Bereich des Learner Modeling beziehungsweise der Wissens- und Fähigkeitsdiagnostik.

Learner Modeling beschäftigt sich grundsätzlich mit der Frage, wie Wissen, Fähigkeiten, Präferenzen oder weitere lernendenbezogene Merkmale innerhalb eines adaptiven Systems repräsentiert und fortlaufend aktualisiert werden können (Wang u. a. 2025; Böck 2025). Adaptive Systeme besitzen dabei keinen direkten Zugriff auf den tatsächlichen Wissensstand eines Lernenden. Beobachtbar sind lediglich Interaktionen mit dem System, etwa Antworten auf Aufgaben, Fehlversuche, Bearbeitungszeiten oder Navigationsverhalten. Der eigentliche Wissenszustand stellt somit eine latente Größe dar, die aus beobachtbaren Daten erschlossen werden muss (Desmarais und Baker 2012).

Vor diesem Hintergrund spielen probabilistische Verfahren eine zentrale Rolle im Learner Modeling. Desmarais und Baker betonen, dass probabilistische Modelle für die Einschätzung von Fähigkeiten und Wissenszuständen in intelligenten Lernumgebungen von grundlegender Bedeutung sind. Solche Verfahren gehen davon aus, dass Wissen nicht als direkt beobachtbarer Zustand vorliegt, sondern nur mit einer bestimmten Wahrscheinlichkeit angenommen werden kann. Anstatt einen Lernenden eindeutig als „beherrscht“ oder „nicht beherrscht“ zu klassifizieren, modellieren probabilistische Ansätze daher die Wahrscheinlichkeit, mit der bestimmte Kenntnisse oder Fähigkeiten vorhanden sind. Neue Interaktionen mit dem Lernsystem können anschließend genutzt werden, um diese Wahrscheinlichkeiten fortlaufend anzupassen und die Einschätzung des Wissenszustands zu aktualisieren (Desmarais und Baker 2012).

In der späteren Überblicksliteratur zum Learner Modeling hebt Pelánek insbesondere Bayesian Knowledge Tracing sowie logistische Modelle als wichtige Ansätze zur Modellierung von Wissenszuständen hervor. Bayesian Knowledge Tracing modelliert dabei den Wissenszustand eines Lernenden als Wahrscheinlichkeit, die nach jeder bearbeiteten Aufgabe aktualisiert wird. Logistische Modelle verfolgen dagegen einen stärker statistischen Ansatz und schätzen die Wahrscheinlichkeit korrekter Antworten auf Grundlage bestimmter Merkmale von Lernenden oder Aufgaben. Beide Ansätze verfolgen damit das Ziel, Lernprozesse quantitativ zu beschreiben und zukünftige Lernleistungen vorherzusagen, beruhen jedoch auf unterschiedlichen Modellannahmen über Wissenserwerb und Kompetenzentwicklung (Pelánek 2017).

Gleichzeitig betont Pelánek, dass die Wahl eines geeigneten Modells stets vom jeweiligen Anwendungskontext, den verfügbaren Daten sowie dem Ziel der Adaptation abhängt (Pelánek 2017). Lernendenmodellierung stellt damit keinen einzelnen Algorithmus dar, sondern einen breiten Bereich unterschiedlicher Zustands-, Fähigkeits- und Wahrscheinlichkeitsmodelle, die jeweils verschiedene Perspektiven auf Lernen, Wissen und Kompetenzentwicklung abbilden.

Besonders stark ausdifferenziert ist dieser Bereich im Forschungsfeld des Knowledge Tracing. Knowledge Tracing beschäftigt sich mit der Frage, wie sich der Wissenszustand eines Lernenden über mehrere Lerninteraktionen hinweg modellieren und fortlaufend aktualisieren lässt. Ziel ist es, auf Grundlage bisheriger Bearbeitungen möglichst präzise abzuschätzen, welche Wissenskomponenten bereits beherrscht werden und bei welchen weiterhin Lernbedarf besteht (Abdelrahman u. a. 2023).

Der Survey von Shen et al. unterscheidet drei grundlegende technische Modellierungsrichtungen innerhalb des Knowledge Tracing: Bayesian Models, Logistic Models und Deep Learning Models (Shen u. a. 2024). Diese Einteilung ist für eine informatische Systematisierung besonders relevant, da die Verfahren nicht primär nach ihrem Anwendungskontext, sondern nach ihrer technischen Modellierungslogik gruppiert werden.

Bayesian Models modellieren Wissen als verborgenen beziehungsweise latenten Zustand, dessen Wahrscheinlichkeit anhand beobachtbarer Interaktionen geschätzt wird. Zu den bekanntesten Vertretern zählen Bayesian Knowledge Tracing (BKT) sowie Erweiterungen wie Dynamic Bayesian Knowledge Tracing (DBKT). Der Wissenszustand eines Lernenden wird dabei als Wahrscheinlichkeit dargestellt, die nach jeder bearbeiteten Aufgabe auf Grundlage neuer Beobachtungen aktualisiert wird (Pelánek 2017; Shen u. a. 2024).

Logistic Models verfolgen dagegen einen stärker statistischen Ansatz. Zu den wichtigsten Vertretern zählen Learning Factors Analysis (LFA) und Performance Factors Analysis (PFA). Im Mittelpunkt steht hierbei die Schätzung der Wahrscheinlichkeit korrekter Antworten auf Grundlage beobachtbarer Merkmale und Interaktionsdaten, etwa früherer Erfolge oder Fehlversuche. Im Unterschied zu klassischen Bayesian-Modellen wird dabei nicht unmittelbar ein verborgener Wissenszustand modelliert, sondern das Antwortverhalten selbst statistisch beschrieben (Shen u. a. 2024).

Deep-Learning-basierte Verfahren verzichten weitgehend auf manuell definierte Wissensmodelle und lernen Zusammenhänge direkt aus großen Mengen von Interaktionsdaten. Zu den bekan-

ntesten Ansätzen zählt Deep Knowledge Tracing (DKT), das rekurrente neuronale Netze zur Modellierung von Lernverläufen verwendet. Neuere Varianten erweitern diesen Ansatz beispielsweise um Speichermechanismen, Aufmerksamkeitsstrukturen oder Graphrepräsentationen. Dadurch können komplexe Muster im Lernverhalten erfasst werden, allerdings geht dies häufig zulasten der Interpretierbarkeit der Modelle (Shen u. a. 2024).

Die von Shen et al. vorgeschlagene Einteilung verdeutlicht, dass dieselbe funktionale Aufgabe – die Schätzung von Wissenszuständen – mit sehr unterschiedlichen technischen Modellierungsansätzen realisiert werden kann. Für eine informatische Klassifikation adaptiver Verfahren sind daher nicht nur die funktionalen Ziele, sondern auch die zugrunde liegenden Modellierungslogiken von zentraler Bedeutung.

Gleichzeitig zeigt die Knowledge-Tracing-Literatur, dass sich die verschiedenen Verfahren nicht nur hinsichtlich ihrer Modellierungsansätze, sondern auch hinsichtlich der verwendeten Datenbasis unterscheiden. Die Qualität der Wissensschätzung hängt wesentlich davon ab, welche Informationen einem Modell zur Verfügung stehen und wie diese in die Schätzung des Lernzustands einbezogen werden (Shen u. a. 2024). Frühe Knowledge-Tracing-Modelle arbeiten häufig ausschließlich mit Aufgabenfolgen und den zugehörigen Antwortdaten. Das Modell beobachtet dabei typischerweise, ob eine Aufgabe korrekt oder inkorrekt beantwortet wurde, und nutzt diese Informationen zur Aktualisierung des geschätzten Wissenszustands. Solche Ansätze sind vergleichsweise einfach zu implementieren und benötigen nur wenige Eingabedaten, können jedoch viele Einflussfaktoren des tatsächlichen Lernprozesses nicht berücksichtigen (Shen u. a. 2024). Neuere Verfahren erweitern diese Datenbasis deutlich. Neben den eigentlichen Antwortdaten werden zunehmend zusätzliche Informationen in die Modellierung einbezogen. Hierzu zählen beispielsweise individuelle Eigenschaften eines Lernenden vor Beginn des Lernprozesses, Merkmale des bisherigen Lernverlaufs, Indikatoren für Motivation oder Engagement sowie Informationen über Vergessensprozesse im Zeitverlauf. Darüber hinaus werden sogenannte Side Information genutzt, etwa Antwortzeiten, Bearbeitungsdauer, Navigationsmuster oder Tutorinterventionen während des Lernprozesses (Shen u. a. 2024). Diese Entwicklung verdeutlicht, dass dieselbe funktionale Aufgabe – die Schätzung von Wissenszuständen – mit sehr unterschiedlichen Datentiefegraden realisiert werden kann. Während einfache Modelle lediglich auf einer Folge richtiger und falscher Antworten basieren, versuchen komplexere Verfahren ein umfassenderes Bild des Lernprozesses zu erfassen (Shen u. a. 2024).

Für die Frage der Interpretierbarkeit ist diese Unterscheidung von zentraler Bedeutung. Der Survey von Shen et al. weist ausdrücklich darauf hin, dass moderne Deep-Learning-Verfahren im Knowledge Tracing häufig eine höhere Vorhersagegenauigkeit erreichen als traditionelle Ansätze, ihre Entscheidungsprozesse jedoch deutlich schwerer nachvollziehbar sind (Shen u. a. 2024). Während klassische Modelle meist auf klar definierten Parametern und Modellannahmen beruhen, entstehen die Vorhersagen tiefer neuronaler Netze aus einer großen Zahl interner Berechnungen, deren Einfluss auf das Ergebnis oft nur schwer zu interpretieren ist.

Gerade im Bildungskontext besitzt diese Problematik besondere Relevanz. Adaptive Lernsysteme treffen Entscheidungen über Lerninhalte, Empfehlungen, Unterstützungsmaßnahmen oder die Einschätzung von Wissensständen. Lehrende und Lernende haben dabei häufig ein

berechtigtes Interesse daran, nachvollziehen zu können, warum ein System eine bestimmte Einschätzung vorgenommen oder eine konkrete Empfehlung ausgesprochen hat. Fehlende Transparenz kann die Akzeptanz adaptiver Systeme reduzieren und erschwert zugleich die pädagogische Bewertung ihrer Entscheidungen.

Vor diesem Hintergrund hat sich innerhalb der Knowledge-Tracing-Forschung ein eigener Forschungsstrang zu interpretierbaren Modellen und Explainable Artificial Intelligence (XAI) entwickelt. Ziel dieser Arbeiten ist es, die Entscheidungsprozesse komplexer Modelle besser verständlich zu machen und zusätzliche Erklärungen für Vorhersagen bereitzustellen. Dabei werden beispielsweise Einflussfaktoren einzelner Aufgaben, Wissenskomponenten oder Interaktionen sichtbar gemacht, um die Ursachen einer Modellentscheidung nachvollziehbarer darzustellen (Shen u. a. 2024).

Für eine informatische Klassifikation adaptiver Verfahren ergibt sich daraus eine wichtige zusätzliche Betrachtungsdimension. Modelle unterscheiden sich nicht nur hinsichtlich ihrer Vorhersageleistung oder ihrer technischen Modellierungslogik, sondern auch hinsichtlich ihrer Transparenz und Erklärbarkeit. Probabilistische und logistische Verfahren sind dabei häufig leichter interpretierbar als Deep-Learning-Ansätze, während tiefe neuronale Modelle oftmals eine höhere Modellkomplexität und geringere Nachvollziehbarkeit aufweisen (Shen u. a. 2024). Die Interpretierbarkeit eines Verfahrens stellt daher eine eigenständige Eigenschaft dar, die bei einer systematischen Einordnung adaptiver Lernverfahren berücksichtigt werden sollte.

2.4.2 Recommender-Systeme und Lernpfadverfahren

Eine zweite große Verfahrensfamilie bilden Recommender-Systeme und Lernpfadverfahren. Während Verfahren des Learner Modelings primär auf die Diagnose und Modellierung von Wissenszuständen abzielen, steht bei Recommender-Systemen die Auswahl und Priorisierung geeigneter Lernressourcen im Vordergrund. Ziel ist es, Lernenden diejenigen Inhalte, Aufgaben oder Lernaktivitäten bereitzustellen, die für ihre individuellen Bedürfnisse, Interessen oder Lernziele besonders relevant erscheinen (Silva u. a. 2023).

Im Bildungsbereich werden Recommender-Systeme daher als zentrales Instrument zur Personalisierung von Lernumgebungen betrachtet. Empfehlungen können sich beispielsweise auf Lernmaterialien, Aufgaben, Kurse, Lernpfade oder unterstützende Ressourcen beziehen. Grundlage hierfür bilden typischerweise Informationen über Lernende, deren bisheriges Lernverhalten, Leistungsdaten, Präferenzen oder Ähnlichkeiten zu anderen Nutzenden (Silva u. a. 2023).

Der systematische Review von da Silva et al. zeigt, dass insbesondere hybride Recommender-Systeme in der aktuellen Forschung und Praxis eine dominante Rolle einnehmen. Hybride Verfahren kombinieren dabei unterschiedliche Empfehlungsstrategien, etwa kollaboratives Filtern, inhaltsbasierte Verfahren oder wissensbasierte Ansätze. Ziel dieser Kombination ist es, die jeweiligen Stärken einzelner Methoden zu nutzen und deren Schwächen auszugleichen. So können beispielsweise Empfehlungen nicht nur auf Ähnlichkeiten zwischen Lernenden beruhen,

sondern zusätzlich fachliche Eigenschaften von Lernressourcen oder pädagogische Anforderungen berücksichtigen (Silva u. a. 2023).

Die einzelnen Empfehlungsstrategien werden wiederum durch unterschiedliche algorithmische Verfahren realisiert. Kollaborative Recommender nutzen beispielsweise Ähnlichkeitsmaße oder Nachbarschaftsverfahren wie k-Nearest Neighbors, um Lernende mit vergleichbaren Interessen oder Verhaltensmustern zu identifizieren. Inhaltsbasierte Ansätze arbeiten häufig mit Merkmalsvektoren und Ähnlichkeitsmaßen wie der Kosinus-Ähnlichkeit, um passende Lernressourcen zu bestimmen. Darüber hinaus kommen in Educational Recommender Systems Verfahren wie Matrix Factorization, Fuzzy Logic, genetische Algorithmen sowie zunehmend neuronale Netze und Deep-Learning-Ansätze zum Einsatz (Silva u. a. 2023).

Gleichzeitig weist die Review darauf hin, dass die Evaluation von Educational Recommender Systems bislang überwiegend auf technischen Qualitätsmaßen wie Genauigkeit, Präzision oder Trefferquote basiert, während die tatsächliche pädagogische Wirksamkeit deutlich seltener untersucht wird (Silva u. a. 2023). Für die Analyse adaptiver Lernverfahren ist dieser Befund besonders relevant, da Recommender-Systeme nicht primär der Wissensdiagnostik dienen, sondern der Auswahl und Priorisierung von Lernressourcen. Der Erfolg eines Verfahrens lässt sich daher nicht allein an der Qualität der Empfehlung messen, sondern sollte idealerweise auch anhand von Lernerfolg, Motivation oder Lernerfahrung bewertet werden.

Innerhalb dieses Bereichs sind insbesondere wissens- und ontologiebasierte Recommender-Systeme von besonderem Interesse. Im Unterschied zu vielen datengetriebenen Verfahren beruhen sie nicht primär auf statistischen Mustern oder Ähnlichkeiten zwischen Nutzenden, sondern auf explizit modelliertem Wissen über Lernende, Lernressourcen und fachliche Zusammenhänge. Die Personalisierung erfolgt dabei auf Grundlage formalisierter Wissensstrukturen, welche Beziehungen zwischen Konzepten, Lernzielen, Kompetenzen oder Inhaltsbereichen beschreiben (George und Lal 2019).

Ontologien dienen in diesem Zusammenhang als formale Repräsentationen von Wissen. Sie definieren Konzepte eines bestimmten Anwendungsbereichs sowie die Beziehungen zwischen diesen Konzepten. Dadurch können Lerninhalte, Wissensgebiete, Kompetenzen und Lernendenmerkmale strukturiert beschrieben und maschinell verarbeitet werden. Adaptive Systeme können diese Wissensstrukturen nutzen, um Zusammenhänge zwischen Lernenden und Lernressourcen abzuleiten und darauf aufbauend personalisierte Empfehlungen zu erzeugen (George und Lal 2019).

George und Lal heben hervor, dass ontologiebasierte Ansätze insbesondere Reusability, Reasoning und Inferenz unterstützen (George und Lal 2019). Da Wissen explizit modelliert wird, können Systeme nicht nur vorhandene Informationen speichern, sondern zusätzliche Beziehungen und Schlussfolgerungen aus den modellierten Strukturen ableiten. Dadurch eignen sich Ontologien besonders für adaptive Lernumgebungen, in denen fachliche Abhängigkeiten, Kompetenzmodelle oder curriculare Zusammenhänge berücksichtigt werden sollen.

Die Review von George und Lal zeigt zugleich, dass ontologiebasierte Recommender-Systeme unterschiedliche technische Verfahren zur Generierung von Empfehlungen einsetzen (George

und Lal 2019). Häufig kommen dabei regelbasierte Schlussfolgerungsverfahren (Rule-Based Reasoning), semantische Ähnlichkeitsmaße (Semantic Similarity), Case-Based Reasoning sowie hybride Ansätze zum Einsatz, welche Ontologien mit kollaborativen Filterverfahren, Fuzzy-Logic-Methoden oder weiteren Empfehlungstechniken kombinieren. Die eigentliche Empfehlung entsteht dabei nicht allein durch statistische Muster in den Nutzungsdaten, sondern durch Schlussfolgerungen auf Grundlage der modellierten Wissensstrukturen.

Besonders semantische Ähnlichkeitsverfahren spielen eine wichtige Rolle. Dabei werden Beziehungen zwischen Konzepten innerhalb einer Ontologie genutzt, um die fachliche Nähe zwischen Lernressourcen, Kompetenzen oder Lernzielen zu bestimmen. Regelbasierte Verfahren ermöglichen darüber hinaus die Formulierung expliziter pädagogischer oder fachlicher Regeln, auf deren Grundlage Empfehlungen abgeleitet werden können. Adaptive Entscheidungen beruhen damit stärker auf symbolischen Inferenzprozessen als auf rein datengetriebenem Lernen (George und Lal 2019).

Gleichzeitig verweisen die Autoren auf mehrere Herausforderungen. Die Erstellung und Pflege ontologischer Wissensmodelle ist häufig mit hohem Modellierungsaufwand verbunden und erfordert umfangreiche Domänenkenntnisse. Darüber hinaus wird die Evaluation solcher Systeme durch das Fehlen standardisierter Datensätze und Vergleichsgrundlagen erschwert (George und Lal 2019).

Für eine informatische Klassifikation adaptiver Verfahren sind ontologiebasierte Recommender insbesondere deshalb relevant, weil sie eine deutlich andere Modellierungslogik verfolgen als rein datengetriebene Ansätze. Während viele Machine-Learning-Verfahren Zusammenhänge implizit aus Interaktionsdaten lernen, beruhen ontologiebasierte Systeme auf explizit repräsentiertem Wissen und symbolischen Schlussfolgerungsmechanismen. Adaptive Lernsysteme unterscheiden sich daher nicht nur hinsichtlich ihrer Algorithmen, sondern auch hinsichtlich der Art, wie Wissen innerhalb des Systems repräsentiert und verarbeitet wird.

Verwandt, aber nicht deckungsgleich mit Recommender-Systemen sind Lernpfad- und Sequenzierungsverfahren. Während klassische Recommender-Systeme primär die Auswahl einzelner Lernressourcen oder Inhalte unterstützen, beschäftigen sich Lernpfadverfahren mit der Planung, Generierung und Anpassung ganzer Sequenzen von Lernaktivitäten. Im Mittelpunkt steht dabei die Frage, in welcher Reihenfolge Lerninhalte bearbeitet werden sollten, um individuelle Lernziele möglichst effizient zu erreichen (Nabizadeh u. a. 2020).

Der Survey von Nabizadeh et al. unterscheidet zur Personalisierung von Lernpfaden drei zentrale Ansätze: Course Generation, Sequential Pattern Recognition und Course Sequence. Bei der Course Generation werden individuelle Lernpfade auf Grundlage von Lernzielen, Vorwissen oder Kompetenzanforderungen erzeugt. Sequential Pattern Recognition konzentriert sich dagegen auf die Identifikation erfolgreicher Lernsequenzen innerhalb vorhandener Lerndaten, um daraus geeignete Reihenfolgen von Lernaktivitäten abzuleiten. Course-Sequence-Verfahren fokussieren schließlich die gezielte Planung und Optimierung von Kurs- oder Inhaltsabfolgen unter Berücksichtigung fachlicher Abhängigkeiten, Voraussetzungen und Lernfortschritte (Nabizadeh u. a. 2020).

Die einzelnen Ansätze zur Lernpfadpersonalisierung werden durch sehr unterschiedliche Optimierungs- und Suchverfahren realisiert. Der Survey von Nabizadeh et al. zeigt, dass insbesondere evolutionäre Verfahren wie Genetic Algorithms, schwarmbasierte Optimierungsverfahren wie Ant Colony Optimization und Particle Swarm Optimization, graphbasierte Verfahren, Constraint-based Approaches sowie Case-Based-Reasoning-Ansätze eingesetzt werden (Nabizadeh u. a. 2020).

Gemeinsam ist diesen Verfahren, dass sie nicht lediglich einzelne Inhalte auswählen, sondern mögliche Lernsequenzen als Optimierungsproblem betrachten. Ziel ist es, unter Berücksichtigung von Lernzielen, Vorwissen, Voraussetzungen oder zeitlichen Restriktionen eine möglichst geeignete Reihenfolge von Lernaktivitäten zu bestimmen. Graphbasierte Verfahren modellieren Lernpfade beispielsweise als Netzwerke von Lernobjekten und suchen geeignete Wege durch diese Strukturen. Evolutionäre und schwarmbasierte Verfahren erzeugen dagegen schrittweise verbesserte Lernpfade, indem verschiedene Lösungsalternativen miteinander verglichen und optimiert werden (Nabizadeh u. a. 2020).

Darüber hinaus zeigt die Literatur, dass Lernpfadverfahren häufig mehrere Modellierungsansätze kombinieren. Neben klassischen Optimierungsverfahren kommen unter anderem Reinforcement-Learning-Ansätze, Fuzzy-Logic-Methoden sowie wissensbasierte Verfahren zum Einsatz. Die algorithmische Vielfalt verdeutlicht, dass Lernpfadpersonalisierung weniger als einzelner Algorithmus, sondern vielmehr als eigenständige Klasse sequenzieller Entscheidungs- und Optimierungsprobleme verstanden werden kann (Nabizadeh u. a. 2020).

Insgesamt verdeutlicht die Literatur, dass Lernpfadpersonalisierung einen eigenständigen Bereich adaptiver Lernverfahren darstellt. Im Unterschied zu klassischen Recommender-Systemen steht nicht primär die Auswahl eines einzelnen Inhaltsobjekts im Vordergrund, sondern die Planung, Generierung und Optimierung ganzer Lernsequenzen (Nabizadeh u. a. 2020). Die Vielfalt der eingesetzten Verfahren – von graphbasierten und wissensbasierten Ansätzen über evolutionäre und schwarmbasierte Optimierungsverfahren bis hin zu Reinforcement-Learning-Methoden – zeigt, dass Lernpfadpersonalisierung als sequenzielles Entscheidungs- und Optimierungsproblem verstanden werden kann. Für eine informatische Klassifikation adaptiver Verfahren ergibt sich daraus, dass nicht nur die verwendeten Algorithmen, sondern auch die Art der zu lösenden Entscheidungsprobleme berücksichtigt werden sollte.

2.4.3 Computerized Adaptive Testing

Die Grundlage vieler Computerized-Adaptive-Testing-Systeme bilden psychometrische Messmodelle, insbesondere Verfahren der Item Response Theory (IRT) (Han 2018; Liu u. a. 2024). Im Gegensatz zu klassischen Tests wird dabei nicht davon ausgegangen, dass alle Testpersonen dieselben Aufgaben bearbeiten müssen. Stattdessen wird die Schwierigkeit einer Aufgabe in Beziehung zur geschätzten Fähigkeit einer Person gesetzt. Auf Grundlage der bisherigen Antworten wird fortlaufend eine Schätzung des Fähigkeitsniveaus berechnet, die anschließend die Auswahl weiterer Aufgaben steuert.

Han beschreibt die klassische CAT-Architektur über drei zentrale Komponenten des Item-Selection-Algorithmus: Content Balancing, Item Selection Criterion und Item Exposure Control (Han 2018). Content Balancing stellt sicher, dass unterschiedliche Inhaltsbereiche angemessen berücksichtigt werden. Das Item Selection Criterion bestimmt, welche Aufgabe für die aktuelle Fähigkeitsschätzung den größten Informationsgewinn verspricht. Item Exposure Control dient dazu, eine übermäßige Wiederverwendung einzelner Aufgaben zu verhindern und die Qualität des Aufgabenpools langfristig zu erhalten.

Die einzelnen Komponenten werden wiederum durch unterschiedliche psychometrische und algorithmische Verfahren realisiert. Für die Fähigkeitsschätzung kommen häufig Modelle der Item Response Theory (IRT) zum Einsatz, insbesondere das Rasch-Modell (1PL) sowie die erweiterten 2PL- und 3PL-Modelle, welche unterschiedliche Eigenschaften von Testaufgaben berücksichtigen. Die Auswahl der nächsten Aufgabe erfolgt häufig informationsbasiert, etwa über Maximum-Fisher-Information-Kriterien, bei denen jene Aufgabe ausgewählt wird, die für die aktuelle Fähigkeitsschätzung den größten erwarteten Informationsgewinn liefert. Zur Kontrolle der Aufgabennutzung werden darüber hinaus Exposure-Control-Verfahren eingesetzt, beispielsweise das Sympon-Hetter-Verfahren, um eine übermäßige Wiederverwendung einzelner Testitems zu verhindern (Han 2018).

Der Survey von Liu et al. erweitert diese klassische Sichtweise um zusätzliche Komponenten wie Measurement Models, Question Selection, Bank Construction und Test Control (Liu u. a. 2024). Dabei kommen zunehmend auch Machine-Learning- und Optimierungsverfahren zum Einsatz. Für die Aufgabenwahl werden beispielsweise informationsbasierte Selektionsverfahren, Bayes-Methoden oder banditähnliche Strategien diskutiert. Darüber hinaus werden Verfahren zur automatisierten Konstruktion und Kalibrierung von Aufgabenpools sowie Modelle zur Vorhersage von Itemeigenschaften untersucht. Die Literatur verdeutlicht damit einen Wandel von klassischen psychometrischen CAT-Systemen hin zu stärker datengetriebenen und algorithmisch erweiterten Adaptionsarchitekturen (Liu u. a. 2024).

Für eine informatische Betrachtung adaptiver Verfahren ist CAT besonders interessant, weil die einzelnen Schritte der Adaptation explizit modelliert werden. Die Fähigkeitsschätzung, die Auswahl der nächsten Aufgabe, die Kontrolle der Testbedingungen sowie die Entscheidung über die Beendigung des Tests erfolgen innerhalb einer klar definierten Entscheidungsarchitektur (Han 2018; Liu u. a. 2024). Im Unterschied zu vielen anderen adaptiven Lernverfahren steht damit nicht primär die Modellierung komplexer Lernprozesse im Vordergrund, sondern die möglichst effiziente Gewinnung von Informationen über den Fähigkeitsstand einer Person. CAT stellt somit ein Anwendungsfeld dar, in dem Adaptivität als sequenzielles Entscheidungs- und Optimierungsproblem besonders deutlich sichtbar wird.

2.4.4 Reinforcement Learning

Reinforcement Learning unterscheidet sich von vielen anderen adaptiven Verfahren dadurch, dass Entscheidungen nicht auf Grundlage fester Regeln oder bereits gelernter Modelle getroffen

werden, sondern durch fortlaufende Interaktion mit einer Umgebung optimiert werden. Ein Agent wählt dabei wiederholt Aktionen aus, beobachtet deren Auswirkungen und erhält Rückmeldungen in Form von Belohnungen oder Bestrafungen. Ziel ist es, langfristig eine Strategie zu erlernen, welche den kumulierten Nutzen über viele Entscheidungsschritte hinweg maximiert (Riedmann u. a. 2025).

Diese Grundidee ist für adaptive Lernsysteme besonders attraktiv, da viele Bildungsprozesse selbst als sequenzielle Entscheidungsprobleme verstanden werden können. Die Auswahl eines Lerninhalts beeinflusst beispielsweise nicht nur den unmittelbaren Lernerfolg, sondern auch spätere Lernmöglichkeiten und den weiteren Lernverlauf. Reinforcement-Learning-Verfahren ermöglichen es daher, adaptive Entscheidungen nicht isoliert, sondern im Kontext langfristiger Lernziele zu optimieren (Riedmann u. a. 2025).

Die Literatur berichtet dabei unterschiedliche Klassen von Reinforcement-Learning-Verfahren. Zu den klassischen Ansätzen zählt Q-Learning, bei dem für jede mögliche Aktion schrittweise ein erwarteter Nutzenwert erlernt wird. Deep-Q-Networks (DQN) erweitern dieses Prinzip durch neuronale Netze und ermöglichen die Verarbeitung komplexerer Zustandsräume. Policy-Gradient-Verfahren wie REINFORCE verfolgen dagegen einen anderen Ansatz: Statt einzelne Aktionswerte zu schätzen, lernen sie direkt eine Entscheidungsstrategie, welche die Auswahl zukünftiger Aktionen steuert (Riedmann u. a. 2025).

Die verschiedenen Verfahren unterscheiden sich insbesondere hinsichtlich ihrer Repräsentation von Zuständen, ihrer Lernstrategie sowie ihrer Skalierbarkeit auf komplexe Lernumgebungen. Während klassische Verfahren wie Q-Learning häufig leichter interpretierbar sind, ermöglichen Deep-Reinforcement-Learning-Ansätze die Modellierung deutlich komplexerer Adaptionsprozesse (Riedmann u. a. 2025).

2.4.5 Heterogene Verfahren und Datenquellen

Über diese Verfahrensfamilien hinaus bleibt festzuhalten, dass adaptive E-Learning-Systeme in der Praxis nur selten auf einem einzelnen Modellierungsansatz beruhen. Der systematische Review von Wang et al. zeigt, dass insbesondere Lernstile, Wissensstände und Lernverhalten häufig gemeinsam innerhalb von Learner Models berücksichtigt werden und zu ihrer Modellierung sehr unterschiedliche Verfahren eingesetzt werden (Wang u. a. 2025).

Die Autoren identifizieren unter anderem Bayesian Networks, Neural Networks, Fuzzy-Logic-Methoden, Entscheidungsbäume, k-Nearest-Neighbor-Verfahren, Faktorenanalyse sowie regelbasierte Ansätze als wiederkehrende Techniken innerhalb adaptiver Lernsysteme (Wang u. a. 2025). Die Bandbreite dieser Verfahren verdeutlicht, dass adaptive Systeme unterschiedliche Arten von Wissen und Daten verarbeiten müssen und daher häufig mehrere Modellierungsansätze miteinander kombinieren.

Besonders interessant ist dabei die Entwicklung der verwendeten Verfahren über die Zeit. Wang et al. beschreiben einen Wandel von einer früher vergleichsweise starken Dominanz von Fuzzy-Logic-Verfahren hin zu einer deutlich vielfältigeren Methodenlandschaft, in der probabilistische Modelle, Machine-Learning-Verfahren, neuronale Netze und regelbasierte Ansätze parallel eingesetzt werden (Wang u. a. 2025). Adaptive Lernsysteme entwickeln sich damit zunehmend zu hybriden Architekturen, in denen unterschiedliche Verfahren jeweils spezifische Teilaufgaben übernehmen.

Für eine informatische Klassifikation adaptiver Lernverfahren ergibt sich daraus eine wichtige Konsequenz: Die einzelnen Verfahrensfamilien treten in realen Systemen häufig nicht isoliert auf. Ein adaptives System kann beispielsweise probabilistische Wissensmodelle zur Lernstandsdiagnostik, Recommender-Verfahren zur Inhaltsauswahl sowie Optimierungsverfahren zur Lernpfadplanung gleichzeitig verwenden. Die algorithmische Landschaft adaptiver Lernsysteme ist daher nicht nur vielfältig, sondern auch stark durch die Kombination unterschiedlicher Modellierungs- und Entscheidungsverfahren geprägt (Wang u. a. 2025).

Neben den verwendeten Modellierungs- und Entscheidungsverfahren unterscheiden sich adaptive Lernsysteme auch hinsichtlich der Datenarten, die sie verarbeiten. Die Literatur zeigt, dass unterschiedliche Verfahrensfamilien auf sehr verschiedenen Informationsquellen basieren und dadurch jeweils andere Aspekte des Lernprozesses erfassen (Wang u. a. 2025; Shen u. a. 2024; Silva u. a. 2023).

Im Bereich des Knowledge Tracing bilden insbesondere Aufgabenfolgen, Antwortmuster und Bearbeitungshistorien die Grundlage der Wissensmodellierung. Erweiterte Modelle berücksichtigen darüber hinaus zusätzliche Informationen wie Antwortzeiten, Vergessenseffekte, Lernverhalten oder Tutorinterventionen als sogenannte Side Information (Shen u. a. 2024). Ziel ist es, den Wissenszustand eines Lernenden möglichst präzise aus einer Folge beobachtbarer Interaktionen abzuleiten.

Computerized-Adaptive-Testing-Systeme arbeiten ebenfalls mit Antwortdaten, konzentrieren sich jedoch stärker auf die kontinuierliche Schätzung von Fähigkeitswerten innerhalb einer Testsituation. Relevant sind dabei insbesondere Antwortmuster, Itemeigenschaften, Aufgabenschwierigkeiten sowie Informationen zur Teststeuerung und Itemauswahl (Han 2018; Liu u. a. 2024).

Recommender-Systeme greifen dagegen häufig auf deutlich breitere Datenquellen zurück. Dazu zählen Interessenprofile, Lernhistorien, Leistungsdaten, Präferenzen, Kompetenzinformationen sowie Eigenschaften von Lernressourcen. Kollaborative Verfahren nutzen zusätzlich Interaktionsdaten anderer Lernender, während wissens- und ontologiebasierte Ansätze stärker auf explizite Domänenmodelle und strukturierte Wissensrepräsentationen zurückgreifen (Silva u. a. 2023; George und Lal 2019).

Auch Machine-Learning-basierte adaptive Lernsysteme verarbeiten häufig vielfältige Verhaltens- und Kontextdaten. Wang et al. nennen unter anderem Lernleistungen, Lernverhalten, demographische Merkmale, Lernstile sowie Interaktionsdaten als typische Informationsquellen innerhalb von Learner Models. In cluster- und verhaltensbasierten Verfahren spielen zusätzlich

Klickpfade, Bearbeitungszeiten oder Nutzungsmuster digitaler Lernumgebungen eine wichtige Rolle (Wang u. a. 2025).

Für eine informatische Klassifikation adaptiver Lernverfahren ergibt sich daraus, dass Verfahren nicht ausschließlich anhand ihrer Algorithmen beschrieben werden können. Unterschiedliche Modellierungsansätze basieren auf unterschiedlichen Datenrepräsentationen und Informationsquellen. Eine systematische Einordnung adaptiver Lernverfahren sollte daher neben den verwendeten Algorithmen auch die zugrunde liegende Datenbasis berücksichtigen, da diese wesentlich beeinflusst, welche Formen von Adaptivität überhaupt realisiert werden können.

2.5 Zwischenfazit und Anforderungen an eine eigene Klassifikation

Die Analyse des Forschungsstands zeigt, dass adaptive Lernsysteme in der Literatur aus sehr unterschiedlichen Perspektiven beschrieben und klassifiziert werden. Während einige Arbeiten Adaptivität primär über Lernendenmerkmale, pädagogische Zielgrößen oder Formen der Personalisierung strukturieren, fokussieren andere stärker Systemarchitekturen, Learner Models, Anwendungskontexte oder konkrete algorithmische Verfahren. Darüber hinaus werden spezialisierte Forschungsfelder wie Knowledge Tracing, Educational Recommender Systems, Computerized Adaptive Testing oder Reinforcement-Learning-basierte Lernsysteme häufig weitgehend unabhängig voneinander betrachtet, obwohl sich zahlreiche algorithmische Grundprinzipien zwischen diesen Bereichen überschneiden.

Die Analyse macht zugleich deutlich, dass bestehende Systematisierungen häufig unterschiedliche Beschreibungsebenen vermischen. Teilweise stehen funktionale Rollen adaptiver Verfahren im Vordergrund, etwa Wissensdiagnostik, Empfehlung oder Sequenzierung. Andere Arbeiten klassifizieren nach Modellierungsverfahren, Datenquellen, Plattfortmtypen oder pädagogischen Zielgrößen. Eine informatisch orientierte Klassifikation adaptiver Lernverfahren sollte diese unterschiedlichen Ebenen zunächst analytisch voneinander trennen, bevor sie systematisch zusammengeführt werden. Erst dadurch lässt sich nachvollziehen, welche Verfahren ähnliche Probleme lösen, welche Daten sie verarbeiten und welche Modellierungslogiken ihren Entscheidungen zugrunde liegen.

Aus der Analyse der unterschiedlichen Verfahrensfamilien ergeben sich mehrere Anforderungen an eine informatisch orientierte Klassifikation adaptiver Lernverfahren. Die untersuchten Verfahren treten in unterschiedlichen Forschungskontexten wie Knowledge Tracing, Educational Recommender Systems, Computerized Adaptive Testing oder Reinforcement-Learning-basierten Lernumgebungen auf, verwenden jedoch teilweise ähnliche Modellierungs- und Entscheidungsprinzipien. Eine Klassifikation sollte daher nicht ausschließlich an Anwendungskontexten ansetzen, sondern gemeinsame algorithmische Grundideen sichtbar machen. Gleichzeitig hat die Analyse gezeigt, dass adaptive Verfahren innerhalb eines Systems unterschiedliche funktionale Rollen übernehmen können, etwa bei der Wissensdiagnostik, der Empfehlung von Lernressourcen, der Planung von Lernpfaden oder der Optimierung adaptiver Entscheidungen.

Darüber hinaus unterscheiden sich die Verfahren erheblich hinsichtlich ihrer Datenquellen, Modellierungsansätze sowie ihrer Transparenz und Interpretierbarkeit. Eine tragfähige Klassifikation sollte diese unterschiedlichen Beschreibungsebenen systematisch berücksichtigen.

Zusätzlich macht die Literatur auf mehrere Defizite bestehender Forschungsansätze aufmerksam. Im Bereich des Learner Modelings wird wiederholt auf fehlende Standardisierung und uneinheitliche Beschreibungen von Lernendenmodellen hingewiesen (Böck 2025). Educational-Recommend-Systeme werden häufig anhand technischer Qualitätsmaße wie Genauigkeit oder Präzision bewertet, während ihre tatsächliche pädagogische Wirksamkeit deutlich seltener untersucht wird (Silva u. a. 2023). Für Reinforcement-Learning-basierte Lernsysteme verweist die Literatur zudem auf methodische und empirische Einschränkungen, da viele Arbeiten weiterhin auf simulierten Szenarien beruhen und groß angelegte Evaluationen mit realen Lernenden bislang vergleichsweise selten sind (Riedmann u. a. 2025). Diese Befunde verdeutlichen die weiterhin starke Fragmentierung der Forschung zu adaptiven Lernverfahren. Eine eigene Klassifikation sollte daher einen gemeinsamen Ordnungsrahmen schaffen, der Verfahren auch über die Grenzen einzelner Forschungsfelder hinweg vergleichbar macht.

Für den weiteren Aufbau der Arbeit bedeutet dies, dass Kapitel 2 zunächst die zentralen Perspektiven, Verfahrensfamilien und Modellierungsansätze adaptiver Lernsysteme systematisch herausarbeitet und zugleich die Grenzen bestehender Systematisierungen sichtbar macht. Die Analyse hat gezeigt, dass weder anwendungsbezogene Einteilungen noch rein algorithmische oder pädagogische Klassifikationen die Vielfalt adaptiver Lernverfahren vollständig erfassen können. Insbesondere die Überschneidungen zwischen unterschiedlichen Forschungsfeldern, die Heterogenität der Datenquellen sowie die Kombination mehrerer Verfahren innerhalb realer Systeme erschweren eine eindeutige Einordnung bestehender Ansätze.

Kapitel 3 sollte daher auf dieser Grundlage eine eigenständige Klassifikation entwickeln, die adaptive Lernverfahren nicht ausschließlich über Anwendungskontexte oder einzelne Technologien beschreibt, sondern als informatische Modellierungs-, Diagnose-, Entscheidungs- und Optimierungsverfahren systematisch einordnet. Der Mehrwert einer solchen Klassifikation liegt insbesondere darin, unterschiedliche Verfahrensfamilien über gemeinsame Strukturmerkmale vergleichbar zu machen und dadurch einen übergreifenden Ordnungsrahmen für adaptive Lernsysteme bereitzustellen.

2.6 Offene Punkte und Grenzen

Die verfügbare Überblicksliteratur zu adaptiven Lernsystemen ist umfangreich, zugleich jedoch stark fragmentiert. Allgemeine Reviews fokussieren häufig pädagogische Konzepte, Formen der Personalisierung oder Systemarchitekturen, während detaillierte Analysen algorithmischer Verfahren überwiegend in spezialisierten Forschungsfeldern wie Knowledge Tracing, Educational Recommender Systems, Computerized Adaptive Testing oder Reinforcement Learning zu finden

sind. Eine übergreifende Betrachtung adaptiver Lernverfahren erfordert daher die Zusammenführung von Erkenntnissen aus mehreren Teilgebieten, die unterschiedliche Begrifflichkeiten, Modellierungsansätze und Bewertungskriterien verwenden.

Darüber hinaus zeigt sich, dass die Evidenzlage häufig stärker auf die Beschreibung einzelner Verfahren oder Forschungsfelder ausgerichtet ist als auf deren systematischen Vergleich. Zwar liegen zahlreiche Untersuchungen zu Lernwirkungen, Vorhersageleistungen oder technischen Eigenschaften einzelner Ansätze vor, jedoch existieren nur begrenzte Erkenntnisse darüber, unter welchen Bedingungen bestimmte Verfahrensfamilien gegenüber anderen vorzuziehen sind. Insbesondere hybride Systeme, die mehrere Modellierungs- und Entscheidungsverfahren kombinieren, erschweren eine eindeutige Zuordnung zu bestehenden Kategorien.

Die im Rahmen dieses Kapitels entwickelte Analyse kann daher keinen Anspruch auf eine vollständige oder abschließende Bewertung aller adaptiven Lernverfahren erheben. Sie schafft jedoch eine fundierte Grundlage, um in den folgenden Kapiteln eine eigenständige informatisch orientierte Klassifikation zu entwickeln, die die identifizierten Perspektiven, Verfahrensfamilien und Beschreibungsebenen systematisch zusammenführt.

3 Eigene Klassifikation adaptiver Lernverfahren

Aufbauend auf den in Kapitel 2 identifizierten Anforderungen wird im Folgenden eine eigenständige Klassifikation adaptiver Lernverfahren entwickelt. Ziel ist nicht die Einordnung nach Anwendungskontexten oder Plattformtypen, sondern die systematische Beschreibung der Verfahren anhand ihrer funktionalen Rolle innerhalb adaptiver Systeme sowie weiterer ergänzender Merkmale. Die Klassifikation soll Verfahren unterschiedlicher Forschungsfelder vergleichbar machen und gleichzeitig die Einordnung konkreter Algorithmen ermöglichen.

3.1 Wahl der Klassifikationsstruktur

Die in Kapitel 2 analysierte Literatur macht deutlich, dass adaptive Lernverfahren durch eine hohe methodische Vielfalt gekennzeichnet sind. Neben probabilistischen, logistischen und tiefen Lernmodellen existieren Recommender-Systeme, Lernpfadverfahren, psychometrische Ansätze und Reinforcement-Learning-Verfahren, die teilweise unterschiedliche Aufgaben innerhalb adaptiver Systeme übernehmen, teilweise jedoch auch ähnliche Probleme mit unterschiedlichen Modellierungsansätzen lösen. Gleichzeitig treten viele Verfahren in mehreren Forschungskontexten auf und werden in realen Systemen häufig miteinander kombiniert. Die Entwicklung einer eigenen Klassifikation erfordert daher zunächst die Frage, welche Strukturform für eine systematische Einordnung dieser Verfahren geeignet ist.

Eine rein hierarchische Taxonomie bietet den Vorteil einer klaren und intuitiven Struktur. Verfahren können schrittweise in Ober- und Unterkategorien eingeordnet werden, wodurch sich eine übersichtliche Gliederung ergibt. Für adaptive Lernverfahren erweist sich ein solcher Ansatz jedoch als nur eingeschränkt geeignet. Viele Verfahren lassen sich nicht eindeutig einer einzelnen Kategorie zuordnen, da hybride Systeme mehrere Modellierungs- und Entscheidungsverfahren kombinieren. Zudem treten identische Verfahren teilweise in unterschiedlichen Anwendungskontexten auf. Eine ausschließlich hierarchische Struktur würde daher entweder Mehrfachzuordnungen erzwingen oder relevante Unterschiede zwischen Verfahren verdecken.

Demgegenüber ermöglicht eine rein facettierte Taxonomie die unabhängige Beschreibung verschiedener Eigenschaften eines Verfahrens. Datenbasis, Modellierungsansatz, Entscheidungsmechanismus oder Interpretierbarkeit könnten getrennt voneinander betrachtet werden. Dieser Ansatz bietet eine hohe analytische Flexibilität und eignet sich insbesondere für den Vergleich heterogener Verfahren. Für die Zielsetzung dieser Arbeit besitzt eine ausschließlich facettierte Struktur jedoch den Nachteil, dass sie keinen intuitiven primären Ordnungsrahmen

bereitstellt. Verfahren würden lediglich als Kombination verschiedener Merkmale erscheinen, ohne dass ihre funktionale Rolle innerhalb adaptiver Systeme unmittelbar sichtbar wird.

Für die vorliegende Arbeit erscheint daher eine hierarchisch verankerte facettierte Mehrdimensionaltaxonomie am geeignetsten. Sie kombiniert die Vorteile beider Ansätze: Einerseits werden Verfahren zunächst anhand ihrer funktionalen Rolle innerhalb des adaptiven Prozesses eingeordnet. Andererseits ermöglichen zusätzliche Beschreibungsdimensionen eine differenzierte Charakterisierung der Verfahren. Auf diese Weise lassen sich sowohl konkrete Algorithmen als auch hybride Systeme systematisch erfassen, ohne die Übersichtlichkeit der Klassifikation zu verlieren.

3.1.1 Herleitung der Hauptdimensionen

Die Analyse der in Kapitel 2 betrachteten Verfahrensfamilien zeigt, dass adaptive Lernsysteme trotz ihrer methodischen Vielfalt zwei grundlegende Aufgaben erfüllen müssen. Zum einen benötigen sie Mechanismen zur Erfassung und Modellierung des aktuellen Lernzustands. Zum anderen müssen sie auf Grundlage dieser Informationen Entscheidungen über Inhalte, Aufgaben, Interventionen oder Lernpfade treffen. Unabhängig davon, ob ein System probabilistische Modelle, Recommender-Verfahren, psychometrische Ansätze oder Reinforcement Learning verwendet, lassen sich die zugrunde liegenden Verfahren letztlich einer dieser beiden Aufgaben zuordnen.

Verfahren wie Bayesian Knowledge Tracing, Performance Factors Analysis, Item-Response-Theory-Modelle oder Deep Knowledge Tracing dienen primär der Schätzung von Wissen, Fähigkeiten oder zukünftigen Leistungen. Ihr Ziel besteht darin, einen internen Zustand des Lernenden möglichst präzise zu modellieren. Recommender-Systeme, Lernpfadverfahren, Computerized Adaptive Testing oder Reinforcement-Learning-Verfahren treffen demgegenüber Entscheidungen darüber, welche Inhalte, Aufgaben oder Interventionen als Nächstes ausgewählt werden sollen. Sie greifen dabei häufig auf Informationen zurück, die zuvor durch Verfahren der Zustandsmodellierung bereitgestellt wurden.

Aus dieser Beobachtung ergibt sich die funktionale Rolle eines Verfahrens als geeignete primäre Klassifikationsdimension. Die vorgeschlagene Taxonomie unterscheidet daher zunächst zwischen Verfahren der Zustandsmodellierung und Verfahren der Adaptionentscheidung.

3.2 Die vorgeschlagene Klassifikation

3.2.1 Zustandsmodellierung

Die erste Hauptklasse der vorgeschlagenen Klassifikation umfasst Verfahren zur Zustandsmodellierung des Lernenden. Gemeinsam ist diesen Verfahren, dass ihre unmittelbare Ausgabe nicht in einer konkreten adaptiven Entscheidung besteht, sondern in der Schätzung eines

internen Zustands des Lernenden. Ziel ist es, Wissen, Fähigkeiten, Kompetenzen, Präferenzen oder zukünftige Leistungen auf Grundlage beobachtbarer Interaktionen möglichst präzise zu modellieren. Die erzeugten Zustandsinformationen dienen anschließend häufig als Grundlage für weitere adaptive Entscheidungen, etwa bei der Auswahl von Lernressourcen, der Generierung von Lernpfaden oder der Steuerung adaptiver Tests.

Die Analyse der in Kapitel 2 betrachteten Forschungsfelder zeigt, dass Verfahren der Zustandsmodellierung in nahezu allen Bereichen adaptiver Lernsysteme eine zentrale Rolle einnehmen. Im Knowledge Tracing steht die Schätzung des Beherrschungsgrads einzelner Wissenskomponenten im Vordergrund. Im Computerized Adaptive Testing werden Fähigkeiten über psychometrische Modelle geschätzt, während Recommender-Systeme und Lernpfadverfahren häufig Informationen über Wissen, Präferenzen oder Lernfortschritte als Eingabe für spätere Entscheidungen nutzen. Trotz unterschiedlicher Anwendungskontexte verfolgen diese Verfahren somit dieselbe grundlegende Funktion: die Modellierung eines internen Zustands des Lernenden auf Basis beobachtbarer Daten.

Aus der Literatur lassen sich innerhalb dieser Hauptklasse fünf zentrale Untergruppen ableiten. Diese unterscheiden sich primär hinsichtlich ihrer Modellierungslogik, ihrer Annahmen über den Lernprozess sowie der Art und Weise, wie Zustandsinformationen aus den verfügbaren Daten gewonnen werden. Die vorgeschlagene Klassifikation unterscheidet daher zwischen psychometrischen Fähigkeitsmodellen, probabilistisch-temporalen Wissensmodellen, logistischen und online aktualisierten Performanzmodellen, merkmalsbasierten Machine-Learning-Modellen sowie tiefen sequenziellen und repräsentationslernenden Modellen.

3.2.1.1 Psychometrische Fähigkeitsmodelle

Psychometrische Fähigkeitsmodelle bilden die erste Unterklasse der Zustandsmodellierung. Ihr gemeinsames Ziel besteht darin, latente Fähigkeiten oder Kompetenzen eines Lernenden auf Grundlage beobachtbarer Antwortmuster zu schätzen. Im Gegensatz zu vielen später entwickelten Lernmodellen steht dabei weniger die Modellierung eines zeitlichen Lernverlaufs als vielmehr die möglichst präzise Messung eines aktuellen Fähigkeitsniveaus im Vordergrund (Han 2018; Liu u. a. 2024).

Zu den wichtigsten Vertretern dieser Modellfamilie zählen das Rasch-Modell sowie die verschiedenen Modelle der Item Response Theory (IRT). Diese Verfahren beschreiben die Wahrscheinlichkeit einer korrekten Antwort als Funktion von Personen- und Itemparametern und ermöglichen dadurch die Schätzung latenter Fähigkeiten aus Testdaten. In adaptiven Testsystemen dienen sie häufig als Grundlage für die Auswahl informativer Aufgaben und die fortlaufende Aktualisierung von Fähigkeitswerten (Han 2018; Liu u. a. 2024).

Innerhalb der vorgeschlagenen Klassifikation werden psychometrische Modelle als eigenständige Unterklasse geführt, da ihr primärer Fokus auf der diagnostischen Fähigkeitsmessung liegt. Während spätere Knowledge-Tracing-Modelle Lernprozesse über mehrere Interaktionen hinweg modellieren, konzentrieren sich psychometrische Verfahren auf die möglichst zuverlässige

Schätzung eines latenten Zustands zu einem gegebenen Zeitpunkt (Shen u. a. 2024; Han 2018). Typische Vertreter dieser Unterklasse sind das Rasch-Modell sowie die 2PL- und 3PL-Varianten der Item Response Theory.

3.2.1.2 Probabilistisch-temporale Wissensmodelle

Probabilistisch-temporale Wissensmodelle bilden die zweite Unterklasse der Zustandsmodellierung. Ihr gemeinsames Merkmal besteht darin, dass sie Wissen nicht als statischen Zustand, sondern als dynamischen Lernprozess modellieren. Ziel dieser Verfahren ist die Schätzung der Wahrscheinlichkeit, mit der ein Lernender eine bestimmte Wissenskomponente beherrscht, wobei diese Schätzung nach jeder neuen Lerninteraktion aktualisiert wird (Shen u. a. 2024; Abdelrahman u. a. 2023).

Charakteristisch für diese Modellfamilie ist die explizite Modellierung von Wissensentwicklung über die Zeit. Viele Verfahren dieser Klasse basieren auf probabilistischen Zustandsmodellen, insbesondere Hidden-Markov-Modellen oder Bayes-Netz-artigen Strukturen. Wissen wird dabei als latenter, nicht direkt beobachtbarer Zustand aufgefasst, der anhand beobachtbarer Antworten oder Interaktionen inferiert wird (Shen u. a. 2024).

Der wichtigste Vertreter dieser Unterklasse ist Bayesian Knowledge Tracing (BKT). Das von Corbett und Anderson entwickelte Verfahren modelliert Lernen als Folge von Zustandsübergängen und berücksichtigt dabei insbesondere Anfangswissen, Lernwahrscheinlichkeit sowie die Möglichkeiten von Guessing, also die Wahrscheinlichkeit, dass eine Aufgabe trotz fehlender Beherrschung korrekt beantwortet wird, und Slipping, der umgekehrte Fall einer falschen Antwort trotz vorhandenen Wissens. Aufbauend auf dem klassischen BKT wurden zahlreiche Erweiterungen entwickelt, die beispielsweise individuelle Lernendenparameter, Itemschwierigkeiten oder komplexere Abhängigkeitsstrukturen berücksichtigen (Shen u. a. 2024; Abdelrahman u. a. 2023).

Innerhalb der vorgeschlagenen Klassifikation werden probabilistisch-temporale Wissensmodelle als eigenständige Unterklasse geführt, da sie im Unterschied zu psychometrischen Fähigkeitsmodellen nicht primär die Messung eines aktuellen Fähigkeitsniveaus verfolgen, sondern die zeitliche Entwicklung von Wissen modellieren. Typische Vertreter dieser Modellfamilie sind Bayesian Knowledge Tracing (BKT) sowie Dynamic Bayesian Knowledge Tracing (DBKT) (Shen u. a. 2024; Abdelrahman u. a. 2023).

3.2.1.3 Logistische und online aktualisierte Performanzmodelle

Logistische und online aktualisierte Performanzmodelle bilden die dritte Unterklasse der Zustandsmodellierung. Im Mittelpunkt dieser Verfahren steht nicht die explizite Modellierung eines verborgenen Wissenszustands, sondern die Vorhersage zukünftiger Leistungen auf Grundlage beobachtbarer Lernhistorien. Ziel ist es, die Wahrscheinlichkeit einer korrekten Antwort aus

bisherigen Erfolgen, Fehlern und Übungserfahrungen abzuleiten (Pelánek 2017; Shen u. a. 2024).

Charakteristisch für diese Modellfamilie ist die Verwendung statistischer oder online aktualisierter Modelle zur Performanzschätzung. Im Gegensatz zu probabilistischen Wissensmodellen wird Wissen dabei häufig nicht als latenter Zustand modelliert, sondern indirekt über beobachtbare Leistungsindikatoren beschrieben. Viele Verfahren dieser Klasse nutzen logistische Regressionen, um den Einfluss früherer Interaktionen auf zukünftige Antworten zu schätzen (Pelánek 2017; Shen u. a. 2024).

Zu den wichtigsten Vertretern dieser Unterklasse zählen Learning Factors Analysis (LFA) und Performance Factors Analysis (PFA). Beide Verfahren modellieren die Wahrscheinlichkeit korrekter Antworten auf Basis der bisherigen Bearbeitungshistorie eines Lernenden. Während LFA insbesondere die Anzahl früherer Übungsgelegenheiten berücksichtigt, unterscheidet PFA zusätzlich zwischen erfolgreichen und fehlerhaften Bearbeitungen und kann dadurch Lernfortschritte differenzierter abbilden (Pelánek 2017; Shen u. a. 2024).

Ebenfalls dieser Unterklasse zuzuordnen sind Elo-basierte Verfahren. Diese interpretieren die Interaktion zwischen Lernendem und Aufgabe als eine Art Wettbewerb, bei dem sowohl die Fähigkeit des Lernenden als auch die Schwierigkeit der Aufgabe nach jeder Bearbeitung fortlaufend aktualisiert werden. Dadurch eignen sich Elo-Verfahren insbesondere für adaptive Systeme, die schnelle Online-Aktualisierungen bei vergleichsweise geringem Modellierungsaufwand benötigen (Pelánek 2017; Shen u. a. 2024).

Innerhalb der vorgeschlagenen Klassifikation werden logistische und online aktualisierte Performanzmodelle als eigenständige Unterklasse geführt, da sie im Unterschied zu probabilistischen Wissensmodellen keine explizite Repräsentation eines verborgenen Wissenszustands anstreben, sondern unmittelbar aus beobachtbaren Leistungsdaten auf zukünftige Performanz schließen. Typische Vertreter dieser Modellfamilie sind LFA, PFA, PFAE sowie Elo-basierte Verfahren (Pelánek 2017; Shen u. a. 2024).

3.2.1.4 Merkmalsbasierte Machine-Learning-Modelle

Merkmalsbasierte Machine-Learning-Modelle bilden die vierte Unterklasse der Zustandsmodellierung. Im Unterschied zu den zuvor beschriebenen Modellfamilien beruhen diese Verfahren nicht auf spezifischen Annahmen über Wissenszustände, Lernprozesse oder Fähigkeitsmodelle. Stattdessen nutzen sie allgemeine Methoden des Machine Learning, um aus beobachtbaren Merkmalen Muster zu erkennen und Eigenschaften von Lernenden vorherzusagen (Wang u. a. 2025; Orji und Vassileva 2022).

Die Eingabedaten dieser Verfahren können sehr unterschiedlich ausfallen. Neben Antwortmustern und Leistungsdaten werden häufig Interaktionsdaten, Nutzungsverhalten, demographische Merkmale oder weitere Informationen über Lernende berücksichtigt. Ziel ist dabei nicht ausschließlich die Schätzung von Wissen oder Fähigkeiten, sondern auch die Vorhersage weiterer

Lernendenmerkmale wie Motivation, Engagement, Lernstilen, Persönlichkeitsmerkmalen oder affektiven Zuständen (Orji und Vassileva 2022).

Zu den typischen Vertretern dieser Unterklasse zählen Entscheidungsbäume, Random Forests, k-Nearest-Neighbor-Verfahren (kNN), Support Vector Machines (SVM), Clustering-Verfahren sowie verschiedene Fuzzy-Logic-Ansätze. Darüber hinaus werden in der Literatur auch Bayesian Networks und faktorenanalytische Verfahren zur Modellierung von Lernendenmerkmalen beschrieben (Wang u. a. 2025; Orji und Vassileva 2022).

Innerhalb der vorgeschlagenen Klassifikation werden diese Verfahren als eigenständige Unterklasse geführt, da sie nicht auf speziell entwickelten Wissens- oder Fähigkeitsmodellen beruhen, sondern allgemeine datengetriebene Lernverfahren zur Vorhersage von Lernendenmerkmalen einsetzen. Im Unterschied zu tiefen neuronalen Verfahren arbeiten merkmalsbasierte Machine-Learning-Modelle typischerweise mit explizit definierten Eingabemerkmalen, die aus den verfügbaren Lern- und Interaktionsdaten abgeleitet werden. Die relevanten Eigenschaften der Lernenden werden dabei nicht automatisch gelernt, sondern dem Modell in Form von Features bereitgestellt. Sie stellen damit eine flexiblere, aber häufig auch weniger domänenspezifische Alternative zu psychometrischen, probabilistischen oder logistischen Modellen dar.

3.2.1.5 Tiefe sequenzielle und repräsentationslernende Modelle

Die fünfte Unterklasse der Zustandsmodellierung umfasst tiefe sequenzielle und repräsentationslernende Modelle. Im Unterschied zu psychometrischen, probabilistischen oder logistischen Ansätzen beruhen diese Verfahren nicht auf explizit definierten Wissenszuständen oder fest vorgegebenen Lernparametern. Stattdessen lernen sie latente Repräsentationen direkt aus den Interaktionsdaten von Lernenden und nutzen diese zur Vorhersage zukünftiger Leistungen oder Wissenszustände (Shen u. a. 2024).

Besonders verbreitet sind diese Verfahren im Bereich des Knowledge Tracing. Zu den bekanntesten Vertretern zählen Deep Knowledge Tracing (DKT), speicherbasierte Modelle sowie aufmerksamkeitsbasierte und transformerbasierte Knowledge-Tracing-Verfahren (Shen u. a. 2024). Gemeinsam ist diesen Ansätzen, dass sie Interaktionssequenzen als zeitliche Datenfolgen behandeln und komplexe Abhängigkeiten zwischen früheren und späteren Lernaktivitäten modellieren können.

Charakteristisch für diese Modellfamilie ist die automatische Bildung latenter Repräsentationen. Anstatt Wissen explizit über Parameter oder Wahrscheinlichkeitsmodelle zu beschreiben, lernen die Modelle interne Zustandsrepräsentationen, die zur Vorhersage zukünftiger Antworten genutzt werden. Dadurch können auch komplexe und nichtlineare Zusammenhänge erfasst werden, die in klassischen Modellen häufig nicht abgebildet werden (Shen u. a. 2024).

Die hohe Vorhersageleistung dieser Verfahren geht jedoch häufig mit einer geringeren Interpretierbarkeit einher. Während psychometrische oder probabilistische Modelle ihre Annahmen explizit offenlegen, bleiben die internen Repräsentationen tiefer neuronaler Modelle oftmals

schwer nachvollziehbar. Die Literatur diskutiert deshalb regelmäßig den Zielkonflikt zwischen Vorhersagegüte und Erklärbarkeit tiefer Knowledge-Tracing-Modelle (Shen u. a. 2024).

Innerhalb der vorgeschlagenen Klassifikation werden tiefe sequenzielle und repräsentation-lernende Modelle als eigenständige Unterklasse geführt, da sie Wissen nicht über explizite Fähigkeits- oder Wissensparameter beschreiben, sondern latente Zustände datengetrieben aus großen Interaktionssequenzen erlernen. Typische Vertreter dieser Kategorie sind DKT sowie weitere neuronale Sequenz- und Transformer-Modelle (Shen u. a. 2024).

3.2.2 Adaptionentscheidung

Die zweite Hauptklasse der vorgeschlagenen Klassifikation umfasst Verfahren der Adaptionentscheidung. Im Unterschied zu den Verfahren der Zustandsmodellierung besteht ihre unmittelbare Aufgabe nicht in der Schätzung eines internen Zustands des Lernenden, sondern in der Auswahl, Steuerung oder Planung einer konkreten Systemaktion. Grundlage dieser Entscheidungen sind häufig die durch Learner Models, Knowledge-Tracing-Verfahren oder andere Zustandsmodelle bereitgestellten Informationen. Das Ergebnis dieser Verfahren ist somit nicht eine Diagnose des Lernenden, sondern eine Entscheidung darüber, wie das adaptive System auf den aktuellen Zustand reagieren soll.

Verfahren der Adaptionentscheidung finden sich in nahezu allen Bereichen adaptiver Lernsysteme. Computerized-Adaptive-Testing-Systeme wählen auf Basis der aktuellen Fähigkeitsschätzung die nächste Aufgabe aus. Recommender-Systeme empfehlen Lernressourcen oder Aufgaben, die zum Lernenden passen. Lernpfadverfahren planen ganze Sequenzen von Lernaktivitäten, während Reinforcement-Learning-Verfahren langfristige Strategien zur Optimierung des Lernerfolgs entwickeln. Trotz unterschiedlicher Anwendungskontexte verfolgen diese Ansätze damit dieselbe grundlegende Funktion: die Auswahl einer geeigneten Folgeaktion auf Grundlage verfügbarer Informationen über den Lernenden und die Lernumgebung.

Die in Kapitel 2 analysierte Literatur zeigt zugleich, dass sich adaptive Entscheidungen auf sehr unterschiedliche Weise realisieren lassen. Einige Verfahren beruhen auf explizit definierten Regeln oder Expertenwissen, andere nutzen informationsbasierte Auswahlkriterien, Empfehlungssysteme oder Optimierungsverfahren. Darüber hinaus unterscheiden sich die Verfahren hinsichtlich ihres Planungshorizonts. Während manche Ansätze lediglich die nächste Aufgabe oder Ressource auswählen, planen andere vollständige Lernpfade oder optimieren langfristige Entscheidungsstrategien über viele Interaktionen hinweg.

Aus der Literatur lassen sich innerhalb dieser Hauptklasse fünf zentrale Untergruppen ableiten. Diese unterscheiden sich primär hinsichtlich ihres Entscheidungsmechanismus sowie der Art der erzeugten Adaptionentscheidung. Die vorgeschlagene Klassifikation unterscheidet daher zwischen regel- und wissensbasierten Adaptionsverfahren, informationsmaximierenden Selektionsverfahren, Verfahren der Ressourcenempfehlung und Aufgabenwahl, Verfahren zur Lernpfadgenerierung und Sequenzplanung sowie Verfahren der sequentiellen Optimierung unter Unsicherheit.

3.2.2.1 Regel- und wissenbasierte Adaptionungsverfahren

Regel- und wissenbasierte Adaptionungsverfahren bilden die erste Unterklasse der Adaptionentscheidung. Gemeinsam ist diesen Verfahren, dass adaptive Entscheidungen nicht durch statistische Optimierung oder datengetriebene Lernverfahren erzeugt werden, sondern auf explizit formulierten Regeln oder Wissensstrukturen beruhen. Die Adaptionslogik wird dabei durch Expertinnen und Experten vorgegeben und vom System zur Auswahl geeigneter Aktionen angewendet.

Typischerweise kommen If-Then-Regeln beziehungsweise Condition-Action-Regeln zum Einsatz. Auf Grundlage beobachteter Merkmale eines Lernenden werden dabei bestimmte Inhalte, Navigationsmöglichkeiten oder Unterstützungsmaßnahmen aktiviert. Ein einfaches Beispiel wäre die Regel, einem Lernenden bei wiederholten Fehlern zusätzliche Erklärungen oder Übungsaufgaben bereitzustellen. Darüber hinaus können auch symbolische Wissensrepräsentationen und regelbasierte Inferenzmechanismen zur Ableitung adaptiver Entscheidungen genutzt werden (Wang u. a. 2025).

Ein wesentlicher Vorteil dieser Verfahren liegt in ihrer hohen Transparenz und Nachvollziehbarkeit. Da die Entscheidungsregeln explizit definiert sind, lässt sich die Ursache einer bestimmten Adaptionentscheidung unmittelbar nachvollziehen. Gleichzeitig sind regelbasierte Verfahren häufig stark von Expertenwissen abhängig und können neue oder unerwartete Situationen nur eingeschränkt berücksichtigen. Im Vergleich zu datengetriebenen Verfahren besitzen sie daher oftmals eine geringere Flexibilität und Anpassungsfähigkeit.

Innerhalb der vorgeschlagenen Klassifikation werden regel- und wissenbasierte Verfahren als eigenständige Unterklasse geführt, da die Adaptionslogik hier nicht gelernt oder optimiert wird, sondern explizit modelliert ist. Typische Vertreter dieser Kategorie sind regelbasierte Tutorensysteme, Expertensysteme sowie Condition-Action-basierte Adaptionsmechanismen.

3.2.2.2 Informationsmaximierende Selektionsverfahren

Informationsmaximierende Selektionsverfahren bilden die zweite Unterklasse der Adaptionentscheidung. Im Mittelpunkt dieser Verfahren steht die Auswahl derjenigen Aufgabe oder Testfrage, die auf Grundlage des aktuell geschätzten Lernendenzustands den größten diagnostischen Informationsgewinn verspricht. Im Unterschied zu Verfahren der Zustandsmodellierung besteht ihre unmittelbare Ausgabe somit nicht in einer Fähigkeitsschätzung, sondern in der Entscheidung, welches Item als Nächstes präsentiert werden soll.

Besonders verbreitet sind diese Verfahren im Bereich des Computerized Adaptive Testing (CAT). Dort wird die aktuelle Fähigkeitsschätzung eines Lernenden fortlaufend genutzt, um die nächste Aufgabe adaptiv auszuwählen. Ziel dieser Verfahren ist es, auf Basis der aktuellen Fähigkeitsschätzung jene Aufgabe auszuwählen, die den größten zusätzlichen Informationsgewinn für die weitere Schätzung des Fähigkeitsniveaus liefert. Die Aufgabenauswahl erfolgt dabei typischerweise anhand informationsbasierter Auswahlkriterien, die bestimmen, welche

Aufgabe unter den verfügbaren Kandidaten den größten zusätzlichen Erkenntnisgewinn liefert (Liu u. a. 2024).

Zu den wichtigsten Verfahren dieser Unterklasse zählen informationsmaximierende Item-Selection-Kriterien wie die Maximum-Fisher-Information-Auswahl oder Kullback-Leibler-basierte Selektionsverfahren. Darüber hinaus spielen Verfahren des Content Balancing sowie Mechanismen zur Kontrolle der Itemexposition eine wichtige Rolle, um in realen Testsystemen sowohl diagnostische Qualität als auch faire Nutzung der Aufgabenbanken sicherzustellen (Liu u. a. 2024).

Charakteristisch für diese Modellfamilie ist die explizite Optimierung der Aufgabenauswahl unter diagnostischen und testtheoretischen Randbedingungen. Die Verfahren wählen Aufgaben nicht primär aufgrund inhaltlicher Ähnlichkeit oder Präferenzen aus, sondern anhand ihres erwarteten Informationsbeitrags zur Fähigkeitsmessung. Dadurch unterscheiden sie sich grundlegend von Recommender-Systemen oder Lernpfadverfahren, deren Ziel stärker auf Personalisierung und Inhaltsauswahl ausgerichtet ist.

Innerhalb der vorgeschlagenen Klassifikation werden informationsmaximierende Selektionsverfahren als eigenständige Unterklasse geführt, da die Adaptionentscheidung hier explizit als Optimierungsproblem der diagnostischen Informationsgewinnung formuliert wird.

3.2.2.3 Ressourcenempfehlung

Verfahren der Ressourcenempfehlung bilden die dritte Unterklasse der Adaptionentscheidung. Im Mittelpunkt dieser Verfahren steht die Auswahl geeigneter Lernressourcen, Aufgaben oder Inhalte auf Grundlage verfügbarer Informationen über den Lernenden. Im Unterschied zu informationsmaximierenden Selektionsverfahren erfolgt die Entscheidung dabei nicht primär nach diagnostischem Informationsgewinn, sondern nach der erwarteten Relevanz, Passung oder Nützlichkeit eines Lernobjekts für einen bestimmten Lernenden.

Besonders verbreitet sind diese Verfahren im Bereich der Educational Recommender Systems (ERS). Ziel solcher Systeme ist es, Lernenden diejenigen Ressourcen vorzuschlagen, die ihren Interessen, ihrem Wissensstand, ihren Lernzielen oder ihren bisherigen Interaktionen möglichst gut entsprechen. Die Literatur unterscheidet dabei insbesondere zwischen content-basierten, kollaborativen, wissensbasierten sowie hybriden Empfehlungsverfahren (Silva u. a. 2023).

Content-basierte Verfahren empfehlen Lernressourcen auf Grundlage ihrer Eigenschaften und Merkmale. Dabei werden Inhalte ausgewählt, die Ähnlichkeiten zu bereits genutzten oder positiv bewerteten Ressourcen aufweisen. Kollaborative Verfahren nutzen dagegen Präferenz- oder Interaktionsmuster mehrerer Lernender und gehen davon aus, dass Personen mit ähnlichem Verhalten auch ähnliche Ressourcen bevorzugen. Wissens- beziehungsweise ontologiebasierte Verfahren greifen auf explizit modelliertes Domänenwissen, Lernziele oder semantische Beziehungen zwischen Lernobjekten zurück, um geeignete Empfehlungen abzuleiten (Silva u. a. 2023).

In der aktuellen Literatur besitzen hybride Empfehlungsverfahren eine besondere Bedeutung. Sie kombinieren mehrere Empfehlungsstrategien, beispielsweise content-basierte und kollaborative Verfahren, um die jeweiligen Stärken verschiedener Ansätze miteinander zu verbinden und deren Einschränkungen teilweise zu reduzieren. Insbesondere Probleme wie der Cold-Start-Effekt, bei dem für neue Lernende oder Lernressourcen zunächst kaum Informationen vorliegen, sowie Datensparsamkeit (Data Sparsity), also eine geringe Anzahl verfügbarer Interaktionsdaten, können durch die Kombination mehrerer Empfehlungsstrategien teilweise reduziert werden. Typische Vertreter dieser Unterklasse sind kollaborative Filterverfahren, content-basierte Empfehlungssysteme, wissens- bzw. ontologiebasierte Recommender sowie hybride Empfehlungssysteme (Silva u. a. 2023).

Charakteristisch für diese Modellfamilie ist die Verbindung von Zustandsinformationen über den Lernenden mit der Auswahl konkreter Lernressourcen. Die Verfahren bilden damit die Schnittstelle zwischen Learner Modeling und inhaltlicher Personalisierung. Während Zustandsmodelle Informationen über Wissen, Fähigkeiten oder Präferenzen bereitstellen, entscheiden Empfehlungssysteme darüber, welche Inhalte auf Grundlage dieser Informationen als Nächstes vorgeschlagen werden sollen.

Innerhalb der vorgeschlagenen Klassifikation werden Verfahren der Ressourcenempfehlung als eigenständige Unterklasse geführt, da ihre primäre Aufgabe in der Auswahl geeigneter Lernobjekte auf Basis von Relevanz-, Ähnlichkeits- oder Präferenzkriterien besteht. Typische Vertreter dieser Kategorie sind content-basierte Recommender, kollaborative Filterverfahren, wissensbasierte Empfehlungssysteme sowie hybride Educational Recommender Systems.

3.2.2.4 Lernpfadempfehlung und Sequenzplanung

Verfahren der Lernpfadempfehlung und Sequenzplanung bilden die vierte Unterklasse der Adaptionentscheidung. Im Unterschied zu klassischen Empfehlungssystemen steht hier nicht die Auswahl eines einzelnen Lernobjekts im Mittelpunkt, sondern die Planung ganzer Sequenzen von Lernaktivitäten. Ziel dieser Verfahren ist die Konstruktion personalisierter Lernpfade, die den aktuellen Wissensstand, individuelle Lernziele sowie weitere Randbedingungen eines Lernenden berücksichtigen.

Die Literatur beschreibt personalisierte Lernpfade als einen zentralen Bestandteil adaptiver Lernsysteme. Während Recommender-Systeme typischerweise einzelne Ressourcen empfehlen, versuchen Lernpfadverfahren, mehrere Lernobjekte in eine sinnvolle Reihenfolge zu bringen und dadurch den gesamten Lernprozess zu strukturieren. Nabizadeh et al. unterscheiden hierzu die Ansätze Course Generation, Sequential Pattern Recognition und Course Sequence. Gemeinsam ist diesen Verfahren, dass sie zeitliche und inhaltliche Abhängigkeiten zwischen Lernaktivitäten berücksichtigen und Lernen als Sequenzierungs- beziehungsweise Optimierungsproblem modellieren (Nabizadeh u. a. 2020).

Auf algorithmischer Ebene kommen unterschiedliche Such-, Optimierungs- und Planungsverfahren zum Einsatz. Nabizadeh et al. nennen insbesondere graphbasierte Verfahren, Constraint-based Approaches, Case-Based-Reasoning-Ansätze sowie evolutionäre und schwarmbasierte Optimierungsverfahren wie Genetic Algorithms, Ant Colony Optimization und Particle Swarm Optimization (Nabizadeh u. a. 2020). Gemeinsam ist diesen Verfahren, dass sie nicht lediglich einzelne Lernobjekte auswählen, sondern ganze Lernsequenzen als Optimierungsproblem modellieren.

Charakteristisch für diese Modellfamilie ist die explizite Berücksichtigung zeitlicher und inhaltlicher Abhängigkeiten zwischen Lernobjekten. Die Verfahren modellieren Lernen somit nicht als Folge isolierter Empfehlungen, sondern als zusammenhängenden Prozess, dessen einzelne Schritte aufeinander aufbauen.

Innerhalb der vorgeschlagenen Klassifikation werden Verfahren der Lernpfadempfehlung und Sequenzplanung als eigenständige Unterklasse geführt, da ihre primäre Aufgabe in der Planung vollständiger Lernsequenzen besteht. Typische Vertreter dieser Kategorie sind Course-Generation-Verfahren, Sequential-Pattern-Mining-Ansätze, graphbasierte Lernpfadverfahren sowie Optimierungsverfahren zur Curriculum- und Lernpfadplanung.

3.2.2.5 Sequentielle Entscheidungsoptimierung

Verfahren der sequentiellen Entscheidungsoptimierung bilden die fünfte Unterklasse der Adaptionsentscheidung. Im Mittelpunkt dieser Verfahren steht nicht die Auswahl einzelner Lernressourcen oder die Planung vorgegebener Lernpfade, sondern die Optimierung von Entscheidungsstrategien über eine Folge von Interaktionen hinweg. Ziel ist es, adaptives Verhalten zu erlernen, das langfristig den Lernerfolg maximiert.

Charakteristisch für diese Modellfamilie ist die Betrachtung adaptiver Entscheidungen als sequentielles Entscheidungsproblem. Die Auswahl einer Lernaktivität beeinflusst dabei nicht nur den unmittelbaren Lernerfolg, sondern auch zukünftige Zustände und Handlungsmöglichkeiten. Verfahren dieser Klasse müssen daher zwischen Exploration und Exploitation abwägen. Exploration bezeichnet das Ausprobieren bislang wenig genutzter Aktionen, um zusätzliche Informationen zu gewinnen, während Exploitation die Nutzung bereits bekannter erfolgreicher Strategien beschreibt (Riedmann u. a. 2025).

Einen frühen Ansatz zur Modellierung adaptiver Bildungsentscheidungen stellen kontextuelle Bandits dar. Hier wird auf Grundlage des aktuellen Lernendenzustands diejenige Aktion ausgewählt, die den erwarteten kurzfristigen Lernerfolg maximiert. Im Gegensatz zu vollständigen Reinforcement-Learning-Verfahren berücksichtigen Bandit-Modelle dabei typischerweise keine langfristigen Auswirkungen späterer Entscheidungen (Riedmann u. a. 2025).

Den wichtigsten Forschungsbereich dieser Unterklasse bildet das Reinforcement Learning. Dabei lernt ein Agent durch Interaktion mit der Lernumgebung eine Strategie (Policy), die langfristige Belohnungen maximiert. Die Literatur beschreibt insbesondere wertbasierte Verfahren wie

Q-Learning und Deep Q-Networks (DQN) sowie Policy-Gradient- und weitere Policy-Learning-Verfahren als häufig eingesetzte Ansätze im Bildungsbereich (Riedmann u. a. 2025).

Im Unterschied zu klassischen Recommender-Systemen erfolgt die Auswahl von Lernaktivitäten hier nicht primär auf Grundlage von Ähnlichkeits-, Präferenz- oder Relevanzmaßen. Stattdessen wird die gesamte Folge von Zuständen, Aktionen und Belohnungen berücksichtigt. Die Adaptionentscheidung wird somit als Optimierungsproblem über längere Interaktionssequenzen modelliert.

Innerhalb der vorgeschlagenen Klassifikation werden Verfahren der sequentiellen Entscheidungsoptimierung als eigenständige Unterklasse geführt, da sie adaptive Entscheidungen explizit als Folgeproblem mit Exploration, Exploitation und langfristiger Belohnungsmaximierung modellieren. Typische Vertreter dieser Kategorie sind kontextuelle Bandits, Q-Learning, Deep Q-Networks (DQN), Proximal Policy Optimization (PPO) (Riedmann u. a. 2025).

3.3 Ergänzende Klassifikationsdimensionen

Die bislang entwickelte Taxonomie klassifiziert adaptive Lernverfahren primär nach ihrer funktionalen Rolle innerhalb adaptiver Lernsysteme. Dabei wird zwischen Verfahren der Zustandsmodellierung und Verfahren der Adaptionentscheidung unterschieden. Diese Einteilung erlaubt eine systematische Zuordnung der in der Literatur beschriebenen Verfahren, erfasst jedoch nicht alle relevanten Unterschiede zwischen einzelnen Ansätzen.

Aus analytischer Sicht ist es daher sinnvoll, die funktionale Klassifikation durch zusätzliche Querschnittsdimensionen zu ergänzen. Diese beschreiben Eigenschaften, die sich über mehrere Kategorien hinweg erstrecken und einen Vergleich unterschiedlicher Verfahren ermöglichen. Insbesondere die verwendete Datenbasis, die zugrunde liegende Modellierungsfamilie sowie die Interpretierbarkeit eines Verfahrens werden in der Literatur wiederholt als zentrale Unterscheidungsmerkmale hervorgehoben.

3.3.1 Datenbasis

Die Datenbasis beschreibt, auf welchen Informationen ein Verfahren seine Modellierung oder Entscheidungsfindung aufbaut. Adaptive Lernsysteme nutzen hierzu eine Vielzahl unterschiedlicher Datentypen. Dazu zählen insbesondere Leistungsdaten wie richtige oder falsche Antworten, Interaktions- und Prozessdaten wie Bearbeitungszeiten, Navigationspfade oder Hint-Nutzung, Strukturwissen über Domänen und Lernobjekte sowie Profil-, Präferenz- und Kontextinformationen der Lernenden.

Die Datenbasis stellt eine wichtige ergänzende Klassifikationsdimension dar, da Verfahren derselben funktionalen Kategorie auf unterschiedlichen Informationsquellen beruhen können. So zählen Rasch-Modelle, Bayesian Knowledge Tracing und Deep Knowledge Tracing trotz ihrer gemeinsamen Zuordnung zur Zustandsmodellierung zu unterschiedlichen Verfahrenstypen und

nutzen verfügbare Lerndaten in unterschiedlicher Form. Während psychometrische Verfahren überwiegend Antwortdaten verarbeiten, beziehen tief-neuronale Ansätze häufig längere Interaktionssequenzen ein. Analog unterscheiden sich Verfahren der Adaptionentscheidung hinsichtlich der verwendeten Informationsquellen, etwa zwischen Präferenzdaten in Recommender-Systemen und Zustands-Aktions-Belohnungsdaten im Reinforcement Learning.

3.3.2 Modellierungsfamilie

Die Modellierungsfamilie beschreibt das zugrunde liegende mathematische oder informatische Repräsentationsprinzip eines Verfahrens. Verfahren mit ähnlicher Funktion können dabei auf sehr unterschiedlichen Modellierungsansätzen beruhen. In der Literatur finden sich insbesondere psychometrische, probabilistische, logistische, symbolische, graphbasierte, faktorisierte, metaheuristische sowie tief-neuronale Modellierungsansätze.

Die Modellierungsfamilie verdeutlicht, dass Verfahren mit gleicher funktionaler Rolle auf unterschiedlichen mathematischen Grundlagen beruhen können. Innerhalb der Zustandsmodellierung finden sich beispielsweise psychometrische Verfahren wie IRT-Modelle, probabilistische Ansätze wie BKT, logistische Verfahren wie PFA sowie tief-neuronale Verfahren wie DKT. Die funktionale Einordnung allein erfasst diese Unterschiede nicht, weshalb die Modellierungsfamilie eine sinnvolle ergänzende Beschreibungsebene darstellt.

3.3.3 Interpretierbarkeit

Die Interpretierbarkeit beschreibt, in welchem Umfang die Entscheidungen oder Vorhersagen eines Verfahrens für Menschen nachvollziehbar sind. Diese Eigenschaft besitzt im Bildungsbereich eine besondere Bedeutung, da adaptive Entscheidungen häufig gegenüber Lernenden, Lehrenden oder Institutionen begründet werden müssen.

Besonders deutlich wird dies innerhalb der Zustandsmodellierung. Psychometrische Modelle, Bayes-Netz-Ansätze oder regelbasierte Verfahren gelten häufig als vergleichsweise gut nachvollziehbar, da ihre Modellannahmen und Entscheidungsregeln explizit beschrieben werden können. Demgegenüber erreichen tiefe neuronale Verfahren oftmals höhere Vorhersageleistungen, erzeugen ihre Ergebnisse jedoch auf Grundlage schwer nachvollziehbarer interner Repräsentationen. Die Interpretierbarkeit stellt daher keine eigenständige Klassifikationsachse dar, ergänzt die funktionale Taxonomie jedoch um eine für den Bildungsbereich wichtige Bewertungsperspektive.

Die Interpretierbarkeit bildet daher eine wichtige ergänzende Klassifikationsdimension, da sie einen zentralen Zielkonflikt adaptiver Lernsysteme sichtbar macht: den Ausgleich zwischen Vorhersage- beziehungsweise Optimierungsleistung einerseits und Transparenz sowie Erklärbarkeit andererseits.

Die beschriebenen Dimensionen stellen keine eigenständigen Klassifikationsachsen der vorgeschlagenen Taxonomie dar, ermöglichen jedoch eine differenziertere Beschreibung und den Vergleich von Verfahren innerhalb derselben funktionalen Kategorie.

3.4 Diskussion und Grenzen der Klassifikation

Die vorgeschlagene Taxonomie ist als synthetische Ordnung adaptiver Lernverfahren zu verstehen. Sie reproduziert keine einzelne, in der Literatur etablierte Gesamtklassifikation, sondern führt mehrere in unterschiedlichen Forschungsbereichen entwickelte Teilordnungen zu einem gemeinsamen Schema zusammen. Ihre Stärke liegt damit in der Zusammenführung fragmentierter Literaturstränge aus Bereichen wie Learner Modeling, Knowledge Tracing, Computerized Adaptive Testing, Educational Recommender Systems und Reinforcement Learning. Gleichzeitig stellt genau diese Synthese auch eine Grenze der Taxonomie dar.

Eine erste Einschränkung ergibt sich aus der Tatsache, dass die vorgeschlagenen Kategorien nicht vollständig trennscharf sind. Besonders deutlich zeigt sich dies bei hybriden Systemen, die in der Literatur eher die Regel als die Ausnahme darstellen. Adaptive Lernumgebungen kombinieren häufig mehrere Modellierungs- und Entscheidungsverfahren miteinander. So können Knowledge-Tracing-Modelle als Grundlage für Empfehlungssysteme dienen, Lernpfadverfahren auf Zustandsmodellen aufbauen oder Reinforcement-Learning-Verfahren Informationen aus psychometrischen oder probabilistischen Lernendenmodellen verwenden.

Einzelne Verfahren können daher je nach Betrachtungsperspektive mehreren Kategorien zugeordnet werden. So lassen sich Bayes-Netz-basierte Ansätze sowohl zur Modellierung von Lernzuständen als auch als Bestandteil von Adaptionentscheidungen einsetzen. Ebenso können Recommender-Systeme Komponenten des Reinforcement Learning integrieren oder Elo-basierte Verfahren Elemente psychometrischer Fähigkeitsmodelle aufweisen. Die Kategorien sind daher als analytische Hauptzuordnungen und nicht als gegenseitig ausschließende Klassen zu verstehen. Eine ausschließlich auf gegenseitig ausschließenden Kategorien beruhende Taxonomie würde die in der Praxis verbreitete Hybridität adaptiver Lernsysteme nur unzureichend abbilden.

Für die vorgeschlagene Klassifikation werden hybride Systeme daher nach der primären funktionalen Rolle des jeweiligen Moduls eingeordnet. Zusätzliche Verfahren oder Modellierungsansätze werden über die ergänzenden Klassifikationsdimensionen berücksichtigt. Ein System, das beispielsweise Bayesian Knowledge Tracing zur Wissensschätzung und anschließend ein Recommender-System zur Auswahl geeigneter Lernressourcen verwendet, umfasst somit sowohl ein Verfahren der Zustandsmodellierung als auch ein Verfahren der Adaptionentscheidung. Die Taxonomie versteht sich daher nicht als Zuordnung vollständiger Systeme zu exakt einer Kategorie, sondern als Einordnung der jeweils verwendeten Verfahren und Module.

Eine zweite Grenze betrifft die Dynamik des Forschungsfeldes. Adaptive Lernsysteme entwickeln sich kontinuierlich weiter, insbesondere im Bereich datengetriebener und neuronaler Verfahren. Neue Modellarchitekturen oder hybride Ansätze können bestehende Kategorien miteinander

verbinden oder neue Untergruppen erforderlich machen. Die vorgeschlagene Taxonomie ist daher nicht als abschließende Ordnung zu verstehen, sondern als strukturierender Bezugsrahmen für den aktuellen Forschungsstand.

Darüber hinaus weist die Literatur wiederholt auf Defizite in der Evaluation adaptiver Lernverfahren hin. Mehrere Reviews stellen fest, dass die Auswahl bestimmter Adaptionungsverfahren häufig nur begrenzt theoretisch oder empirisch begründet wird. Gleichzeitig konzentrieren sich viele Studien auf technische Leistungsmaße wie Vorhersagegenauigkeit oder Empfehlungsqualität, während pädagogische Wirkungen, Lernerfolge oder langfristige Nutzungseffekte deutlich seltener untersucht werden. Auch im Bereich des Reinforcement Learning basiert ein erheblicher Teil der vorhandenen Evidenz auf Simulationen statt auf realen Lernumgebungen. Die Aussagekraft von Vergleichen zwischen Verfahren ist dadurch teilweise eingeschränkt.

Die ergänzenden Klassifikationsdimensionen Datenbasis, Modellierungsfamilie und Interpretierbarkeit wurden eingeführt, um einige dieser Einschränkungen abzumildern. Sie verdeutlichen, dass Verfahren mit gleicher funktionaler Rolle auf unterschiedlichen Datenquellen, Modellierungsansätzen oder Transparenzniveaus beruhen können. Gleichzeitig ersetzen diese Dimensionen nicht die funktionale Hauptstruktur der Taxonomie, sondern dienen als ergänzende Beschreibungsperspektiven.

Insgesamt erscheint die Unterscheidung zwischen Zustandsmodellierung und Adaptionentscheidung dennoch als ein sachlich klarer und informatisch anschlussfähiger Ausgangspunkt für die Klassifikation adaptiver Lernverfahren. Innerhalb dieser beiden Hauptklassen lassen sich die in der Literatur beschriebenen Verfahren konsistent einordnen, ohne die Vielfalt der zugrunde liegenden Modellierungsansätze vollständig zu verlieren.

4 Konzeption der Lernressource

4.1 Zielsetzung

Ziel der im Rahmen dieser Arbeit entwickelten Lernressource ist die verständliche und anschauliche Vermittlung zentraler Verfahren adaptiver Lernverfahren. Adaptive Lernverfahren beruhen häufig auf komplexen algorithmischen Konzepten und mathematischen Modellen, deren Funktionsweise für Studierende und andere Interessierte nicht immer leicht nachvollziehbar ist. Die Lernressource soll dazu beitragen, diese Verfahren systematisch aufzubereiten und einen niedrigschwelligen Zugang zu ihren grundlegenden Mechanismen zu ermöglichen.

Die Lernressource richtet sich primär an Studierende der Informatik und verwandter Fachrichtungen sowie an weitere Personen mit Interesse an adaptiven Lernverfahren. Grundlegende algorithmische Kenntnisse werden vorausgesetzt, während spezifisches Vorwissen zu einzelnen Verfahren nicht erforderlich ist.

Ein zentrales Ziel der Konzeption besteht darin, komplexe algorithmische Zusammenhänge möglichst anschaulich darzustellen. Hierzu werden textuelle Erklärungen, grafische Darstellungen und interaktive Elemente miteinander kombiniert, um sowohl theoretische Grundlagen als auch praktische Anwendungsaspekte verständlich zu vermitteln. Die Lernressource soll dadurch nicht nur Faktenwissen vermitteln, sondern insbesondere das Verständnis für die Funktionsweise, Eigenschaften und Einsatzmöglichkeiten adaptiver Lernverfahren fördern.

Die in Kapitel 3 entwickelte Taxonomie dient dabei als Strukturierungsgrundlage für die Organisation der Lerninhalte. Sie soll Lernenden eine systematische Orientierung innerhalb des Themengebiets ermöglichen, steht jedoch nicht als eigenständiges Lernziel im Mittelpunkt der Lernressource. Der Fokus liegt vielmehr auf der verständlichen Vermittlung der einzelnen Verfahren und ihrer grundlegenden Konzepte.

Die Konzeption der Lernressource erfolgt bewusst modular. Die entwickelte Struktur soll grundsätzlich auf unterschiedliche adaptive Lernverfahren übertragbar sein und eine schrittweise Erweiterung der Lernumgebung ermöglichen. Die konkrete prototypische Umsetzung eines solchen Lernmoduls wird in Kapitel 5 exemplarisch anhand des Elo-Verfahrens dargestellt.

4.2 Didaktisches Konzept

Die Konzeption der Lernressource verfolgt das Ziel, komplexe algorithmische Verfahren adaptiver Lernsysteme möglichst verständlich und anschaulich zu vermitteln. Da viele der behandelten Verfahren auf mathematischen Modellen oder abstrakten Entscheidungsmechanismen beruhen, sollen theoretische Grundlagen und praktische Anwendungsaspekte miteinander verknüpft werden. Die Lernressource soll den Lernenden nicht nur Informationen über einzelne Verfahren bereitstellen, sondern deren grundlegende Funktionsweise, algorithmische Umsetzung und Einsatzmöglichkeiten nachvollziehbar machen.

Ein zentrales Gestaltungsprinzip der Lernressource ist die Kombination unterschiedlicher Darstellungsformen. Textuelle Erklärungen werden durch grafische Darstellungen und interaktive Elemente ergänzt, um komplexe Zusammenhänge aus verschiedenen Perspektiven zugänglich zu machen. Die Kombination textueller und grafischer Darstellungen kann das Verständnis komplexer Inhalte unterstützen und bildet ein zentrales Prinzip multimedialer Lernumgebungen (Mayer 2005).

Darüber hinaus folgt die Lernressource einem modularen Aufbau. Jedes Verfahren soll nach einer einheitlichen Struktur präsentiert werden, um eine konsistente Navigation und einen einfachen Vergleich unterschiedlicher Ansätze zu ermöglichen. Die entwickelte Lernressource ist dabei als digitale Anwendung konzipiert, die Lernende schrittweise durch die Inhalte eines adaptiven Lernverfahrens führt.

Den Einstieg bildet eine Einführung in das jeweilige Verfahren und die zugrunde liegende Problemstellung. Anschließend werden die wesentlichen Konzepte und die grundlegende Funktionsweise des Algorithmus erläutert. Darauf aufbauend werden mathematische Zusammenhänge und algorithmische Abläufe durch grafische Darstellungen, konkrete Beispiele sowie ausgewählte Codebeispiele veranschaulicht. Dadurch soll der Zusammenhang zwischen theoretischem Konzept und praktischer Implementierung nachvollziehbar werden.

Ergänzend zu den theoretischen Inhalten werden interaktive Elemente eingesetzt, die eine aktive Auseinandersetzung mit dem Verfahren ermöglichen. Hierzu können beispielsweise Simulationen, Parameteranpassungen oder kleine Übungsaufgaben dienen, welche die Auswirkungen einzelner Algorithmusbestandteile nachvollziehbar machen. Den Abschluss bilden Möglichkeiten zur Wiederholung und Selbstkontrolle der vermittelten Inhalte, sodass nicht nur Faktenwissen vermittelt, sondern auch das eigenständige Verständnis der behandelten Verfahren gefördert wird.

Ein weiteres Gestaltungsprinzip besteht in der schrittweisen Vermittlung der Lerninhalte. Komplexe Verfahren werden zunächst auf konzeptioneller Ebene eingeführt, bevor algorithmische Details, Visualisierungen und konkrete Anwendungsbeispiele behandelt werden. Dadurch soll ein schrittweiser Wissensaufbau unterstützt und der Einstieg in komplexe Themengebiete erleichtert werden.

Die entwickelte Konzeption ist bewusst allgemein gehalten und nicht auf ein einzelnes Verfahren beschränkt. Vielmehr soll die zugrunde liegende Struktur auf unterschiedliche adaptive Lernverfahren übertragbar sein und eine schrittweise Erweiterung der Lernressource ermöglichen.

4.3 Lern- und Interaktionselemente

Die entwickelte Lernressource kombiniert unterschiedliche Lern- und Interaktionselemente, um komplexe algorithmische Zusammenhänge möglichst verständlich und anschaulich zu vermitteln. Dabei werden verschiedene Darstellungsformen miteinander verknüpft, sodass theoretische Inhalte durch Visualisierungen, Beispiele und interaktive Komponenten ergänzt werden.

Den Ausgangspunkt bilden textuelle Erklärungen, welche die grundlegenden Konzepte, Begriffe und Funktionsweisen eines Verfahrens erläutern. Sie dienen der Einführung in die jeweilige Problemstellung und schaffen die notwendigen Grundlagen für das Verständnis der algorithmischen Abläufe.

Ergänzend kommen grafische Darstellungen zum Einsatz. Diese sollen insbesondere mathematische Zusammenhänge, Zustandsänderungen oder algorithmische Prozesse übersichtlicher darstellen und komplexe Inhalte leichter nachvollziehbar machen. Die Kombination textueller und visueller Informationen entspricht grundlegenden Prinzipien multimedialen Lernens und kann das Verständnis komplexer Inhalte unterstützen (Mayer 2005).

Ein wesentliches Merkmal der Lernressource bilden interaktive Elemente. Diese ermöglichen es den Lernenden, die Auswirkungen einzelner Parameter oder Entscheidungen aktiv nachzuvollziehen und sich eigenständig mit den behandelten Verfahren auseinanderzusetzen. Interaktive Komponenten können beispielsweise Simulationen, veränderbare Eingabewerte oder kleine Experimentierumgebungen umfassen, in denen algorithmische Abläufe schrittweise untersucht werden.

Darüber hinaus werden konkrete Anwendungsbeispiele genutzt, um den Bezug zwischen theoretischen Konzepten und praktischen Einsatzgebieten herzustellen. Reale oder vereinfachte Szenarien sollen verdeutlichen, wie adaptive Lernverfahren eingesetzt werden und welche Auswirkungen unterschiedliche Modellparameter oder Eingaben auf das Verhalten eines Algorithmus besitzen. Ergänzend können ausgewählte Codebeispiele eingesetzt werden, um die algorithmische Umsetzung der behandelten Verfahren zu verdeutlichen. Diese dienen nicht der vollständigen Implementierung der Algorithmen, sondern sollen zentrale Berechnungsschritte und Modellmechanismen nachvollziehbar machen sowie den Transfer zwischen theoretischer Beschreibung und praktischer Anwendung unterstützen.

Zur Unterstützung des Lernprozesses werden die Inhalte schließlich durch kurze Verständnis- und Reflexionsaufgaben ergänzt. Diese dienen der Wiederholung zentraler Konzepte und ermöglichen eine aktive Überprüfung des eigenen Verständnisses der behandelten Inhalte.

Die Kombination aus textuellen Erklärungen, grafischen Darstellungen, interaktiven Elementen, Anwendungsbeispielen sowie Verständnisaufgaben soll unterschiedliche Zugänge zu den Lerninhalten schaffen und dadurch das Verständnis komplexer adaptiver Lernverfahren fördern.

4.4 Modularität und Erweiterbarkeit

Die Konzeption der Lernressource folgt einem modularen Ansatz, der sich primär auf die didaktische und strukturelle Gestaltung der Inhalte bezieht. Ziel ist es, eine allgemeine Vorlage für die Vermittlung adaptiver Lernverfahren zu entwickeln, die unabhängig vom jeweils behandelten Algorithmus eingesetzt werden kann. Die prototypische Umsetzung anhand des Elo-Verfahrens dient dabei als exemplarische Anwendung dieses Konzepts.

Die Modularität der Lernressource besteht darin, dass unterschiedliche adaptive Lernverfahren nach einer einheitlichen Grundstruktur aufbereitet werden können. Unabhängig vom konkreten Verfahren umfasst ein Lernmodul dabei grundlegende Informationen zur Problemstellung, eine Beschreibung der Funktionsweise, anschauliche Beispiele, grafische Darstellungen, interaktive Elemente sowie Möglichkeiten zur Wiederholung und Selbstkontrolle. Die konkrete inhaltliche Ausgestaltung dieser Bestandteile richtet sich jeweils nach den Eigenschaften des betrachteten Verfahrens.

Die einheitliche Struktur erleichtert sowohl die Entwicklung weiterer Lernressourcen als auch deren Nutzung. Für zusätzliche adaptive Lernverfahren muss nicht jedes Mal ein neues didaktisches Konzept entwickelt werden. Stattdessen kann die bestehende Grundstruktur übernommen und mit den jeweils verfahrensspezifischen Inhalten, Visualisierungen und Interaktionselementen ausgestaltet werden.

Die prototypische Umsetzung des Elo-Verfahrens bildet damit den Ausgangspunkt für eine potenziell erweiterbare Sammlung einheitlich strukturierter Lernressourcen im Bereich adaptiver Lernverfahren. Das entwickelte Konzept soll grundsätzlich auf weitere Verfahren übertragbar sein und eine schrittweise Erweiterung der Lernumgebung ermöglichen.

5 Umsetzung einer Lernressource

5.1 Motivation und Problemstellung

Adaptive Lernsysteme verfolgen das Ziel, Lerninhalte an die individuellen Voraussetzungen und den aktuellen Wissensstand von Lernenden anzupassen. Um geeignete Aufgaben oder Lernressourcen auswählen zu können, müssen sie daher zunächst möglichst zuverlässig abschätzen, wie gut ein Lernender ein bestimmtes Themengebiet bereits beherrscht. Die Modellierung dieses aktuellen Leistungs- oder Wissensstands stellt eine zentrale Aufgabe adaptiver Lernsysteme dar (Pelánek 2017; Abdi u. a. 2019).

Für diese Schätzung wurden unterschiedliche Verfahren entwickelt. Während einige Ansätze auf psychometrischen oder probabilistischen Modellen beruhen, existieren auch Verfahren, die ihre Schätzungen nach jeder neuen Interaktion kontinuierlich aktualisieren. Ein vergleichsweise einfaches und weit verbreitetes Verfahren dieser Art ist das Elo-Verfahren. Es wurde ursprünglich zur Bewertung von Schachspielern entwickelt (Elo 1978) und später für verschiedene Anwendungsgebiete, darunter auch adaptive Lernsysteme, weiterentwickelt und eingesetzt (Abdi u. a. 2019).

Im Vergleich zu vielen komplexeren Modellierungsansätzen zeichnet sich das Elo-Verfahren durch eine vergleichsweise einfache Struktur sowie die Möglichkeit einer kontinuierlichen Aktualisierung aus. Diese Eigenschaften machen es für den Einsatz in digitalen Lernumgebungen interessant und haben dazu geführt, dass Elo-basierte Verfahren in der Literatur als geeignete Ansätze zur Lernendenmodellierung diskutiert werden (Pelánek 2016; Abdi u. a. 2019).

5.2 Die Grundidee des Elo-Verfahrens

Die Grundidee des Elo-Verfahrens entstand ursprünglich im Schachsport. Ziel war es, die relative Spielstärke verschiedener Spieler möglichst objektiv abzuschätzen. Hierzu wird jedem Spieler eine numerische Bewertung, das sogenannte Rating, zugeordnet. Treffen zwei Spieler aufeinander, kann aus ihren Ratings abgeschätzt werden, welcher Spieler mit höherer Wahrscheinlichkeit gewinnen sollte (Elo 1978).

Betrachtet man beispielsweise zwei Schachspieler mit einem Rating von 1600 beziehungsweise 1400 Punkten, so würde das Elo-Verfahren erwarten, dass der Spieler mit dem höheren Rating

häufiger gewinnt. Das tatsächliche Ergebnis einer einzelnen Partie ist jedoch nicht sicher vorher-sagbar. Auch ein schwächer eingeschätzter Spieler kann gewinnen und für eine Überraschung sorgen.

Genau diese Kombination aus Erwartung und tatsächlichem Ergebnis bildet den Kern des Elo-Verfahrens. Vor jeder Begegnung wird zunächst abgeschätzt, wie wahrscheinlich ein bestimmter Ausgang ist. Nach dem Spiel wird das tatsächliche Ergebnis mit dieser Erwartung verglichen. Entspricht das Ergebnis der Erwartung, verändern sich die Bewertungen nur geringfügig. Tritt dagegen ein unerwartetes Ergebnis ein, werden die Bewertungen stärker angepasst (Elo 1978).

Dieses Prinzip lässt sich auch auf adaptive Lernsysteme übertragen. Anstelle zweier Schachspiel-er treten hier ein Lernender und eine Aufgabe gegeneinander an. Dem Lernenden wird eine geschätzte Fähigkeit zugeordnet, während die Aufgabe durch einen Schwierigkeitswert beschrieben wird. Aus beiden Werten lässt sich ableiten, wie wahrscheinlich eine erfolgreiche Bearbeitung der Aufgabe ist. Nach jeder Interaktion werden die Schätzwerte anhand des tat-sächlichen Ergebnisses aktualisiert, sodass sich die Einschätzung des Lernenden kontinuierlich an neue Informationen anpasst (Abdi u. a. 2019).

Die grundlegende Idee des Elo-Verfahrens lässt sich somit auf drei einfache Schritte zurück-führen:

1. Aus den vorhandenen Bewertungen wird eine Erwartung gebildet.
2. Das tatsächliche Ergebnis wird beobachtet.
3. Die Bewertungen werden entsprechend angepasst.

Diese drei Schritte bilden den Kern des Elo-Verfahrens und werden im weiteren Verlauf der Lernressource zunächst algorithmisch und anschließend mathematisch genauer betrachtet.

5.3 Algorithmische Funktionsweise des Elo-Verfahrens

Im vorherigen Abschnitt wurde die grundlegende Idee des Elo-Verfahrens vorgestellt. Dabei wurde deutlich, dass das Verfahren aus einer vorhandenen Bewertung zunächst eine Erwartung ableitet, das tatsächliche Ergebnis beobachtet und die Bewertung anschließend entsprechend anpasst. Dieser Ablauf wird nach jeder Interaktion erneut durchlaufen und bildet den Kern des Elo-Verfahrens (Pelánek 2016).

Zu Beginn einer Interaktion liegen für den Lernenden und die Aufgabe jeweils aktuelle Schätzwerte vor. Der Lernende wird durch eine geschätzte Fähigkeit beschrieben, während für die Aufgabe ein Schwierigkeitswert angenommen wird. Beide Werte repräsentieren den aktuellen Kenntnisstand des Systems über den Lernenden beziehungsweise die Aufgabe (Pelánek 2016; Abdi u. a. 2019).

Im ersten Schritt wird aus diesen Schätzwerten eine Erwartung gebildet. Das System bestimmt, mit welcher Wahrscheinlichkeit ein Lernender die betrachtete Aufgabe erfolgreich bearbeiten

sollte. Besitzt der Lernende im Vergleich zur Schwierigkeit der Aufgabe eine hohe geschätzte Fähigkeit, wird eine erfolgreiche Bearbeitung wahrscheinlicher eingeschätzt. Ist die Aufgabe schwieriger als die geschätzte Fähigkeit des Lernenden, fällt die erwartete Erfolgswahrscheinlichkeit entsprechend geringer aus (Elo 1978; Pelánek 2016).

Im zweiten Schritt wird das tatsächliche Ergebnis der Bearbeitung beobachtet. Das System stellt fest, ob die Aufgabe erfolgreich gelöst wurde oder nicht. Dieses Ergebnis liefert neue Informationen über die Fähigkeit des Lernenden und gegebenenfalls auch über die Schwierigkeit der Aufgabe.

Anschließend wird das beobachtete Ergebnis mit der zuvor berechneten Erwartung verglichen. Stimmen Erwartung und Ergebnis weitgehend überein, werden die Schätzwerte nur geringfügig angepasst. Treten dagegen unerwartete Ergebnisse auf, beispielsweise wenn ein Lernender eine schwierige Aufgabe erfolgreich bearbeitet oder an einer einfachen Aufgabe scheitert, erfolgt eine stärkere Aktualisierung der Bewertungen (Elo 1978; Pelánek 2016).

Im letzten Schritt werden die Schätzwerte aktualisiert. Die neu berechnete Fähigkeit des Lernenden sowie gegebenenfalls die angepasste Schwierigkeit der Aufgabe bilden die Ausgangsbasis für die nächste Interaktion. Durch die wiederholte Anwendung dieses Ablaufs passt sich das Modell kontinuierlich an neue Beobachtungen an und verbessert fortlaufend seine Schätzung des aktuellen Leistungsstands (Pelánek 2016; Abdi u. a. 2019).

Der algorithmische Ablauf des Elo-Verfahrens lässt sich somit in fünf Schritte zusammenfassen:

1. Aktuelle Schätzwerte bestimmen.
2. Erwartete Erfolgswahrscheinlichkeit berechnen.
3. Tatsächliches Ergebnis beobachten.
4. Erwartung und Ergebnis vergleichen.
5. Schätzwerte aktualisieren.

Diese fünf Schritte werden nach jeder bearbeiteten Aufgabe erneut durchlaufen und bilden den grundlegenden Arbeitsablauf des Elo-Verfahrens. Im nächsten Abschnitt wird betrachtet, wie die einzelnen Berechnungsschritte mathematisch beschrieben werden können.

5.4 Mathematische Grundlagen des Elo-Verfahrens

Im vorherigen Abschnitt wurde die grundlegende Funktionsweise des Elo-Verfahrens beschrieben. Dabei wurde deutlich, dass das Verfahren aus der geschätzten Fähigkeit eines Lernenden und der Schwierigkeit einer Aufgabe zunächst eine Erwartung ableitet und diese nach jeder Interaktion aktualisiert.

Um diesen Prozess mathematisch zu beschreiben, müssen zunächst geeignete Größen definiert werden. Im Elo-Verfahren wird jedem Lernenden eine numerische Bewertung zugeordnet, welche die aktuell geschätzte Fähigkeit repräsentiert. Analog erhält auch jede Aufgabe einen

numerischen Schwierigkeitswert. Beide Bewertungen werden kontinuierlich angepasst und bilden die Grundlage für die weiteren Berechnungen (Pelánek 2016; Elo 1978).

Die zentrale Idee besteht darin, aus der Beziehung zwischen Fähigkeit und Aufgabenschwierigkeit die Wahrscheinlichkeit einer erfolgreichen Bearbeitung abzuleiten. Besitzt ein Lernender eine höhere geschätzte Fähigkeit als die Schwierigkeit einer Aufgabe, sollte die Erfolgswahrscheinlichkeit entsprechend größer ausfallen. Umgekehrt sinkt diese Wahrscheinlichkeit, wenn die Aufgabe schwieriger eingeschätzt wird als die Fähigkeit des Lernenden.

5.4.1 Erwartete Erfolgswahrscheinlichkeit

Der erste Berechnungsschritt des Elo-Verfahrens besteht darin, die Wahrscheinlichkeit zu bestimmen, mit der ein Lernender eine Aufgabe erfolgreich bearbeiten sollte. Diese Wahrscheinlichkeit wird als erwartete Erfolgswahrscheinlichkeit bezeichnet.

Im Bildungsbereich wird die Erfolgswahrscheinlichkeit aus der Differenz zwischen der geschätzten Fähigkeit eines Lernenden und der Schwierigkeit einer Aufgabe berechnet. Besitzt ein Lernender eine höhere Fähigkeit als die Schwierigkeit der Aufgabe, wird eine erfolgreiche Bearbeitung wahrscheinlicher. Ist die Aufgabe schwieriger als die geschätzte Fähigkeit des Lernenden, fällt die erwartete Erfolgswahrscheinlichkeit entsprechend geringer aus (Pelánek 2016).

Die Berechnung erfolgt mithilfe einer logistischen Funktion:

$$P_{si} = \frac{1}{1 + e^{d_i - \theta_s}} \quad (1)$$

Dabei bezeichnet

Symbol	Bedeutung
P_{si}	Wahrscheinlichkeit einer korrekten Antwort
θ_s	Fähigkeit des Lernenden
d_i	Schwierigkeit der Aufgabe

Der Wert von P_{si} liegt stets zwischen 0 und 1. Werte nahe 1 deuten auf eine hohe Erfolgswahrscheinlichkeit hin, während Werte nahe 0 auf eine geringe Erfolgswahrscheinlichkeit hinweisen. Besitzen Lernender und Aufgabe denselben Bewertungswert, also $\theta_s = d_i$, ergibt sich eine erwartete Erfolgswahrscheinlichkeit von 0,5. Das System geht in diesem Fall davon aus, dass eine korrekte und eine falsche Antwort gleichermaßen wahrscheinlich sind (Pelánek 2016).

Die ursprüngliche Elo-Formulierung im Schach verwendet statt der natürlichen Exponentialfunktion e eine Potenz zur Basis 10 sowie den Skalierungsfaktor 400. Beide Darstellungen beschreiben jedoch denselben grundlegenden Zusammenhang zwischen Fähigkeitsdifferenz und

Erfolgswahrscheinlichkeit. Für Anwendungen im Bildungsbereich wird häufig die mathematisch einfachere Form mit der Standard-Logistikfunktion verwendet (Pelánek 2016).

5.4.2 Aktualisierung der Bewertungen

Nachdem die erwartete Erfolgswahrscheinlichkeit berechnet wurde, wird sie mit dem tatsächlichen Ergebnis der Bearbeitung verglichen. Die zentrale Idee des Elo-Verfahrens besteht darin, die Schätzwerte für die Fähigkeit eines Lernenden und die Schwierigkeit einer Aufgabe nach jeder Interaktion anzupassen. Auf diese Weise kann das Modell neue Informationen unmittelbar berücksichtigen und seine Vorhersagen fortlaufend verbessern (Pelánek 2016).

Die Anpassung basiert auf der Differenz zwischen dem beobachteten Ergebnis und der zuvor berechneten Erfolgswahrscheinlichkeit. Fällt das Ergebnis besser aus als erwartet, wird die Fähigkeit des Lernenden erhöht und die Schwierigkeit der Aufgabe reduziert. Fällt das Ergebnis schlechter aus als erwartet, erfolgt die Anpassung in die entgegengesetzte Richtung.

Die Aktualisierung der Fähigkeit eines Lernenden erfolgt nach der Formel

$$\theta'_s = \theta_s + K (\text{correct}_{si} - P_{si}) \quad (2)$$

Die Schwierigkeit einer Aufgabe wird analog aktualisiert:

$$d'_i = d_i - K (\text{correct}_{si} - P_{si}) \quad (3)$$

Zum Start liegen dabei die Werte von θ_s und d_i bei 0 (Pelánek 2016).

Dabei bezeichnet

Symbol	Bedeutung
θ'_s	aktualisierte Fähigkeit des Lernenden
d'_i	aktualisierte Schwierigkeit der Aufgabe
correct_{si}	tatsächliches Ergebnis (0 = falsch, 1 = richtig)
P_{si}	erwartete Erfolgswahrscheinlichkeit
K	Anpassungs- bzw. Lernrate

Der Ausdruck

$$\text{correct}_{si} - P_{si} \quad (4)$$

beschreibt die Abweichung zwischen dem tatsächlichen und dem erwarteten Ergebnis. Dieser Wert wird häufig als Vorhersagefehler bezeichnet. Ist die Antwort korrekt und wurde dies zuvor

nur mit einer geringen Wahrscheinlichkeit erwartet, ergibt sich ein positiver Vorhersagefehler. Wird eine Aufgabe dagegen falsch beantwortet, obwohl eine hohe Erfolgswahrscheinlichkeit vorhergesagt wurde, fällt der Vorhersagefehler negativ aus.

Der Parameter K bestimmt die Stärke der Aktualisierung. Große Werte führen zu schnelleren Anpassungen der Schätzwerte, während kleine Werte stabilere, aber langsamere Veränderungen bewirken. Die Wahl dieses Parameters beeinflusst daher maßgeblich, wie schnell das Modell auf neue Beobachtungen reagiert (Pelánek 2016).

Die Aktualisierungsregeln sorgen dafür, dass die Schätzwerte schrittweise an die tatsächlich beobachteten Leistungen angepasst werden. Im nächsten Abschnitt wird dieser Prozess anhand eines konkreten Zahlenbeispiels Schritt für Schritt nachvollzogen.

5.4.3 Beispiel einer Aktualisierung

Die bisher vorgestellten Formeln lassen sich anhand eines konkreten Zahlenbeispiels veranschaulichen.

Angenommen, die geschätzte Fähigkeit eines Lernenden beträgt

$$\theta_s = 0.5$$

während die Schwierigkeit einer Aufgabe mit

$$d_i = 1.5$$

eingeschätzt wird. Die Aufgabe gilt damit als deutlich schwieriger als das aktuelle Fähigkeitsniveau des Lernenden.

Die erwartete Erfolgswahrscheinlichkeit ergibt sich gemäß Gleichung (1) zu

$$\begin{aligned} P_{si} &= \frac{1}{1 + e^{1.5-0.5}} \\ &= \frac{1}{1 + e^1} \\ &\approx 0.27 \end{aligned}$$

Das System geht somit davon aus, dass der Lernende die Aufgabe nur mit einer Wahrscheinlichkeit von etwa 27 % korrekt beantworten wird.

Nun sei angenommen, dass der Lernende die Aufgabe dennoch richtig löst. Das beobachtete Ergebnis beträgt daher

$$correct_{si} = 1$$

Für dieses Beispiel werde eine Lernrate von

$$K = 0.1$$

verwendet.

Zunächst wird der Vorhersagefehler mithilfe von Gleichung (4) berechnet:

$$\begin{aligned} correct_{si} - P_{si} &= 1 - 0.27 \\ &= 0.73 \end{aligned}$$

Da das tatsächliche Ergebnis deutlich besser ausfällt als erwartet, ergibt sich ein vergleichsweise großer positiver Vorhersagefehler.

Die Fähigkeit des Lernenden wird anschließend gemäß Gleichung (2) zu

$$\begin{aligned} \theta'_s &= \theta_s + K(correct_{si} - P_{si}) \\ &= 0.5 + 0.1(1 - 0.27) \\ &= 0.5 + 0.073 \\ &= 0.573 \end{aligned}$$

aktualisiert.

Für die Schwierigkeit der Aufgabe ergibt sich analog gemäß Gleichung (3)

$$\begin{aligned} d'_i &= d_i - K(correct_{si} - P_{si}) \\ &= 1.5 - 0.1(1 - 0.27) \\ &= 1.5 - 0.073 \\ &= 1.427 \end{aligned}$$

Nach der Aktualisierung wird der Lernende somit etwas stärker und die Aufgabe etwas leichter eingeschätzt als zuvor. Das Elo-Verfahren berücksichtigt dadurch die neue Information, dass ein unerwartet gutes Ergebnis erzielt wurde.

Je stärker ein tatsächliches Ergebnis von der zuvor berechneten Erwartung abweicht, desto größer fällt die Anpassung der Schätzwerte aus. Überraschende Ergebnisse führen daher zu stärkeren Aktualisierungen als Ergebnisse, die bereits erwartet wurden.

5.5 Implementierung des Elo-Verfahrens

Die mathematischen Grundlagen des Elo-Verfahrens wurden in den vorherigen Abschnitten vorgestellt. Für den praktischen Einsatz in adaptiven Lernsystemen müssen diese Berechnungsschritte jedoch algorithmisch umgesetzt werden. Die Fähigkeit eines Lernenden und die Schwierigkeit einer Aufgabe sollen nach jeder Bearbeitung automatisch aktualisiert werden, sodass das System kontinuierlich neue Informationen berücksichtigen kann.

Im Rahmen dieser Lernressource wird das Elo-Verfahren exemplarisch in Python implementiert. Ziel ist nicht die Entwicklung eines vollständigen adaptiven Lernsystems, sondern die schrittweise Umsetzung der zuvor eingeführten mathematischen Konzepte. Dadurch wird deutlich, wie aus den Gleichungen des Elo-Verfahrens ein ausführbarer Algorithmus entsteht.

5.5.1 Repräsentation von Lernenden und Aufgaben

Für die Implementierung werden zunächst die beiden zentralen Größen des Elo-Verfahrens benötigt: die Fähigkeit eines Lernenden und die Schwierigkeit einer Aufgabe. Diese können in Python zunächst als einfache numerische Variablen gespeichert werden:

```
theta = 0.5      # Fähigkeit des Lernenden
difficulty = 1.5 # Schwierigkeit der Aufgabe
```

5.5.2 Berechnung der erwarteten Erfolgswahrscheinlichkeit

Der erste Berechnungsschritt des Elo-Verfahrens besteht in der Bestimmung der erwarteten Erfolgswahrscheinlichkeit.

Die im vorherigen Kapitel eingeführte Formel

$$P_{si} = \frac{1}{1 + e^{d_i - \theta_s}}$$

lässt sich in Python direkt umsetzen:

```
import math

def probability(theta, difficulty):
    return 1 / (1 + math.exp(difficulty - theta))
```

Die Funktion erhält die Fähigkeit eines Lernenden und die Schwierigkeit einer Aufgabe als Eingabe und liefert die erwartete Erfolgswahrscheinlichkeit zurück.

Für die Werte aus dem vorherigen Beispiel ergibt sich:

```
p = probability(0.5, 1.5)
print(round(p, 2))
```

Ausgabe:

```
0.27
```

Das System erwartet somit eine korrekte Antwort mit einer Wahrscheinlichkeit von etwa 27 %.

5.5.3 Aktualisierung der Bewertungen

Nach der Bearbeitung einer Aufgabe werden die Bewertungen aktualisiert. Hierzu werden die in Kapitel 5 eingeführten Aktualisierungsgleichungen verwendet.

Die Aktualisierung kann in Python wie folgt implementiert werden:

```
def update(theta, difficulty, result, k=0.1):

    p = probability(theta, difficulty)

    theta_new = theta + k * (result - p)
    difficulty_new = difficulty - k * (result - p)

    return theta_new, difficulty_new
```

Die Funktion erhält:

- die Fähigkeit des Lernenden,
- die Schwierigkeit der Aufgabe,
- das beobachtete Ergebnis (0 oder 1),
- sowie die Lernrate k.

Als Ergebnis liefert sie die aktualisierten Werte zurück.

5.5.4 Durchführung einer Aktualisierung

Die zuvor implementierten Funktionen können nun kombiniert werden.

Angenommen, ein Lernender beantwortet die betrachtete Aufgabe korrekt:

```
theta = 0.5
difficulty = 1.5

theta, difficulty = update(
    theta,
    difficulty,
    result=1,
    k=0.1
)

print(round(theta, 3))
print(round(difficulty, 3))
```

Ausgabe:

```
0.573
1.427
```

Die Werte entsprechen exakt den Ergebnissen des zuvor durchgerechneten Beispiels. Die Fähigkeit des Lernenden steigt an, während die Schwierigkeit der Aufgabe leicht reduziert wird.

5.5.5 Zusammenspiel der einzelnen Schritte

Der vollständige Elo-Algorithmus besteht somit aus einer wiederholten Folge von Berechnungsschritten:

1. Aktuelle Fähigkeit und Aufgabenschwierigkeit bestimmen.
2. Erwartete Erfolgswahrscheinlichkeit berechnen.
3. Tatsächliches Ergebnis beobachten.
4. Vorhersagefehler bestimmen.
5. Fähigkeit und Schwierigkeit aktualisieren.
6. Mit der nächsten Aufgabe fortfahren.

Durch die wiederholte Anwendung dieser Schritte entsteht ein dynamisches Modell des Lernenden, das sich kontinuierlich an neue Beobachtungen anpasst.

Im nächsten Abschnitt wird dieser Prozess mithilfe einer interaktiven Simulation visualisiert, sodass die Auswirkungen unterschiedlicher Fähigkeiten, Aufgabenschwierigkeiten und Lernraten unmittelbar untersucht werden können.

5.6 Interaktive Simulation des Elo-Verfahrens

Die mathematischen Grundlagen und die Implementierung des Elo-Verfahrens wurden in den vorherigen Abschnitten erläutert. Viele Eigenschaften des Verfahrens lassen sich jedoch erst durch eigenes Experimentieren vollständig nachvollziehen. Insbesondere der Zusammenhang zwischen Fähigkeit, Aufgabenschwierigkeit, Erfolgswahrscheinlichkeit und Aktualisierung wird deutlicher, wenn die Auswirkungen von Parameteränderungen unmittelbar beobachtet werden können.

Aus diesem Grund wird das Elo-Verfahren im Rahmen dieser Lernressource durch eine interaktive Simulation ergänzt. Die Simulation ermöglicht es, zentrale Parameter des Verfahrens selbst zu verändern und die Auswirkungen auf die Schätzwerte unmittelbar zu beobachten. Dadurch soll das Verständnis der zugrunde liegenden Mechanismen unterstützt und die Verbindung zwischen den mathematischen Formeln und dem Verhalten des Algorithmus verdeutlicht werden.

5.6.1 Nutzung der Simulation

Verändern Sie die Werte für die Fähigkeit des Lernenden (θ_s), die Schwierigkeit der Aufgabe (d_i), die Lernrate (K) sowie das Ergebnis der Bearbeitung ($correct_{si}$). Beobachten Sie anschließend, wie sich die erwartete Erfolgswahrscheinlichkeit und die aktualisierten Schätzwerte verändern.

Führen Sie mehrere Aktualisierungsschritte nacheinander durch und vergleichen Sie die Entwicklung der Fähigkeits- und Schwierigkeitswerte. Achten Sie insbesondere darauf, wie stark sich die Bewertungen bei erwarteten und unerwarteten Ergebnissen verändern und welchen Einfluss die Wahl der Lernrate auf die Aktualisierung hat.

```
//| echo: false

viewof thetaStart = Inputs.range([-3, 3], {
  value: 0.5,
  step: 0.1,
  label: " : Startfähigkeit des Lernenden"
})

viewof difficultyStart = Inputs.range([-3, 3], {
  value: 1.5,
  step: 0.1,
  label: "d : Startschwierigkeit der Aufgabe"
})

viewof k = Inputs.range([0.01, 1], {
  value: 0.1,
  step: 0.01,
```

```

    label: "K: Lernrate"
  })

viewof resultText = Inputs.radio(
  ["Korrekt = 1", "Falsch = 0"],
  {
    value: "Korrekt = 1",
    label: "correct : Ergebnis der Bearbeitung"
  }
)

```

```

//| echo: false

mutable thetaCurrent = thetaStart
mutable difficultyCurrent = difficultyStart
mutable stepCount = 0
mutable history = []

```

```

//| echo: false

result = resultText === "Korrekt = 1" ? 1 : 0

p = 1 / (1 + Math.exp(difficultyCurrent - thetaCurrent))
predictionError = result - p

thetaPreview = thetaCurrent + k * predictionError
difficultyPreview = difficultyCurrent - k * predictionError

```

```

//| echo: false

viewof applyUpdate = Inputs.button("Aktualisierung durchführen", {
  reduce: () => {
    mutable history = [
      ...history,
      {
        Schritt: stepCount + 1,
        Ergebnis: result,
        "P ": Number(p.toFixed(3)),
        " vorher": Number(thetaCurrent.toFixed(3)),
        " nachher": Number(thetaPreview.toFixed(3)),
        "d nachher": Number(difficultyPreview.toFixed(3))
      }
    ]
  }
})

```

```

    }
  ]

  mutable thetaCurrent = thetaPreview
  mutable difficultyCurrent = difficultyPreview
  mutable stepCount = stepCount + 1
}
})

```

```

///| echo: false

```

```

viewof resetSimulation = Inputs.button("Simulation zurücksetzen", {
  reduce: () => {
    mutable thetaCurrent = thetaStart
    mutable difficultyCurrent = difficultyStart
    mutable stepCount = 0
    mutable history = []
  }
})

```

```

///| echo: false

```

```

html`
<div style="display:grid; grid-template-columns: 1fr 1fr; gap:12px; margin-top:15px;">

  <div style="border:1px solid #ccc; padding:12px; border-radius:8px;">
    <strong>Schritt</strong><br>
    ${stepCount}
  </div>

  <div style="border:1px solid #ccc; padding:12px; border-radius:8px;">
    <strong>P : Erwartete Erfolgswahrscheinlichkeit</strong><br>
    ${(p * 100).toFixed(1)} %
  </div>

  <div style="border:1px solid #ccc; padding:12px; border-radius:8px;">
    <strong> : Aktuelle Fähigkeit</strong><br>
    ${thetaCurrent.toFixed(3)}
  </div>

  <div style="border:1px solid #ccc; padding:12px; border-radius:8px;">
    <strong>d : Aktuelle Schwierigkeit</strong><br>

```

```

    ${difficultyCurrent.toFixed(3)}
  </div>

  <div style="border:1px solid #ccc; padding:12px; border-radius:8px;">
    <strong>Vorhersagefehler</strong><br>
    ${predictionError.toFixed(3)}
  </div>

  <div style="border:1px solid #ccc; padding:12px; border-radius:8px;">
    <strong>Vorschau nach Aktualisierung</strong><br>
    = ${thetaPreview.toFixed(3)}<br>
    d = ${difficultyPreview.toFixed(3)}
  </div>

</div>
`

```

```

//| echo: false

html`
<h4>Verlauf der Aktualisierungen</h4>

${history.length === 0
  ? html`<p>Noch keine Aktualisierung durchgeführt.</p>`
  : html`
    <table style="border-collapse: collapse; width: 100%; margin-top: 10px;">
      <thead>
        <tr>
          <th style="border:1px solid #ccc; padding:6px;">Schritt</th>
          <th style="border:1px solid #ccc; padding:6px;">Ergebnis</th>
          <th style="border:1px solid #ccc; padding:6px;">P </th>
          <th style="border:1px solid #ccc; padding:6px;"> vorher</th>
          <th style="border:1px solid #ccc; padding:6px;"> nachher</th>
          <th style="border:1px solid #ccc; padding:6px;">d nachher</th>
        </tr>
      </thead>
      <tbody>
        ${history.map(row => html`
          <tr>
            <td style="border:1px solid #ccc; padding:6px;">${row.Schritt}</td>
            <td style="border:1px solid #ccc; padding:6px;">${row.Ergebnis}</td>
            <td style="border:1px solid #ccc; padding:6px;">${row["P "]}</td>

```



```

        <td style="border:1px solid #ccc; padding:6px;">${row[" vorher"]}</td>
        <td style="border:1px solid #ccc; padding:6px;">${row[" nachher"]}</td>
        <td style="border:1px solid #ccc; padding:6px;">${row["d nachher"]}</td>
    </tr>
    `)}
</tbody>
</table>
`}
,

```

Die Simulation zeigt, dass die Bewertungen nicht nur vom tatsächlichen Ergebnis abhängen, sondern auch von der zuvor erwarteten Erfolgswahrscheinlichkeit. Wird eine Aufgabe korrekt gelöst, obwohl die Erfolgswahrscheinlichkeit gering war, steigt die Fähigkeit stärker an. Wird eine Aufgabe falsch beantwortet, obwohl eine hohe Erfolgswahrscheinlichkeit erwartet wurde, sinkt die Fähigkeit entsprechend. Die Lernrate (K) bestimmt dabei, wie stark diese Anpassungen ausfallen.

5.7 Anwendungen des Elo-Verfahrens in adaptiven Lernsystemen

Das Elo-Verfahren wird in adaptiven Lernsystemen vor allem zur Schätzung von Fähigkeits- und Schwierigkeitswerten eingesetzt. Dabei wird jede Interaktion zwischen einem Lernenden und einer Aufgabe als Beobachtung genutzt, um die zugrunde liegenden Parameter fortlaufend zu aktualisieren. Durch diese kontinuierliche Aktualisierung eignet sich das Verfahren insbesondere für Systeme, die den Wissensstand von Lernenden während des Lernprozesses modellieren möchten. (Pelánek 2016)

5.7.1 Lernendenmodellierung

Eine zentrale Anwendung des Elo-Verfahrens besteht in der Schätzung der Fähigkeiten von Lernenden. Nach jeder bearbeiteten Aufgabe wird die Fähigkeitsbewertung anhand des beobachteten Ergebnisses aktualisiert. Dadurch entsteht ein dynamisches Modell des aktuellen Wissensstands, das sich kontinuierlich an neue Beobachtungen anpasst. (Pelánek 2016)

5.7.2 Schätzung von Aufgabenschwierigkeiten

Neben der Modellierung von Lernenden können auch Schwierigkeitswerte für Aufgaben geschätzt werden. Neue Aufgaben erhalten zunächst einen Startwert, der im Laufe der Nutzung anhand der Antworten vieler Lernender angepasst wird. Auf diese Weise kann ein System automatisch Informationen über die Schwierigkeit einzelner Aufgaben gewinnen. (Pelánek 2016)

5.7.3 Grundlage adaptiver Entscheidungen

Die geschätzten Fähigkeits- und Schwierigkeitswerte können anschließend als Grundlage adaptiver Entscheidungen dienen. Beispielsweise können Lernsysteme Aufgaben auswählen, deren Schwierigkeit zum aktuellen Leistungsstand eines Lernenden passt. Die eigentliche Aufgabenauswahl ist dabei nicht Bestandteil des Elo-Verfahrens selbst, sondern nutzt die durch das Verfahren bereitgestellten Schätzwerte. (Pelánek 2016)

5.7.4 Open Learner Models

Eine weitere Anwendung besteht in sogenannten Open Learner Models. Dabei werden die durch das System geschätzten Fähigkeitswerte nicht ausschließlich intern verwendet, sondern den Lernenden direkt zugänglich gemacht. Die Lernenden erhalten dadurch Einblick in die Einschätzung ihres aktuellen Wissensstands und können ihre Stärken und Schwächen besser nachvollziehen. Abdi et al. beschreiben einen solchen Ansatz auf Basis eines mehrdimensionalen Elo-Modells (M-Elo), bei dem Fähigkeitswerte für verschiedene Themengebiete visualisiert werden. Die Autoren argumentieren, dass transparente Darstellungen des Lernendenmodells die Reflexion des eigenen Lernfortschritts unterstützen und das Vertrauen in die Empfehlungen eines adaptiven Systems fördern können (Abdi u. a. 2019).

Die dargestellten Anwendungsbereiche verdeutlichen, dass das Elo-Verfahren nicht nur zur Schätzung von Fähigkeiten eingesetzt werden kann, sondern auch die Grundlage verschiedener adaptiver Funktionen in modernen Lernsystemen bildet. Trotz dieser Vorteile besitzt das Verfahren jedoch auch mehrere Einschränkungen, die im nächsten Kapitel betrachtet werden.

5.8 Grenzen und Erweiterungen des Elo-Verfahrens

5.8.1 Grenzen des Standard-Elo-Verfahrens

Das Elo-Verfahren bietet eine vergleichsweise einfache und effiziente Möglichkeit zur Modellierung von Lernenden und Aufgaben. Insbesondere die kontinuierliche Aktualisierung nach jeder Interaktion sowie die geringe Anzahl benötigter Parameter machen das Verfahren für adaptive Lernsysteme attraktiv (Pelánek 2016). Dennoch weist das Standard-Elo-Verfahren mehrere Einschränkungen auf, die seine Aussagekraft in komplexen Bildungsszenarien begrenzen können.

Eine erste Einschränkung besteht darin, dass die Fähigkeit eines Lernenden durch einen einzigen Fähigkeitswert beschrieben wird. Das Verfahren geht somit implizit davon aus, dass sich der Wissensstand einer Person durch eine einzige Dimension repräsentieren lässt. In realen Lernumgebungen setzt sich Wissen jedoch häufig aus mehreren Teilgebieten zusammen. Ein Lernender kann beispielsweise in einem Themenbereich sehr gute Kenntnisse besitzen, während

gleichzeitig Defizite in anderen Bereichen bestehen. Solche Unterschiede können durch einen einzelnen Elo-Wert nur eingeschränkt abgebildet werden (Pelánek 2016).

Darüber hinaus verwendet das Standard-Elo-Verfahren einen konstanten Aktualisierungsparameter (K). Die Wahl dieses Parameters beeinflusst das Verhalten des Modells maßgeblich. Kleine Werte führen zu einer langsamen Anpassung der Schätzwerte, während große Werte zwar schneller auf neue Beobachtungen reagieren, jedoch zu instabilen Schätzungen führen können. Die Verwendung eines festen Parameters stellt daher einen Kompromiss zwischen Stabilität und Anpassungsgeschwindigkeit dar (Pelánek 2016).

Eine weitere Einschränkung besteht darin, dass das Standard-Elo-Modell keine Unsicherheit der Schätzwerte berücksichtigt. Neue Lernende und Aufgaben werden mit derselben Aktualisierungsstärke behandelt wie Objekte, für die bereits viele Beobachtungen vorliegen. Intuitiv erscheint dies problematisch, da die Schätzungen bei wenigen verfügbaren Daten deutlich unsicherer sind als nach einer großen Anzahl von Interaktionen (Pelánek 2016).

Schließlich basiert das Standard-Elo-Verfahren in seiner einfachsten Form auf binären Ergebnissen. Antworten werden lediglich als korrekt oder inkorrekt betrachtet. In realen Bildungssystemen treten jedoch häufig komplexere Situationen auf, beispielsweise Multiple-Choice-Aufgaben mit Ratewahrscheinlichkeit, Teilpunktbewertungen, Hinweissysteme oder die Berücksichtigung von Bearbeitungszeiten. Diese Informationen können durch das Grundmodell nur eingeschränkt genutzt werden (Pelánek 2016).

Aus diesen Gründen wurden verschiedene Erweiterungen des Elo-Verfahrens entwickelt, die versuchen, einzelne Schwächen des Standardmodells zu adressieren. Im folgenden Abschnitt wird zunächst die Verwendung von Unsicherheitsfunktionen als Alternative zu einem konstanten Aktualisierungsparameter betrachtet.

5.8.2 Unsicherheitsfunktionen

Im Standard-Elo-Verfahren wird die Stärke der Aktualisierung durch den konstanten Parameter K bestimmt. Dieser Parameter beeinflusst, wie stark neue Beobachtungen die Bewertungen verändern. Die Wahl eines geeigneten Wertes stellt dabei einen Kompromiss dar: Kleine Werte führen zu stabilen, aber langsamen Anpassungen, während große Werte schnelle Reaktionen ermöglichen, jedoch zu stärkeren Schwankungen der Schätzwerte führen können. Eine wesentliche Einschränkung eines konstanten Aktualisierungsparameters besteht darin, dass die Unsicherheit der Schätzwerte nicht berücksichtigt wird. Zu Beginn liegen für einen Lernenden oder eine Aufgabe nur wenige Informationen vor. Die Schätzungen sind daher zunächst mit einer hohen Unsicherheit verbunden. Mit zunehmender Anzahl beobachteter Interaktionen steigt dagegen das Vertrauen in die geschätzten Werte (Pelánek 2016).

Aus diesem Grund verwenden viele Erweiterungen des Elo-Verfahrens anstelle eines konstanten Parameters K eine sogenannte Unsicherheitsfunktion. Die Grundidee besteht darin, die Stärke der Aktualisierung von der Anzahl bereits beobachteter Interaktionen abhängig zu machen. Bei

wenigen verfügbaren Daten fallen die Aktualisierungen zunächst groß aus, sodass das Modell schnell auf neue Informationen reagieren kann. Mit zunehmender Anzahl von Beobachtungen wird die Aktualisierung schrittweise reduziert, wodurch die Schätzwerte stabiler werden (Pelánek 2016).




Abbildung 5.1: Vergleich eines konstanten Aktualisierungsparameters K mit verschiedenen Unsicherheitsfunktionen. Die gestrichelte Linie kennzeichnet den tatsächlichen Schwierigkeitswert. Quelle: (Pelánek 2016).

Abbildung 5.1 verdeutlicht den Einfluss des Aktualisierungsparameters auf die Schätzung der Aufgabenschwierigkeit. Während große konstante Werte zu deutlichen Schwankungen führen können, ermöglichen Unsicherheitsfunktionen zunächst schnelle grobe Schätzungen und anschließend eine zunehmend stabile Annäherung an den tatsächlichen Parameterwert (Pelánek 2016).

Anschaulich entspricht dieses Vorgehen dem intuitiven Umgang mit Unsicherheit. Bei einem neu registrierten Lernenden liegen zunächst kaum Informationen über dessen Leistungsstand vor. Bereits wenige Antworten können daher einen erheblichen Einfluss auf die Schätzung haben. Nach einer großen Anzahl bearbeiteter Aufgaben erscheint eine einzelne zusätzliche Beobachtung dagegen deutlich weniger aussagekräftig.

Pelánek verweist in diesem Zusammenhang auf verschiedene Ansätze zur Modellierung von Unsicherheit. Neben einfachen Unsicherheitsfunktionen existieren auch komplexere Verfahren wie das Glicko-System oder TrueSkill, die Unsicherheit explizit modellieren. Für viele Anwendungen im Bildungsbereich zeigen Untersuchungen jedoch, dass bereits einfache Unsicherheitsfunktionen zu einer deutlichen Verbesserung gegenüber einem konstanten Aktualisierungsparameter führen können (Pelánek 2016).

Die Verwendung von Unsicherheitsfunktionen stellt somit eine vergleichsweise einfache Erweiterung des Elo-Verfahrens dar, die insbesondere in frühen Phasen der Schätzung eine schnellere Anpassung ermöglicht und gleichzeitig langfristig stabilere Bewertungen erzeugt.

5.8.3 Multiple-Choice-Aufgaben und Teilpunkte

Eine weitere Einschränkung des Standard-Elo-Verfahrens besteht darin, dass Antworten in ihrer einfachsten Form ausschließlich als korrekt oder inkorrekt bewertet werden. Die Erfolgsvariable nimmt somit lediglich die Werte 0 oder 1 an. Diese Annahme ist für viele Anwendungsszenarien ausreichend, bildet jedoch zahlreiche Situationen realer Lernumgebungen nur unzureichend ab. In adaptiven Lernsystemen kommen häufig Multiple-Choice-Aufgaben, Aufgaben mit Teilpunkten oder Lernumgebungen mit Hinweissystemen zum Einsatz. In solchen Fällen liefern Lerninteraktionen oftmals mehr Informationen als eine reine Richtig-Falsch-Bewertung erfassen kann (Pelánek 2016).

Ein Beispiel hierfür sind Multiple-Choice-Aufgaben. Bei diesen Aufgaben besteht grundsätzlich die Möglichkeit, dass eine korrekte Antwort durch Raten zustande kommt. Bei vier Antwortmöglichkeiten liegt die Wahrscheinlichkeit einer zufällig richtigen Antwort bereits bei 25 %. Das Standard-Elo-Verfahren behandelt jedoch jede korrekte Antwort gleich und unterscheidet nicht zwischen tatsächlich vorhandenem Wissen und einem zufälligen Treffer. Dadurch kann insbesondere bei kurzen Tests oder wenigen Beobachtungen eine Überschätzung der Fähigkeit auftreten.

Pelánek beschreibt eine einfache Erweiterung des Elo-Verfahrens zur Berücksichtigung von Ratewahrscheinlichkeiten bei Multiple-Choice-Aufgaben. Hierzu wird die Berechnung der erwarteten Erfolgswahrscheinlichkeit angepasst. Für eine Aufgabe mit k Antwortmöglichkeiten ergibt sich die Wahrscheinlichkeit einer korrekten Antwort zu

$$P(\text{korrekt}) = \frac{1}{k} + \frac{1 - \frac{1}{k}}{1 + e^{-(\theta - d)}} \quad (5)$$

Der erste Term berücksichtigt die Wahrscheinlichkeit eines zufälligen Treffers, während der zweite Term den eigentlichen Einfluss von Fähigkeit und Aufgabenschwierigkeit beschreibt (Pelánek 2016). Dadurch wird die Erfolgswahrscheinlichkeit insbesondere bei sehr schwierigen Aufgaben realistischer modelliert.

Neben Ratewahrscheinlichkeiten stellen Teilpunkte eine weitere Herausforderung für das Standard-Elo-Verfahren dar. Viele Aufgaben liefern nicht nur die Information, ob eine Lösung richtig oder falsch ist, sondern erlauben eine abgestufte Bewertung. Dies betrifft beispielsweise Programmieraufgaben, mathematische Aufgaben mit mehreren Zwischenschritten oder komplexe Problemlöseaufgaben. Ein Lernender kann dabei einen Teil der Aufgabe erfolgreich bearbeiten, ohne die vollständige Lösung zu erreichen. Da das Elo-Verfahren ursprünglich nicht auf binäre Ergebnisse beschränkt ist, können solche Teilbewertungen vergleichsweise einfach integriert werden. Anstelle der Werte 0 oder 1 wird die Erfolgsvariable als kontinuierlicher Wert zwischen 0 und 1 interpretiert. Eine Aufgabe, bei der 75 % der möglichen Punkte erreicht werden, kann beispielsweise mit einem Erfolgswert von

$$S = 0.75$$

in die Aktualisierung eingehen. Die grundlegende Struktur der Elo-Gleichungen bleibt dabei unverändert. Lediglich die Definition des beobachteten Ergebnisses wird erweitert (Pelánek 2016).

Ein ähnlicher Ansatz kann bei der Verwendung von Hinweissystemen eingesetzt werden. Viele intelligente Tutorensysteme erlauben es Lernenden, während der Bearbeitung zusätzliche Hinweise anzufordern. Eine korrekte Lösung nach mehreren Hilfestellungen besitzt jedoch eine andere Aussagekraft als eine vollständig selbstständig gefundene Lösung. Deshalb können korrekte Antworten abhängig von der Anzahl verwendeter Hinweise mit reduzierten Erfolgswerten bewertet werden. Eine vollständig selbstständig gelöste Aufgabe könnte beispielsweise den Wert 1 erhalten, während eine korrekte Lösung nach mehreren Hinweisen lediglich mit einem geringeren Wert in die Aktualisierung eingeht (Pelánek 2016).

Die beschriebenen Erweiterungen zeigen, dass das Elo-Verfahren deutlich flexibler eingesetzt werden kann, als die binäre Grundform vermuten lässt. Durch die Berücksichtigung von Ratewahrscheinlichkeiten, Teilpunkten und Hinweisen können zusätzliche Informationen aus Lerninteraktionen genutzt werden, ohne die grundlegende Struktur des Verfahrens verändern zu müssen. Dennoch beziehen sich diese Erweiterungen weiterhin ausschließlich auf das Antwortergebnis selbst. Weitere Informationen über den Lösungsprozess, beispielsweise die benötigte Bearbeitungszeit, bleiben unberücksichtigt. Aus diesem Grund wurden zusätzliche Elo-Varianten entwickelt, die auch zeitbezogene Informationen in die Modellierung einbeziehen.

5.8.4 Berücksichtigung von Bearbeitungszeiten

Die bisher betrachteten Erweiterungen des Elo-Verfahrens beziehen sich ausschließlich auf das Ergebnis einer Aufgabe. Dabei wird bewertet, ob eine Antwort korrekt oder inkorrekt ist beziehungsweise welcher Teil einer Aufgabe erfolgreich gelöst wurde. Informationen über den eigentlichen Lösungsprozess bleiben jedoch unberücksichtigt. Insbesondere die Bearbeitungszeit einer Aufgabe kann zusätzliche Hinweise auf den Wissensstand eines Lernenden liefern und stellt daher eine potenziell wertvolle Informationsquelle für adaptive Lernsysteme dar.

Betrachtet man zwei Lernende, die dieselbe Aufgabe korrekt beantworten, erscheint eine identische Bewertung nicht immer angemessen. Ein Lernender kann die Lösung innerhalb weniger Sekunden finden, während ein anderer deutlich mehr Zeit benötigt. Obwohl beide Antworten korrekt sind, deutet die längere Bearbeitungszeit möglicherweise auf Unsicherheit, langsames Abrufen von Wissen oder einen höheren kognitiven Aufwand hin. Umgekehrt können sehr schnelle Fehlantworten auf unüberlegtes Raten hindeuten. Das Standard-Elo-Verfahren berücksichtigt solche Unterschiede nicht, da ausschließlich die Korrektheit der Antwort in die Aktualisierung eingeht (Pelánek 2016).

Aus diesem Grund wurden verschiedene Erweiterungen entwickelt, die Bearbeitungszeiten in die Modellierung einbeziehen. Ein erster Ansatz besteht darin, die Bearbeitungszeit selbst als Leistungsmaß zu verwenden. Dies eignet sich insbesondere für Aufgabentypen, bei denen die Lösung grundsätzlich eindeutig überprüfbar ist und die benötigte Zeit den entscheidenden

Leistungsunterschied darstellt. Beispiele hierfür sind Sudoku-Rätsel oder Programmieraufgaben, bei denen die Zeit bis zur korrekten Lösung betrachtet wird (Pelánek 2016).

Analog zum klassischen Elo-Verfahren besitzt jeder Lernende einen Fähigkeitsparameter θ_s und jede Aufgabe einen Schwierigkeitsparameter d_p . Anstelle einer Erfolgswahrscheinlichkeit wird jedoch die erwartete logarithmierte Bearbeitungszeit modelliert:

$$E(t \mid s, p) = d_p - \theta_s \quad (6)$$

Dabei bezeichnet $E(t \mid s, p)$ die erwartete Bearbeitungszeit eines Lernenden s für die Aufgabe p . Hohe Fähigkeitswerte führen zu kürzeren erwarteten Bearbeitungszeiten, während hohe Schwierigkeitswerte längere Bearbeitungszeiten erwarten lassen.

Nachdem die tatsächliche Bearbeitungszeit t_{sp} beobachtet wurde, können die Parameter ähnlich wie im klassischen Elo-Verfahren aktualisiert werden:

$$\theta_{s,\text{neu}} = \theta_{s,\text{alt}} + K(E(t \mid s, p) - t_{sp}) \quad (7)$$

$$d_{p,\text{neu}} = d_{p,\text{alt}} + K(t_{sp} - E(t \mid s, p)) \quad (8)$$

Bearbeitet ein Lernender eine Aufgabe schneller als vom Modell erwartet, erhöht sich seine geschätzte Fähigkeit. Gleichzeitig sinkt die geschätzte Schwierigkeit der Aufgabe. Bei längeren Bearbeitungszeiten erfolgt die Aktualisierung entsprechend in die entgegengesetzte Richtung. Das Verfahren nutzt somit dieselbe Grundidee wie das klassische Elo-Modell, ersetzt jedoch die Antwortkorrektheit durch die Bearbeitungszeit als beobachtete Leistungsgröße (Pelánek 2016).

In vielen Anwendungen erweist sich jedoch die alleinige Betrachtung der Bearbeitungszeit als unzureichend. Häufig liefern sowohl die Korrektheit einer Antwort als auch die benötigte Bearbeitungszeit relevante Informationen über den Lernprozess. Aus diesem Grund wurden Modelle entwickelt, die beide Informationsquellen gemeinsam berücksichtigen. Ein bekanntes Beispiel ist die von Klinkenberg u. a. (2011) vorgeschlagene *“high speed, high stakes”*-Regel. Dabei wird die Bewertung einer Antwort nicht nur von ihrer Korrektheit, sondern zusätzlich von der Bearbeitungszeit beeinflusst. Schnelle Antworten besitzen einen stärkeren Einfluss auf die Bewertung, während der Einfluss mit zunehmender Bearbeitungsdauer abnimmt (Klinkenberg u. a. 2011).

Der Nutzen solcher Erweiterungen hängt jedoch stark vom jeweiligen Anwendungskontext ab. In Lernsystemen, die Zeitlimits oder sichtbare Zeitinformationen verwenden, kann die Bearbeitungszeit ein aussagekräftiger Leistungsindikator sein. In anderen Anwendungen wird die Bearbeitungszeit zwar erfasst, den Lernenden jedoch nicht explizit angezeigt. In diesen Fällen kann sie ebenfalls zusätzliche Informationen liefern, erfordert jedoch angepasste Bewertungsverfahren (Pelánek 2016).

Die Berücksichtigung von Bearbeitungszeiten erweitert das Elo-Verfahren somit um eine zusätzliche Dimension der Leistungsbewertung. Anstatt ausschließlich das Ergebnis einer Aufgabe zu betrachten, können nun auch Informationen über den Lösungsprozess in die Modellierung einfließen. Dennoch bleibt die Fähigkeit eines Lernenden weiterhin durch einen einzelnen Wert beschrieben. In vielen Lerngebieten reicht eine solche eindimensionale Darstellung jedoch nicht aus, da Wissen aus mehreren Teilkompetenzen besteht. Aus diesem Grund wurden mehrdimensionale Erweiterungen entwickelt, die mehrere Wissenskomponenten gleichzeitig modellieren.

5.8.5 Multivariate Elo-Modelle

Die bisher betrachteten Erweiterungen des Elo-Verfahrens verändern vor allem die Art und Weise, wie Informationen aus Lerninteraktionen verarbeitet werden. Unsicherheitsfunktionen, Teilpunkte oder Bearbeitungszeiten können die Schätzung von Fähigkeiten verbessern, ändern jedoch nichts an einer grundlegenden Annahme des Standard-Elo-Modells: Die Fähigkeit eines Lernenden wird durch einen einzigen Wert beschrieben.

In vielen Lerngebieten erweist sich diese Annahme als problematisch. Wissen besteht häufig aus mehreren Teilkompetenzen, die unterschiedlich stark ausgeprägt sein können. Ein Lernender kann beispielsweise sehr gute Kenntnisse in Algebra besitzen, gleichzeitig jedoch Schwierigkeiten in der Geometrie haben. Ein einzelner Fähigkeitswert kann solche Unterschiede nur eingeschränkt erfassen. Werden alle Leistungen auf einer gemeinsamen Skala zusammengefasst, gehen Informationen über die Struktur des Wissens teilweise verloren (Pelánek 2016).

Aus diesem Grund wurden multivariate Erweiterungen des Elo-Verfahrens entwickelt. Anstelle eines einzelnen Fähigkeitsparameters wird die Kompetenz eines Lernenden durch mehrere Werte beschrieben. Jeder dieser Parameter repräsentiert einen bestimmten Wissensbereich oder eine einzelne Kompetenz. Im Bereich der Mathematik könnten dies beispielsweise Bruchrechnung, Polynome oder trigonometrische Funktionen sein (Pelánek 2016).

Ein wesentlicher Gedanke multivariater Modelle besteht darin, dass verschiedene Wissenskomponenten häufig nicht unabhängig voneinander sind. Kenntnisse in einem Themengebiet können mit Fähigkeiten in anderen Bereichen zusammenhängen. Antworten auf Aufgaben liefern daher nicht nur Informationen über das unmittelbar geprüfte Konzept, sondern unter Umständen auch über verwandte Wissensbereiche.

Zur Modellierung dieser Zusammenhänge werden Korrelationen zwischen den einzelnen Wissenskomponenten bestimmt. Beantwortet ein Lernender eine Aufgabe zu einer bestimmten Wissenskomponente, wird nicht ausschließlich die zugehörige Fähigkeit aktualisiert. Stattdessen können auch die Fähigkeitswerte verwandter Konzepte angepasst werden. Pelánek beschreibt diesen Ansatz durch die folgende Aktualisierungsregel:

$$\theta_{sj,\text{neu}} = \theta_{sj,\text{alt}} + c_{ij}K(\text{correct} - P(\text{correct} = 1)) \quad (9)$$

Dabei bezeichnet θ_{sj} die Fähigkeit des Lernenden s im Wissensbereich j . Der Faktor c_{ij} beschreibt die Korrelation zwischen den Wissenskomponenten i und j . Eine korrekte oder inkorrekte Antwort auf eine Aufgabe des Konzepts i beeinflusst somit nicht nur die Schätzung für dieses Konzept selbst, sondern gegebenenfalls auch die Bewertungen verwandter Wissensbereiche (Pelánek 2016).

Anschaulich bedeutet dies, dass Lernfortschritte in einem Themengebiet Hinweise auf den Wissensstand in verwandten Bereichen liefern können. Beherrscht ein Lernender beispielsweise grundlegende algebraische Verfahren, lässt dies häufig auch Rückschlüsse auf Kompetenzen in verwandten mathematischen Themen zu. Multivariate Elo-Modelle nutzen solche Zusammenhänge, um differenziertere Fähigkeitsprofile zu erzeugen als das eindimensionale Standard-Elo-Verfahren.

Der zusätzliche Informationsgewinn geht jedoch mit einer höheren Modellkomplexität einher. Neben den einzelnen Fähigkeitswerten müssen nun auch die Beziehungen zwischen den Wissenskomponenten modelliert werden. Zudem setzt der Ansatz voraus, dass Aufgaben bestimmten Wissensbereichen zugeordnet werden können und geeignete Informationen über deren Zusammenhänge vorliegen (Pelánek 2016).

Multivariate Elo-Modelle stellen damit einen wichtigen Schritt von einer eindimensionalen Leistungsbewertung hin zu einer strukturierten Repräsentation von Wissen dar.

5.8.6 Erweiterung durch Lernmodellierung (PFAE)

Die bisher betrachteten Erweiterungen des Elo-Verfahrens verbessern vor allem die Schätzung des aktuellen Wissensstands von Lernenden. Dabei bleibt jedoch eine grundlegende Annahme des klassischen Elo-Modells bestehen: Antworten werden ausschließlich als Beobachtungen bereits vorhandenen Wissens interpretiert. Eine korrekte Antwort liefert Hinweise auf eine hohe Fähigkeit, während eine falsche Antwort auf Wissensdefizite hindeutet.

In Bildungsszenarien greift diese Sichtweise jedoch häufig zu kurz. Die Bearbeitung einer Aufgabe dient nicht nur der Messung von Wissen, sondern stellt zugleich eine Lerngelegenheit dar. Lernende können bereits durch die Auseinandersetzung mit einer Aufgabe neue Kenntnisse erwerben oder bestehendes Wissen festigen. Eine Antwort liefert daher nicht nur Informationen über den aktuellen Wissensstand, sondern kann selbst einen Lernprozess auslösen (Papoušek u. a. 2014; Pelánek 2016).

Aus diesem Grund schlagen Papoušek et al. sowie Pelánek eine Erweiterung des Elo-Verfahrens vor, die unter der Bezeichnung Performance Factor Analysis Extended Elo (PFAE) beschrieben wird. Die Grundidee besteht darin, korrekte und inkorrekte Antworten unterschiedlich zu behandeln. Während das klassische Elo-Verfahren für beide Fälle denselben Aktualisierungsparameter verwendet, nutzt PFAE getrennte Lernraten für erfolgreiche und nicht erfolgreiche Bearbeitungen (Papoušek u. a. 2014; Pelánek 2015, 2016).

Die Aktualisierung erfolgt dabei nach den folgenden Regeln:

$$\theta_{si, \text{neu}} = \begin{cases} \theta_{si, \text{alt}} + \gamma(1 - P_i), & \text{falls die Antwort korrekt war} \\ \theta_{si, \text{alt}} + \delta P_i, & \text{falls die Antwort inkorrekt war} \end{cases}$$

(Pelánek 2016)

Dabei beschreiben γ und δ unterschiedliche Lernraten für korrekte beziehungsweise inkorrekte Antworten. Die Parameter erlauben es, den erwarteten Wissenszuwachs abhängig vom Ergebnis einer Aufgabe unterschiedlich zu modellieren (Pelánek 2016).

Die Motivation hinter diesem Ansatz liegt in der Beobachtung, dass Lernende auch aus Fehlern lernen können. Eine inkorrekte Antwort muss daher nicht zwangsläufig zu einer Verringerung der geschätzten Fähigkeit führen. Stattdessen kann sie als Hinweis darauf interpretiert werden, dass während der Bearbeitung ein Lernprozess stattgefunden hat. Das Modell versucht somit nicht nur den aktuellen Wissensstand abzuschätzen, sondern berücksichtigt zusätzlich mögliche Wissenszuwächse durch die Interaktion mit Lernaufgaben (Pelánek 2016).

Während das ursprüngliche Elo-Verfahren primär der Leistungsbewertung dient, rückt bei PFAE zunehmend die Modellierung von Lernprozessen in den Mittelpunkt. Die Erweiterung verdeutlicht damit eine zentrale Entwicklung adaptiver Lernsysteme: den Übergang von der reinen Wissensschätzung hin zur expliziten Modellierung individueller Lernverläufe (Pelánek 2016).

7

References

- Abdelrahman, Ghada, Qian Wang, und Bruno P. Nunes. 2023. „Knowledge Tracing: A Survey“. *ACM Computing Surveys* 55 (11): 1–37. <https://doi.org/10.1145/3567604>.
- Abdi, Solmaz, Hassan Khosravi, Shazia Sadiq, und Dragan Gašević. 2019. „A Multivariate Elo-based Learner Model for Adaptive Educational Systems“. *arXiv preprint arXiv:1910.12581*. <https://arxiv.org/abs/1910.12581>.
- Alajlani, Nawaf, Michael Crabb, und Iain Murray. 2024. „A Systematic Review in Understanding Stakeholders’ Role in Developing Adaptive Learning Systems“. *Journal of Computers in Education* 11: 901–20. <https://doi.org/10.1007/s40692-023-00283-x>.
- Arksey, Hilary, und Lisa O’Malley. 2005. „Scoping Studies: Towards a Methodological Framework“. *International Journal of Social Research Methodology* 8 (1): 19–32. <https://doi.org/10.1080/1364557032000119616>.
- Böck, Florian. 2025. „Learner Models: Design, Components, Structure, and Modelling“. *User Modeling and User-Adapted Interaction*, Online-Vorab-Publikation. <https://doi.org/10.1007/s11257-025-09434-4>.
- Desmarais, Michel C., und Ryan S. J. d. Baker. 2012. „A Review of Recent Advances in Learner and Skill Modeling in Intelligent Learning Environments“. *User Modeling and User-Adapted Interaction* 22 (1–2): 9–38. <https://doi.org/10.1007/s11257-011-9106-8>.
- Elo, Arpad E. 1978. *The Rating of Chessplayers, Past and Present*. Arco Publishing.
- George, Gifty, und A. M. Lal. 2019. „Review of Ontology-Based Recommender Systems in E-Learning“. *Computers & Education* 142: 103642. <https://doi.org/10.1016/j.compedu.2019.103642>.
- Gligorea, Ilie, Marius Cioca, Romana Oancea, Andra-Teodora Gorski, Hortensia Gorski, und Paul Tudorache. 2023. „Adaptive Learning Using Artificial Intelligence in e-Learning: A Literature Review“. *Education Sciences* 13 (12): 1216. <https://doi.org/10.3390/educsci13121216>.
- Han, K. C. T. 2018. „Components of the Item Selection Algorithm in Computerized Adaptive Testing“. *Journal of Educational Evaluation for Health Professions* 15: 7. <https://doi.org/>

10.3352/jeehp.2018.15.7.

- Hariyanto, F. X. D. Kristianingsih, und R. Maharani. 2025. „Artificial Intelligence in Adaptive Education: A Systematic Review of Techniques for Personalized Learning“. *Discover Education* 4: 458. <https://doi.org/10.1007/s44217-025-00908-6>.
- Klinkenberg, S., M. Straatemeier, und Han L. J. van der Maas. 2011. „Computer Adaptive Practice of Maths Ability Using a New Item Response Model for On the Fly Ability and Difficulty Estimation“. *Computers & Education* 57 (2): 1813–24. <https://doi.org/10.1016/j.compedu.2011.02.003>.
- Liu, Q., Y. Zhuang, H. Bi, u. a. 2024. „Survey of Computerized Adaptive Testing: A Machine Learning Perspective“. *arXiv preprint arXiv:2404.00712*. <https://arxiv.org/abs/2404.00712>.
- Martin, Florence, Yiyin Chen, Richard L. Moore, und Chad D. Westine. 2020. „Systematic Review of Adaptive Learning Research Designs, Context, Strategies, and Technologies from 2009 to 2018“. *Educational Technology Research and Development* 68 (4): 1903–29. <https://doi.org/10.1007/s11423-020-09759-9>.
- Mayer, Richard E. 2005. „Cognitive Theory of Multimedia Learning“. In *The Cambridge Handbook of Multimedia Learning*, herausgegeben von Richard E. Mayer. Cambridge Handbooks in Psychology. Cambridge University Press. <https://doi.org/10.1017/CBO9780511816819.004>.
- Nabizadeh, Amir Hossein, José Paulo Leal, Hamed N. Rafsanjani, und Rajiv Ratn Shah. 2020. „Learning Path Personalization and Recommendation Methods: A Survey of the State-of-the-Art“. *Expert Systems with Applications* 159: 113596. <https://doi.org/10.1016/j.eswa.2020.113596>.
- Orji, Fidelia A., und Julita Vassileva. 2022. „Automatic Modeling of Student Characteristics with Interaction and Physiological Data Using Machine Learning: A Review“. *Frontiers in Artificial Intelligence* 5. <https://doi.org/10.3389/frai.2022.1015660>.
- Papoušek, Jan, Radek Pelánek, und Vít Stanislav. 2014. „Adaptive Practice Assignment in Geography Learning“. *Proceedings of the 7th International Conference on Educational Data Mining (EDM 2014)*, 260–63. https://educationaldatamining.org/EDM2014/uploads/procs2014/long%20papers/6_EDM-2014-Full.pdf.
- Pelánek, Radek. 2015. *Modeling Students' Memory for Application in Adaptive Educational Systems*. Masaryk University. <https://eric.ed.gov/?id=ED560907>.
- Pelánek, Radek. 2016. „Applications of the Elo Rating System in Adaptive Educational Systems“. *Computers & Education* 98: 169–79. <https://doi.org/10.1016/j.compedu.2016.03.017>.

- Pelánek, Radek. 2017. „Bayesian knowledge tracing, logistic models, and beyond: an overview of learner modeling techniques“. *User Modeling and User-Adapted Interaction* 27: 313–50. <https://doi.org/10.1007/s11257-017-9193-2>.
- Peters, Micah D. J., Christina Marnie, Andrea C. Tricco, u. a. 2020. „Updated Methodological Guidance for the Conduct of Scoping Reviews“. *JBIM Evidence Synthesis* 18 (10): 2119–26. <https://doi.org/10.11124/JBIES-20-00167>.
- Plass, Jan L., und Shashank Pawar. 2020. „Toward a Taxonomy of Adaptivity for Learning“. *Journal of Research on Technology in Education* 52 (3): 275–300. <https://doi.org/10.1080/15391523.2020.1719943>.
- Plooy, Eileen du, Daleen Casteleijn, und Denise Franzsen. 2024. „Personalized Adaptive Learning in Higher Education: A Scoping Review of Key Characteristics and Impact on Academic Performance and Engagement“. *Heliyon* 10 (21): e39630. <https://doi.org/10.1016/j.heliyon.2024.e39630>.
- Riedmann, A., P. Schaper, und B. Lugin. 2025. „Reinforcement Learning in Education: A Systematic Literature Review“. *International Journal of Artificial Intelligence in Education*, Online-Vorab-Publikation. <https://doi.org/10.1007/s40593-025-00494-6>.
- Shen, Shuanghong, Qi Liu, Zhenya Huang, u. a. 2024. „A Survey of Knowledge Tracing: Models, Variants, and Applications“. *IEEE Transactions on Learning Technologies* 17: 1858–79. <https://doi.org/10.1109/TLT.2024.3383325>.
- Sibley, Leonie, Andreas Lachner, Christine Plicht, u. a. 2024. „Feasibility of adaptive teaching with technology: Which implementation conditions matter?“. *Computers & Education* 219: 105108. <https://doi.org/10.1016/j.compedu.2024.105108>.
- Silva, F. L. da, B. K. Slodkowski, K. K. A. da Silva, u. a. 2023. „A Systematic Literature Review on Educational Recommender Systems for Teaching and Learning: Research Trends, Limitations and Opportunities“. *Education and Information Technologies* 28: 3289–328. <https://doi.org/10.1007/s10639-022-11341-9>.
- Simon, Patricia D., und Lily Min Zeng. 2024. „Behind the Scenes of Adaptive Learning: A Scoping Review of Teachers’ Perspectives on the Use of Adaptive Learning Technologies“. *Education Sciences* 14 (12): 1413. <https://doi.org/10.3390/educsci14121413>.
- Tan, L. Y., S. Hu, D. J. Yeo, und K. H. Cheong. 2025. „Artificial Intelligence-Enabled Adaptive Learning Platforms: A Review“. *Computers and Education: Artificial Intelligence* 9: 100429. <https://doi.org/10.1016/j.caeai.2025.100429>.
- Tricco, Andrea C., Erin Lillie, Wasifa Zarin, u. a. 2018. „PRISMA Extension for Scoping

Reviews (PRISMA-ScR): Checklist and Explanation“. *Annals of Internal Medicine* 169 (7): 467–73. <https://doi.org/10.7326/M18-0850>.

Wang, Xiyu, Yukiko Maeda, und Hua-Hua Chang. 2025. „Development and techniques in learner model in adaptive e-learning system: A systematic review“. *Computers & Education* 225: 105184. <https://doi.org/10.1016/j.compedu.2024.105184>.